



Instituto Federal de Educação, Ciência e Tecnologia do Ceará
PPGER – PPGCC

Aula 8: Segmentação em imagens

Visão Computacional

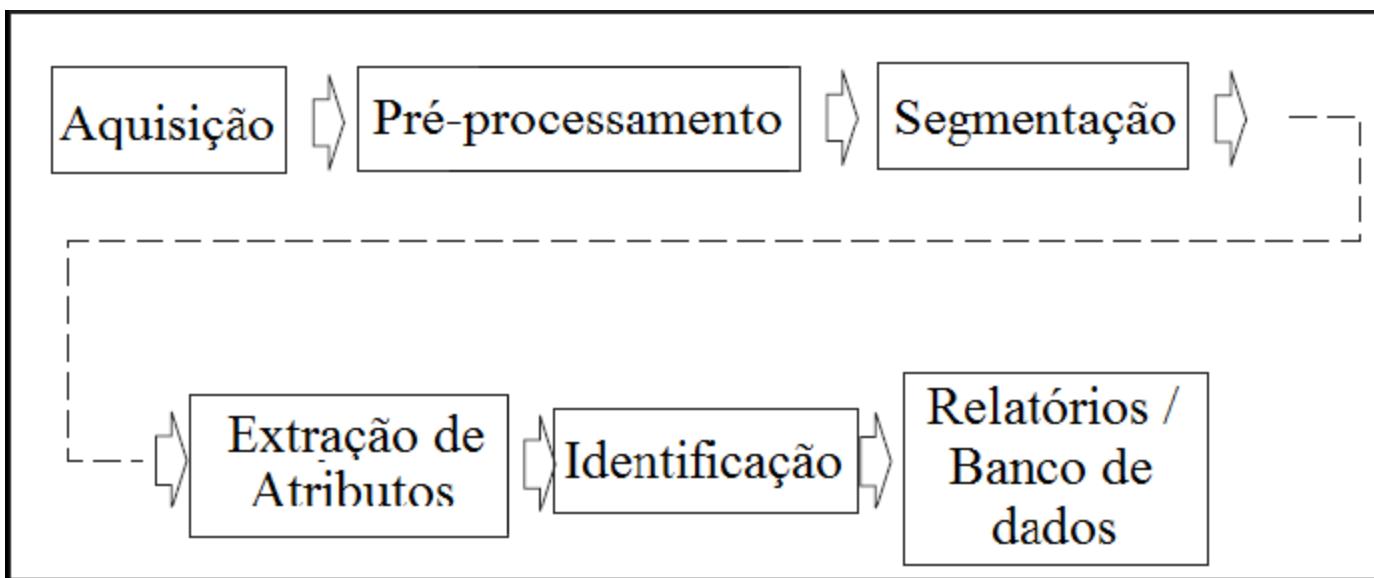
Prof. Dr. Pedro Pedrosa

pedrosarf@ifce.edu.br

professorpedrosoa.com

INTRODUÇÃO

- Sistema de Visão Computacional



Introdução à Segmentação

- Identificar e destacar na imagem as regiões de interesse (ROI)
- Tipos:
 - *Similaridade*
 - *Limiarização*
 - *Crescimento de Região*
 - *Clusterização*
 - *Descontinuidade*
 - *Detecção de pontos*
 - *Detecção de linhas*
 - *Detecção de bordas*
 - *Watershed*
 - *Métodos de Contornos Ativos*



Limiarização

Segmentação por similaridade

Limiarização

- Depende da escolha de um limiar

– Fixo

$$B(x, y) = \begin{cases} 1, & \text{se } I(x, y) > L \\ 0, & \text{caso contrário.} \end{cases}$$

- Automático

- BERNSEN, 1986
- COCQUEREZ; PHILLIP, 1995
- JOHANNSEN; BILLE, 1982
- Otsu, 1979

- *Multilimiarização*

$$R(x, y) = \begin{cases} 0, & \text{para } 0 < I(x, y) < 86 \\ 1, & \text{para } 85 < I(x, y) < 171 \\ 2, & \text{para } 170 < I(x, y) < 256 \end{cases}$$

Limiarização

- Exemplo



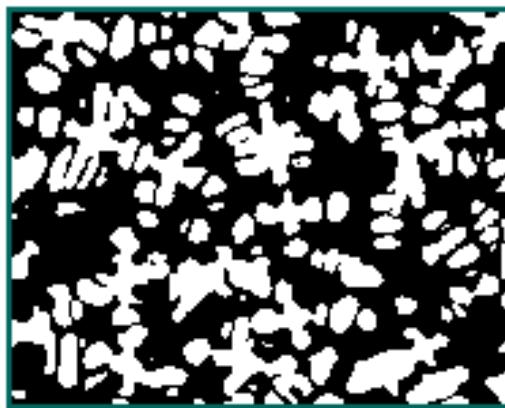
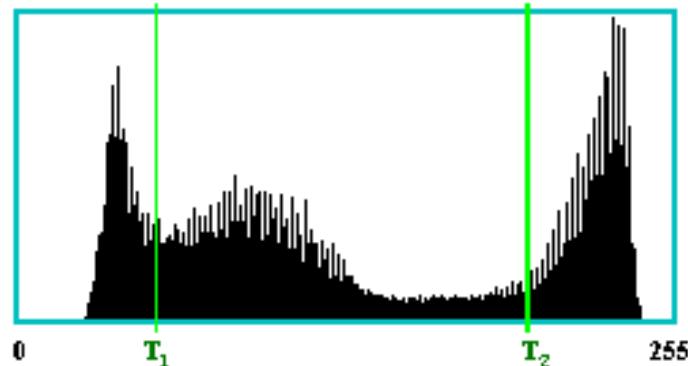
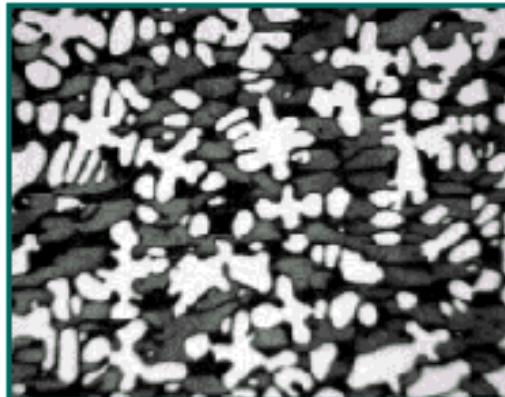
(a)



(b)

Figura 2.1: exemplo de aplicação da limiarização: a) imagem original e b) resultado (ALBUQUERQUE, 2006).

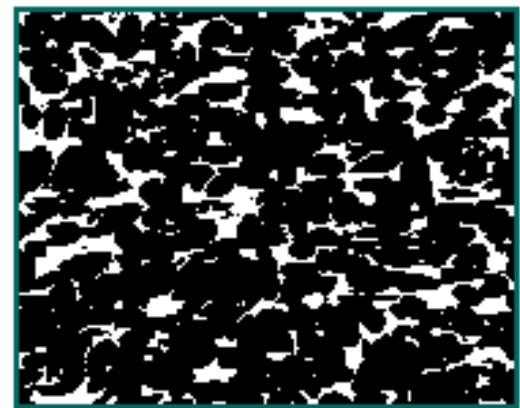
Exemplos de *Thresholding*



Fase clara ($t > T_2$)



Fase média ($T_1 < t < T_2$)
problema !

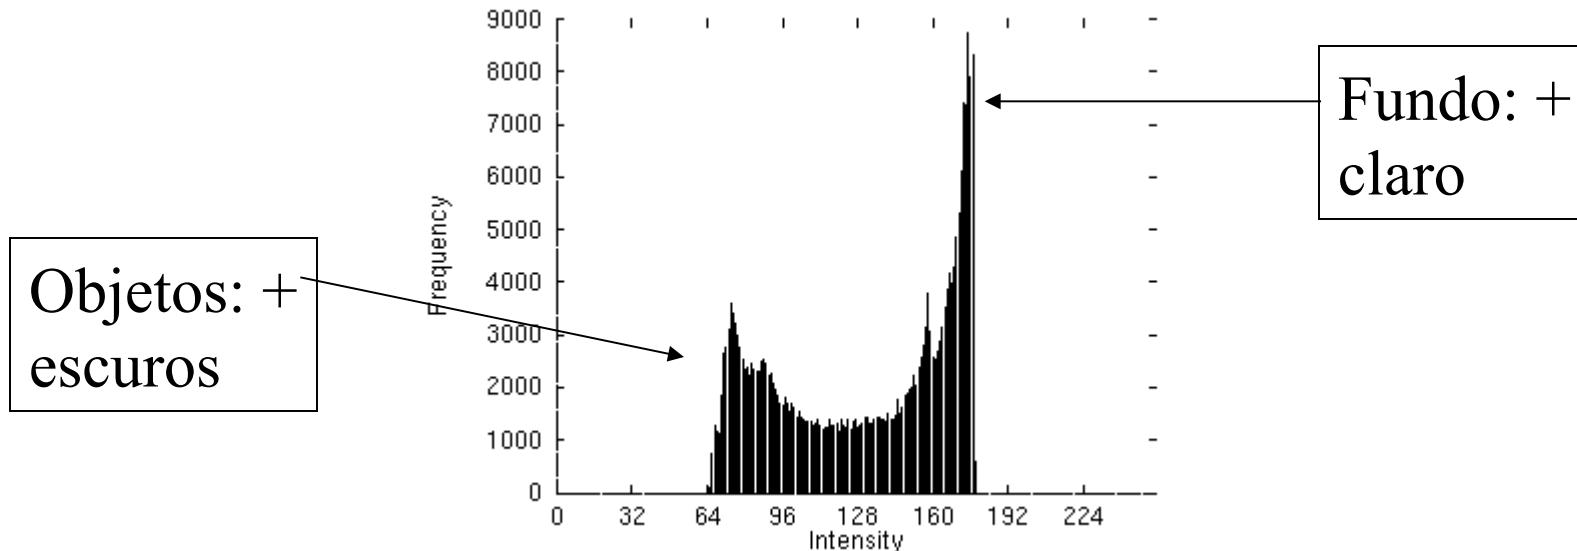


Fase escura ($t < T_1$)



Detecção do Limiar (T)

- Tem-se informação “a priori”?  Simples
 - exemplo: detecção de caracteres em um folha papel
- Análise do formato do histograma
 - bi-modal: Objetos de mesmo NC + fundo



Limiarização global simples

- Pode ser utilizado quando as distribuições de intensidade entre o fundo e os objetos são suficientemente diferentes.
- Um único limiar para toda a imagem (global)
- Em muitas aplicações, no entanto, a variação das imagens é grande e o limiar muda, mesmo quando a abordagem global for adequada.



Algoritmo Limiarização global simples

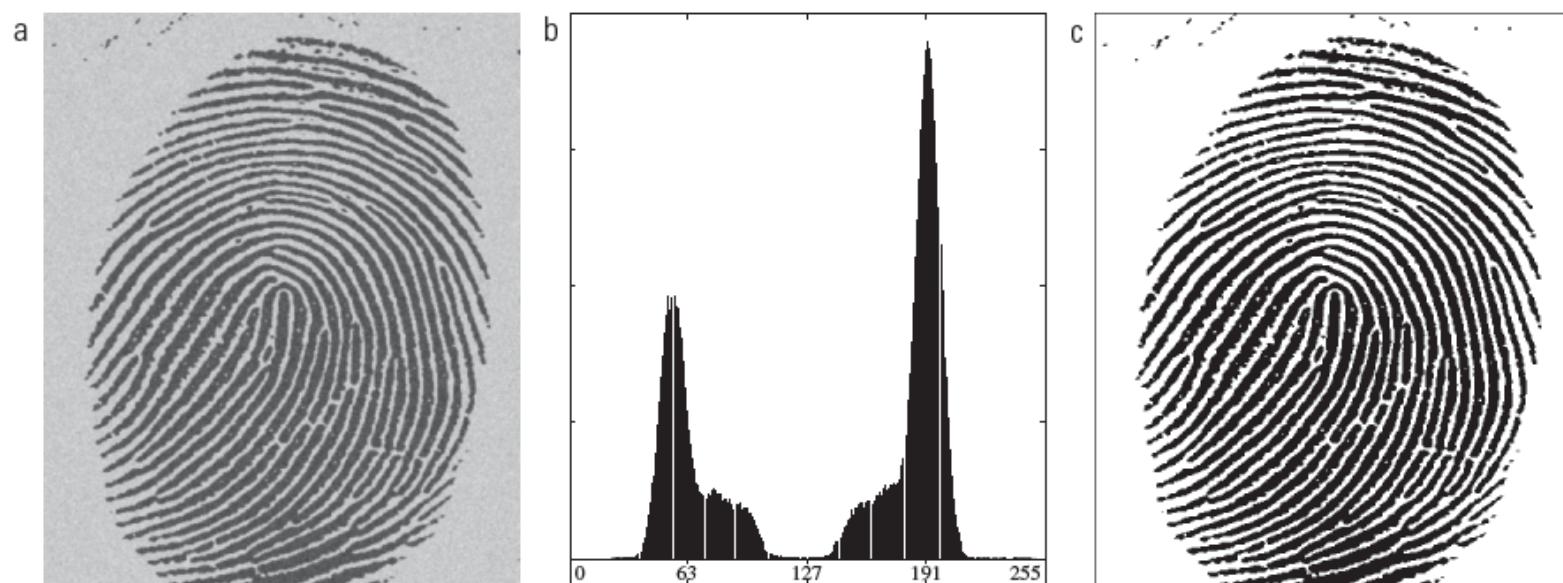


Figura 10.38 (a) Impressão digital ruidosa. (b) Histograma. (c) Segmentação resultante usando um limiar global (a moldura da imagem foi adicionada para maior clareza). (Original cortesia do National Institute of Standards and Technology.)



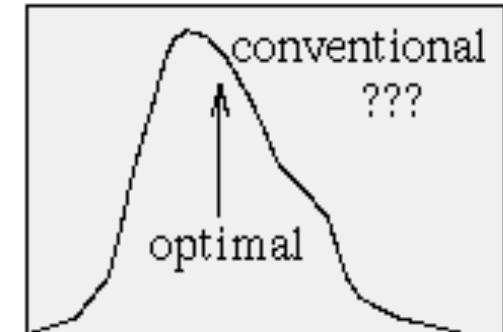
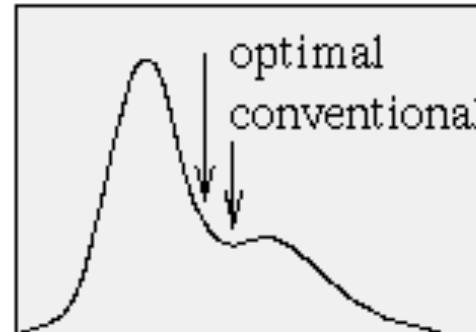
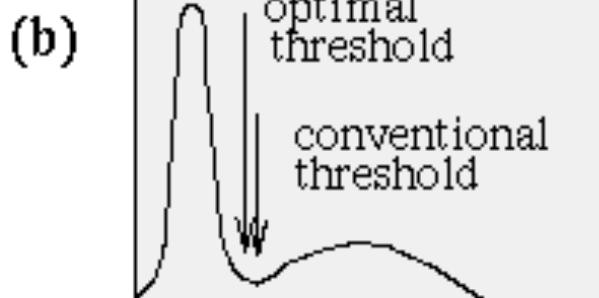
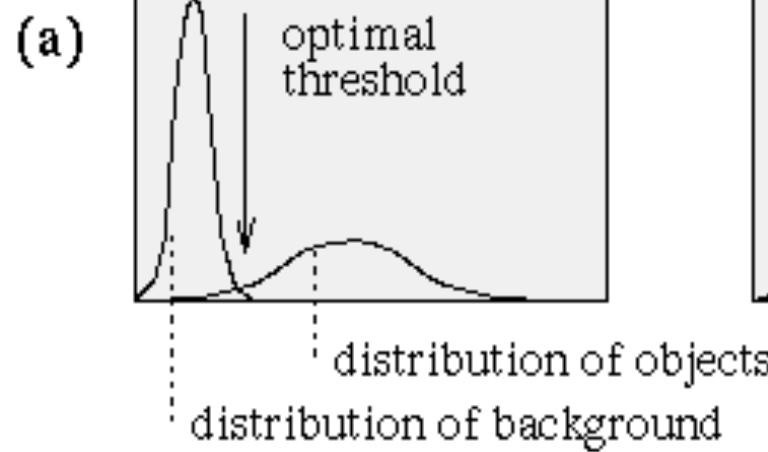
Algoritmo Limiarização global simples

1. Estimar um limiar global inicial
2. Segmentar a imagem usando a regra tradicional de limiarização. Dois grupos se formarão: G1 com pixeis $> T$ e G2 com pixeis $\leq T$
3. Calcular a intensidade média de cada grupo m_1 e m_2
4. Calcular novo $T = (m_1 + m_2) / 2$
5. Repita 2 a 4, até que a diferença entre interações sucessivas de T seja menor que um ΔT



Limiar Ótimo

- Limiar escolhido como o nível de cinza mais próximo correspondente a probabilidade mínima entre dois pontos de máximo de duas ou mais distribuições normais.



Limiarização de Otsu

Segmentação de Imagens

Método de Otsu (1979)

- Determina o tom de corte que maximiza a medida de variância entre o objeto e o fundo
- Idéia bastante simples: encontrar o limiar que minimiza a variância ponderada *intra* classe (*within-class variance*)
 - Isso equivale a maximizar a variância *entre* classes (*between-class variance*)
- Tudo se baseia em cálculos no vetor 1D do histograma da imagem.



Método de Otsu (+custoso)

- A variância ponderada intra classes é a soma ponderada das variâncias de cada classe

$$\sigma_w^2(t) = q_1(t)\sigma_1^2(t) + q_2(t)\sigma_2^2(t)$$

- As probabilidades das classes são dadas por

$$q_1(t) = \sum_{i=1}^t P(i)$$

$$q_2(t) = \sum_{i=t+1}^I P(i)$$



Método de Otsu (+custoso)

e as médias das classes são dadas por

$$\mu_1(t) = \frac{1}{q_1(t)} \sum_{i=1}^t iP(i) \quad \mu_2(t) = \frac{1}{q_2(t)} \sum_{i=t+1}^I iP(i)$$

As variâncias individuais das classes

$$\sigma_1^2(t) = \sum_{i=1}^t [i - \mu_1(t)]^2 \frac{P(i)}{q_1(t)} \quad \sigma_2^2(t) = \sum_{i=t+1}^I [i - \mu_2(t)]^2 \frac{P(i)}{q_2(t)}$$

Pronto. Precisamos apenas percorrer toda a faixa de valores de T [1,256] e escolher o valor que minimiza $\sigma_w^2(t)$

– Isso é um pouco custoso...



Otsu (variâncias)

- Ao subtrairmos a variância intra classes da variância total do histograma (ambas as classes), obtemos a variância entre classes (between-class variance)

$$\begin{aligned}\sigma^2_{\text{Between}}(T) &= \sigma^2 - \sigma^2_{\text{Within}}(T) \\ &= q_1(T) [\mu_1(T) - \mu]^2 + q_2(T) [\mu_2(T) - \mu]^2\end{aligned}$$

- Note que a variância entre classes é apenas a variância ponderada da média dos clusters sobre a media global.



Imagen original
com iluminação
irregular

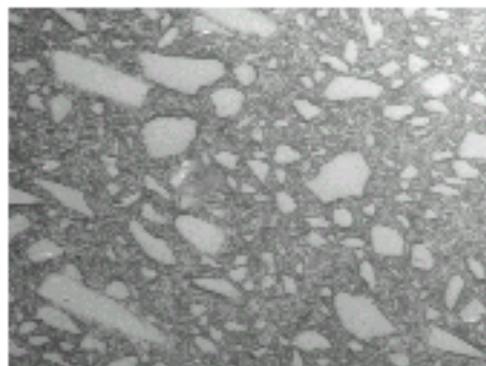


Imagen
segmentada com
limiar no mínimo

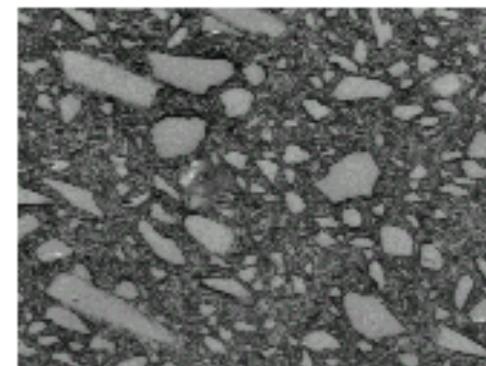
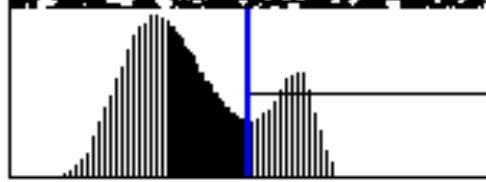
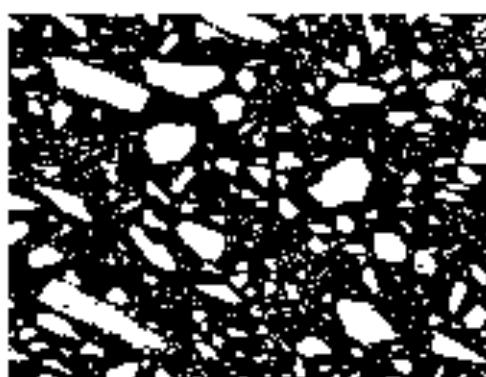


Imagen corrigida
com filtro passa-
altas, 49x49, 4
iterações

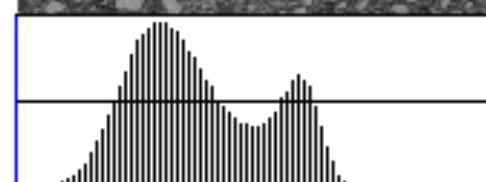
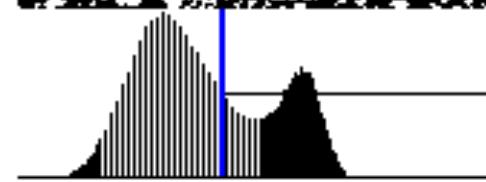
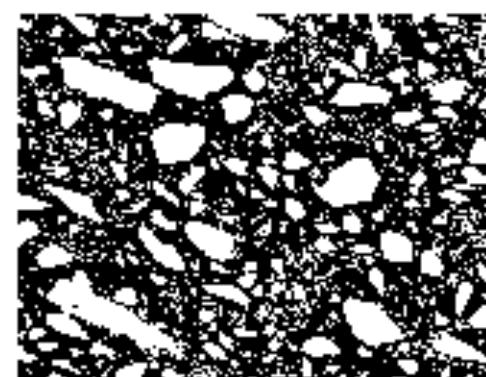


Imagen
sementada pelo
método de Otsu



Otsu - Exemplos

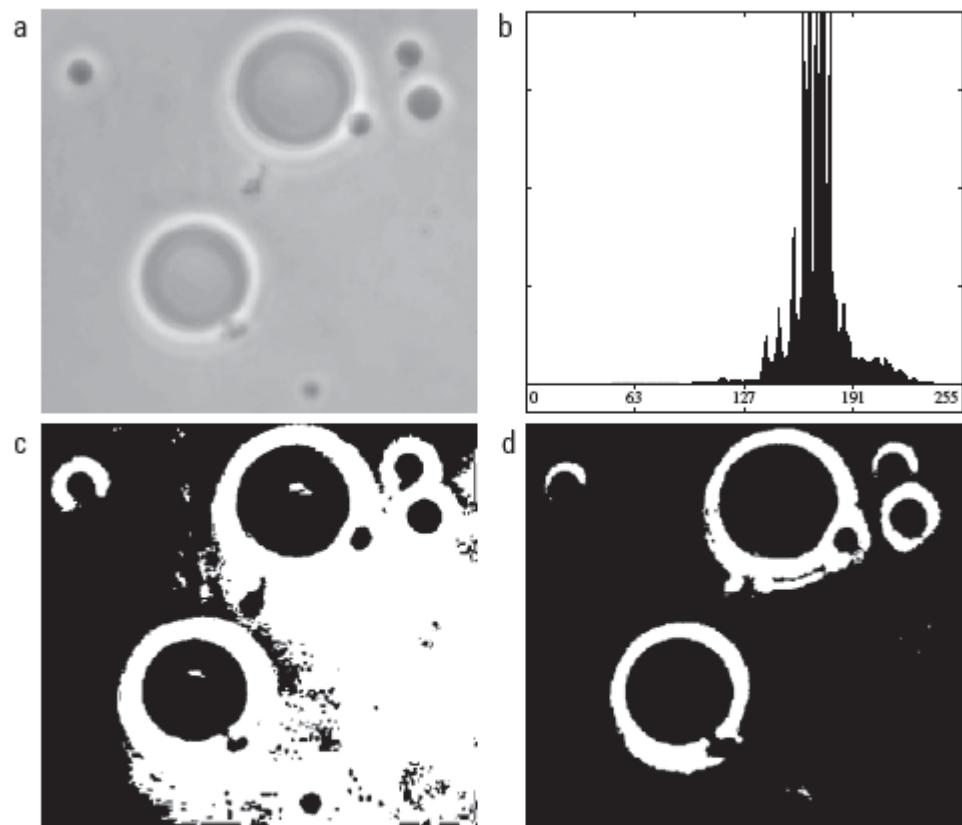


Figura 10.39 (a) Imagem original. (b) Histograma (os picos elevados foram cortados para realçar os detalhes nos valores mais baixos). (c) Resultado da segmentação utilizando o algoritmo global básico da Seção 10.3.2. (d) Resultado obtido pelo método de Otsu. (Imagen original: cortesia do Professor Daniel A. Hammer, da Universidade da of Pennsylvania.)



Otsu - Exemplos

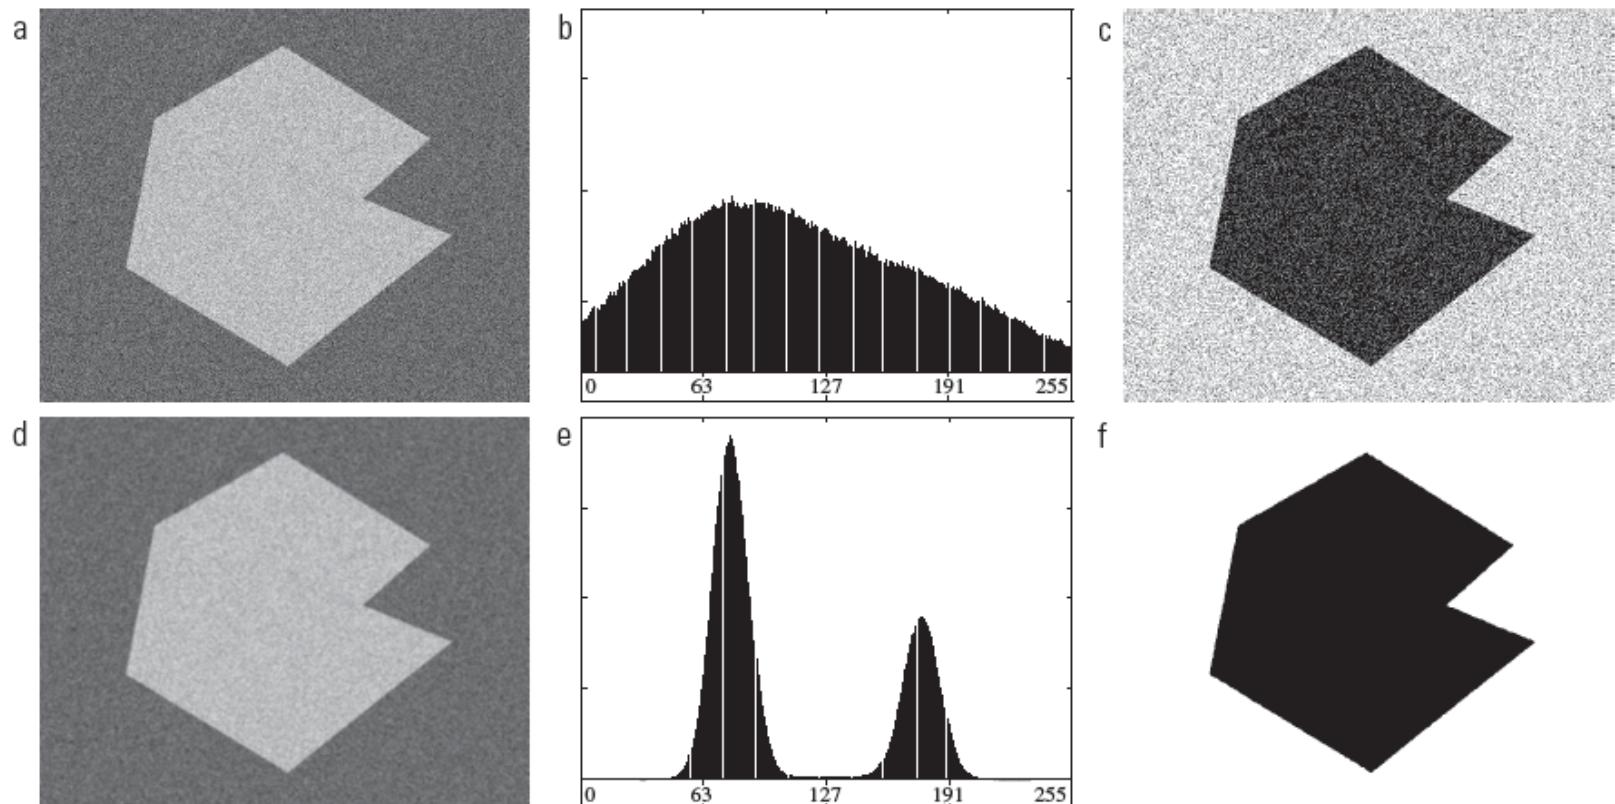


Figura 10.40 (a) Imagem ruidosa da Figura 10.36 e (b) seu histograma. (c) Resultado obtido pelo método de Otsu. (d) Imagem ruidosa suavizada usando uma máscara de média de tamanho 5×5 e (e) seu histograma. (f) Resultado da limiarização pelo método de Otsu.



Limiarização por médias móveis

- Calcular a média de uma janela (máscara)

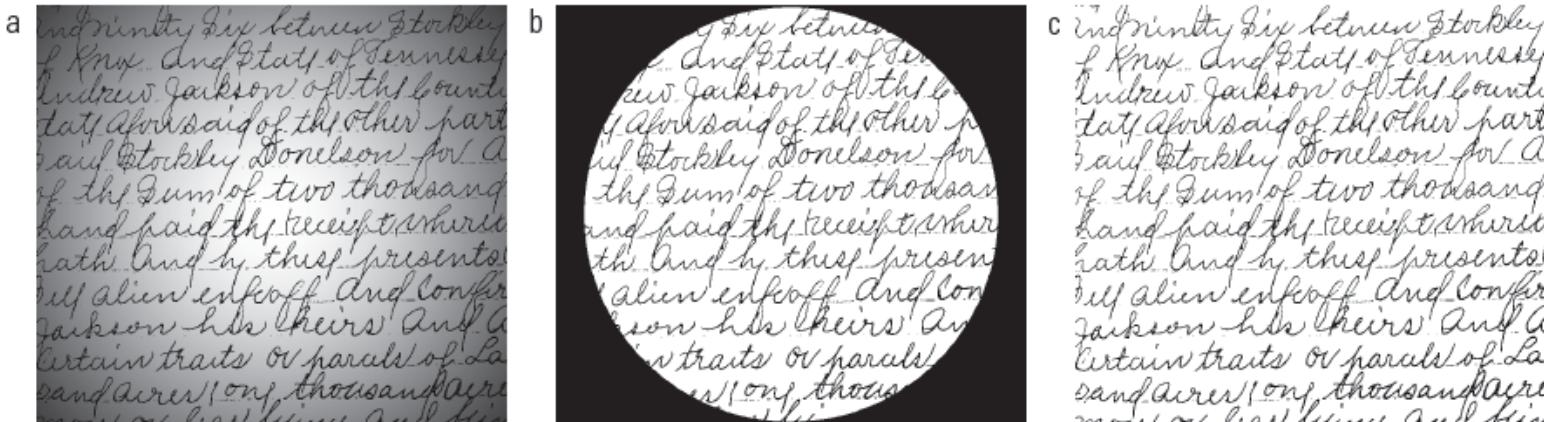


Figura 10.49 (a) Imagem de texto corrompido por sombreamento pontual. (b) Resultado da limiarização global pelo método de Otsu. (c) Resultado da limiarização local usando médias móveis.

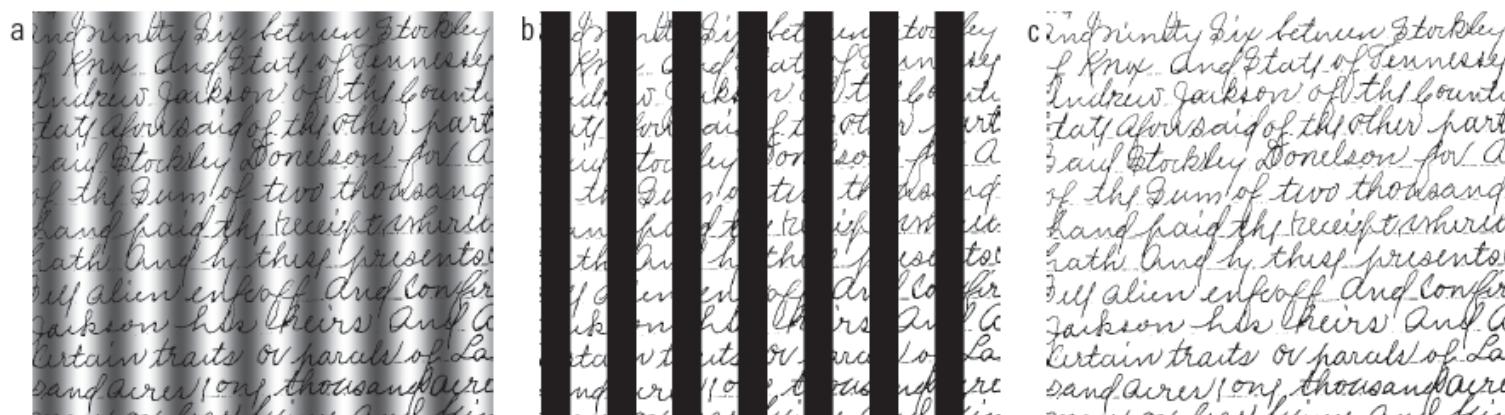


Figura 10.50 (a) Imagem de texto corrompida pelo sombreamento senoidal. (b) Resultado da limiarização global pelo método de Otsu. (c) Resultado da limiarização local usando médias móveis.



Gradiente - Canny

Segmentação de Imagens

Gradiente - Canny

1. Presente na OpenCv e no Matlab
2. Link dos detalhes: [Download](#)



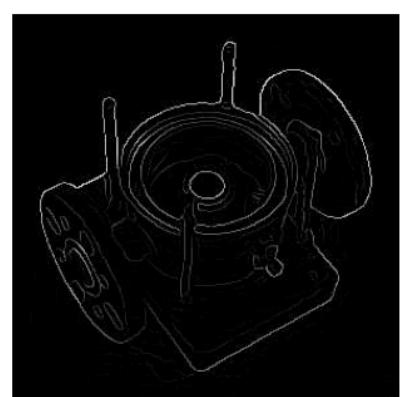
(a) Original



(b) Smoothed



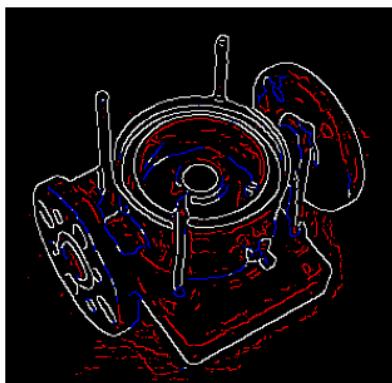
(c) Gradient magnitudes



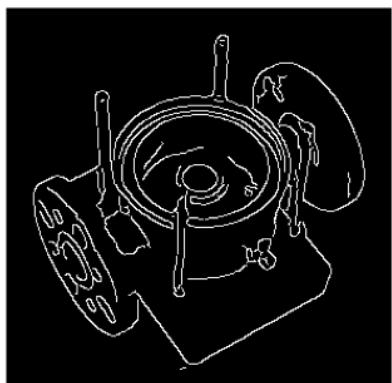
(d) Edges after non-maximum suppression



(e) Double thresholding



(f) Edge tracking by hysteresis



(g) Final output

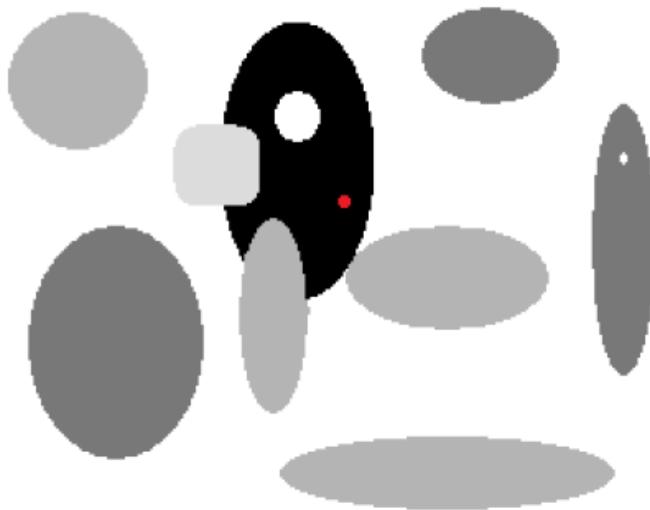


Crescimento de Regiões

Segmentação de Imagens

Crescimento de Região

- Semente
- Regra de agregação



(a)

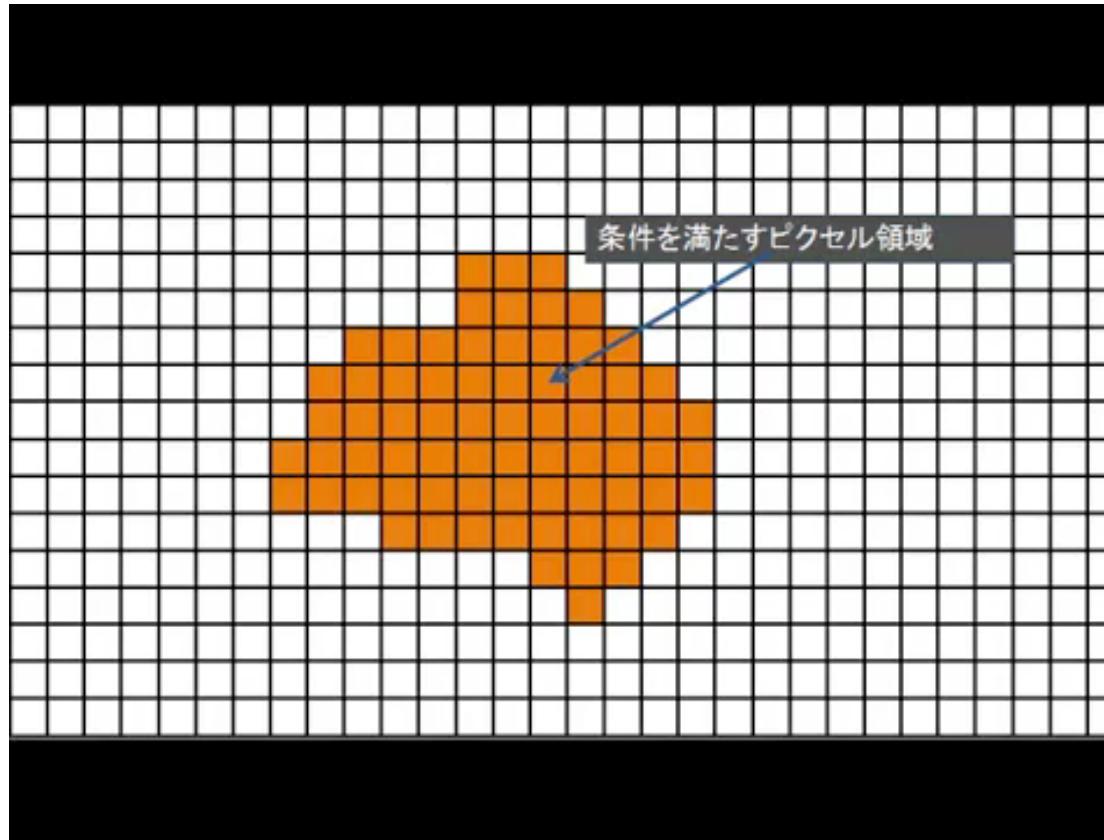


(b)

Figura 2.2: exemplo de aplicação da técnica de Crescimento de Região: a) imagem original com a semente em vermelho, b) resultado da segmentação em vermelho.

Crescimento de Região

- Semente
- Regra de agregação

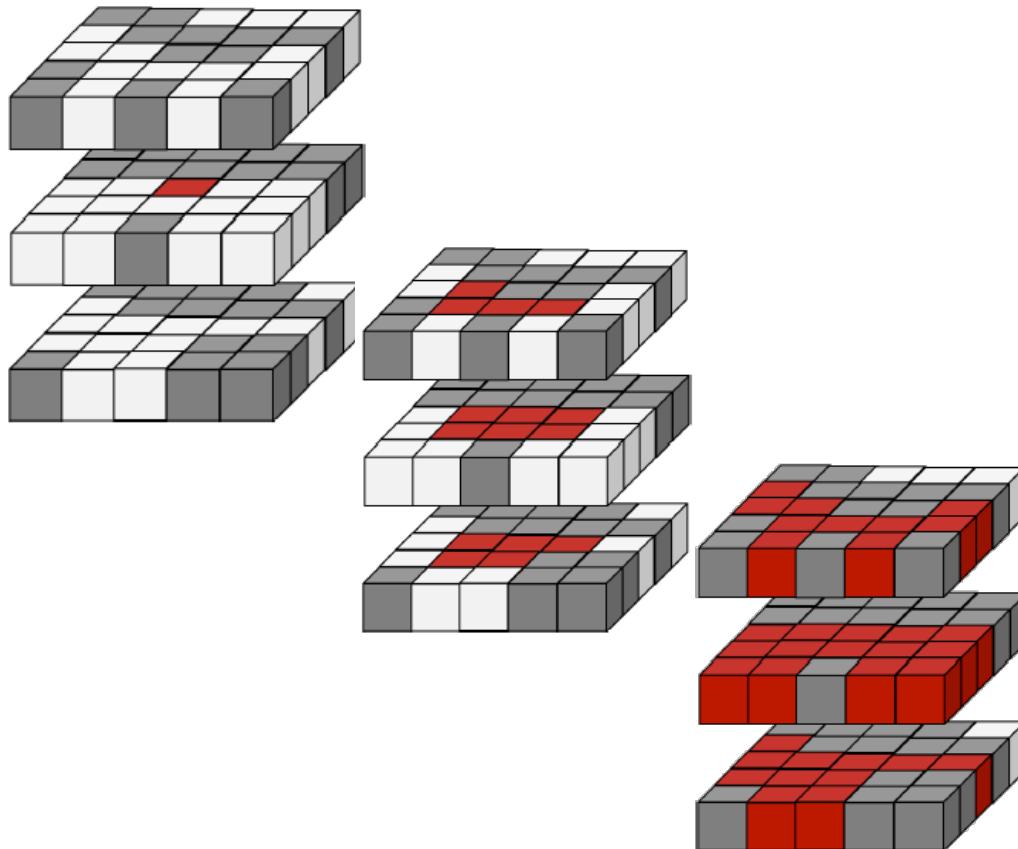


<http://youtu.be/IjK774GwRGk>



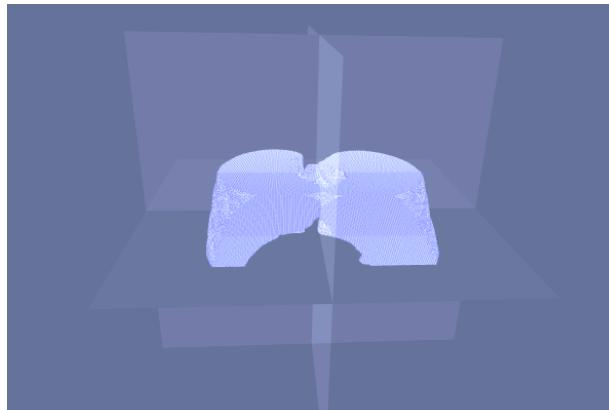
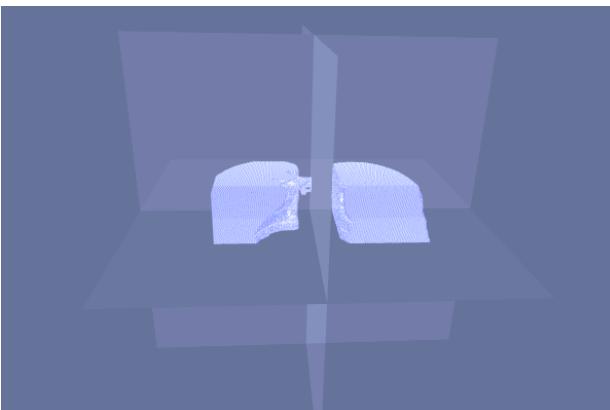
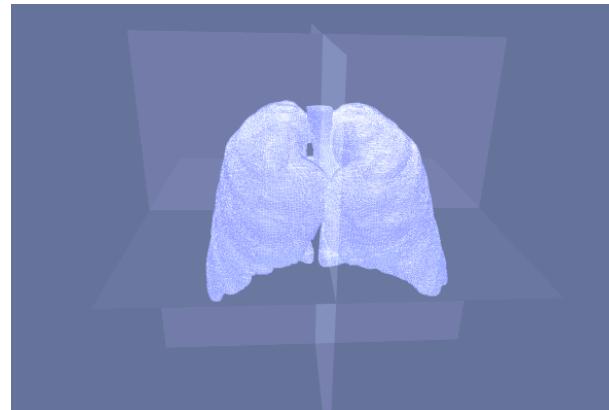
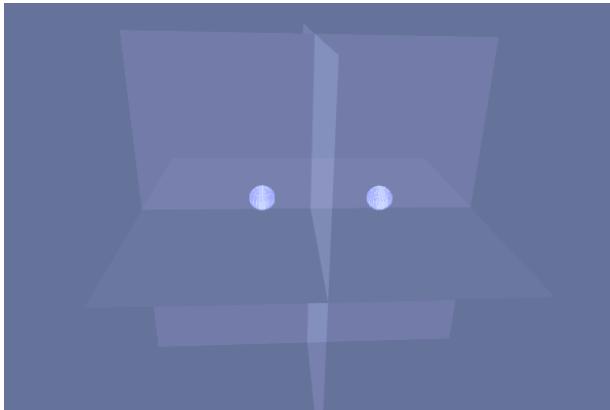
Crescimento de Região 3D

- Expansão do 2D



Crescimento de Região 3D

- Exemplo – [Link do artigo](#)



Clusterização pelo método k-médias

Segmentação de Imagens

K-means Clustering Segmentation

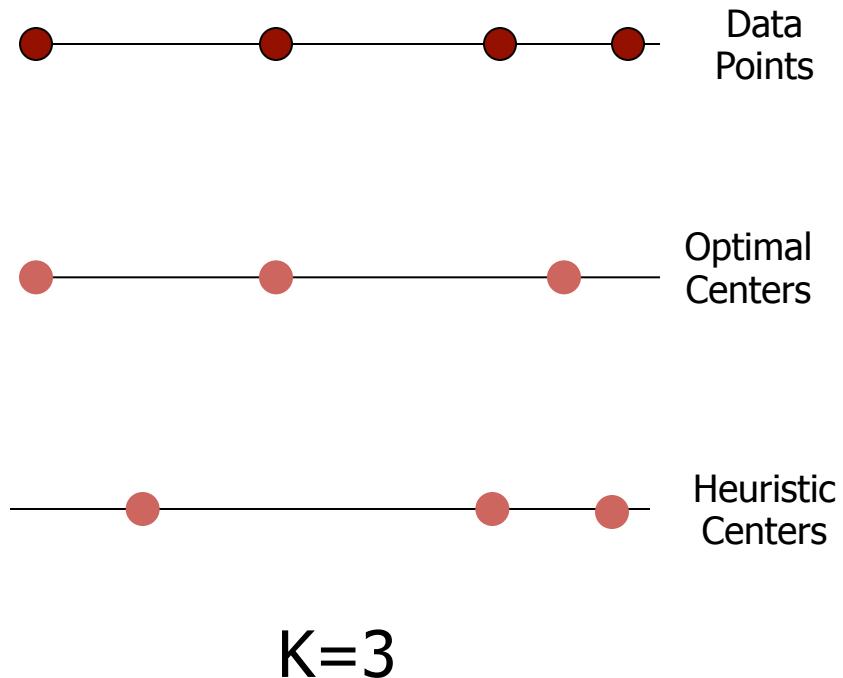
- Dado um Conjunto de n pontos no espaço d-dimensional em um inteiro k
- Queremos encontrar um conjunto de k pontos no espaço d-dimensional que minimiza a distância media quadrática de cada ponto para seu centro mais próximo.
- Não existe algoritmo polinomial para esse problema

“A Local Search Approximation Algorithm for k-Means Clustering” by Kanungo et. al



K-means Algorithm

- O KM converge para uma solução local ótima.
- Mas pode convergir para uma solução arbitrária ruim
- Por que ?



K-means Clustering Segmentation

- **Definição formal**

Seja $X = \{x_1, x_2, x_3, \dots, x_n\}$ um conjunto de dados e $C = \{c_1, c_2, c_3, \dots, c_k\}$ para $k \ll n$, um conjunto de *clusters*, onde cada elemento x_i pode pertencer a somente um elemento c_i . O K-Means é um método iterativo que agrupa os n elementos de X pelos k *clusters* de C .

$$J(C) = \sum_{k=1}^K \sum_{x_i \in c_k} \|x_i - \mu_k\|^2$$



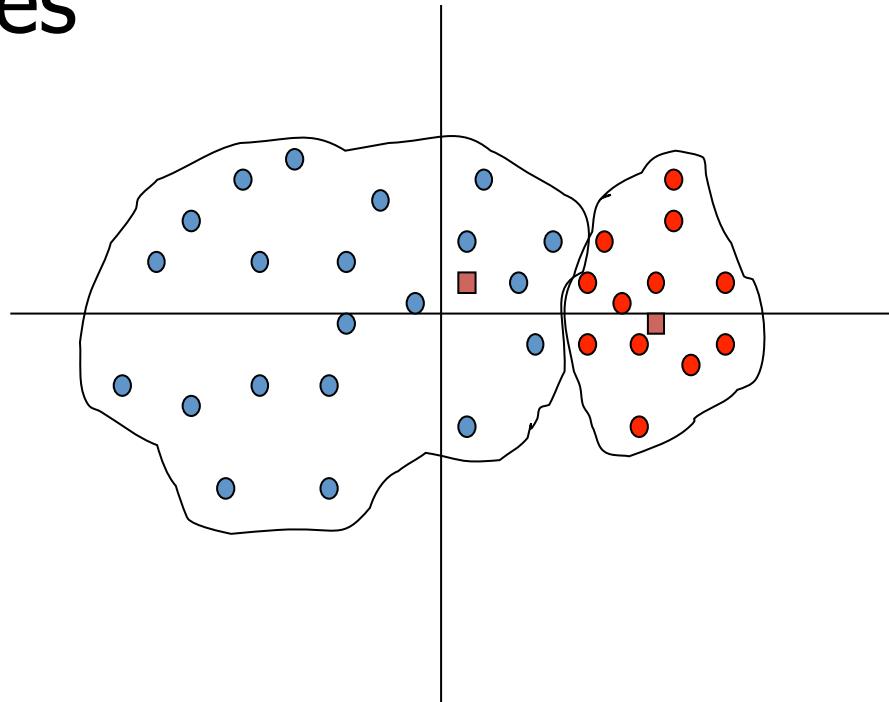
K-means Algorithm

- 1 – Escolha k pontos iniciais aleatoriamente
- 2 – Clusterize os dados usando uma distância qualquer (a mais usada é a distância euclidiana)
- 3 – Compute novos centros para cada cluster usando apenas pontos dentro de cada cluster
- 4 – Re-compute todos os dados usando os novos centros
(esse passo pode provocar mudança de cluster de um ponto)
- 5 – Repita os passos 3 e 4 até que nenhum ponto no passo quatro tenha mudado de cluster ou outro critério de convergência.



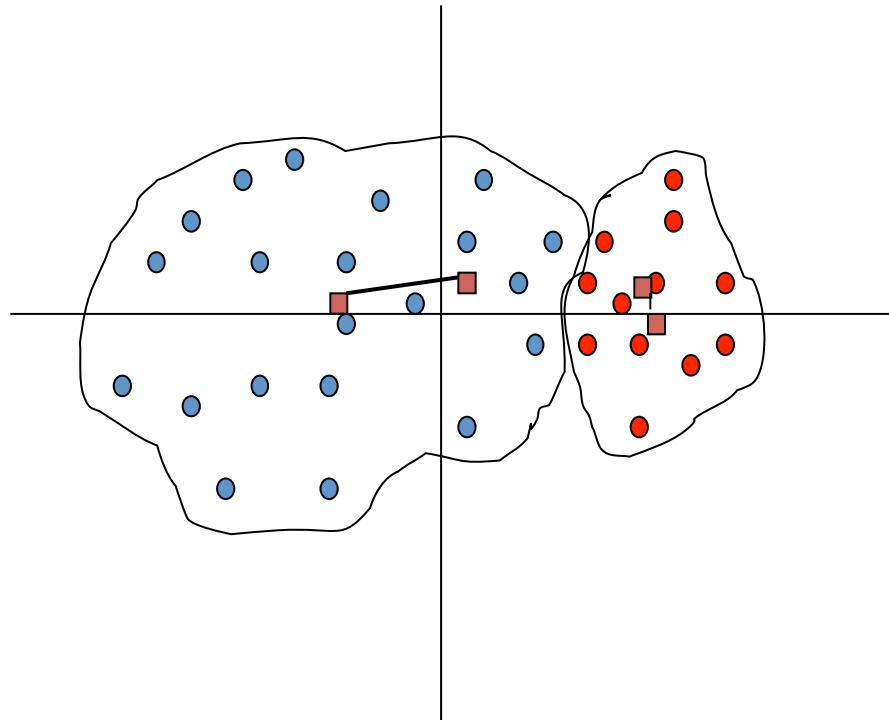
Exemplo para k=2

1. Escolha $k=2$
2. Clusterize os pontos em torno de $K=2$ centroides



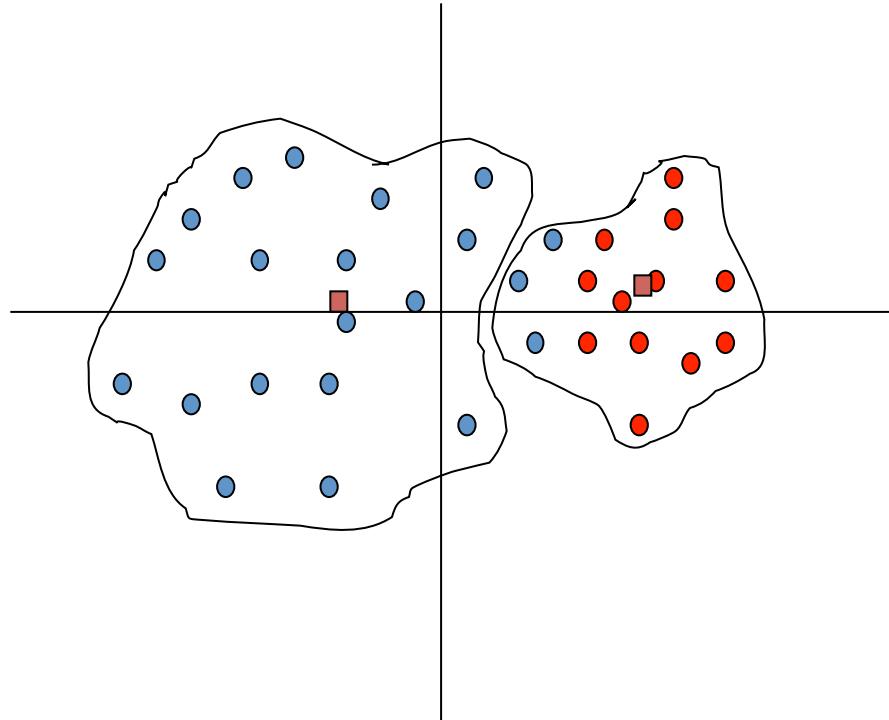
K-means para k=2

3. Recalcule os centroides
4. Redistribution points into the two clusters, considering the new centroids



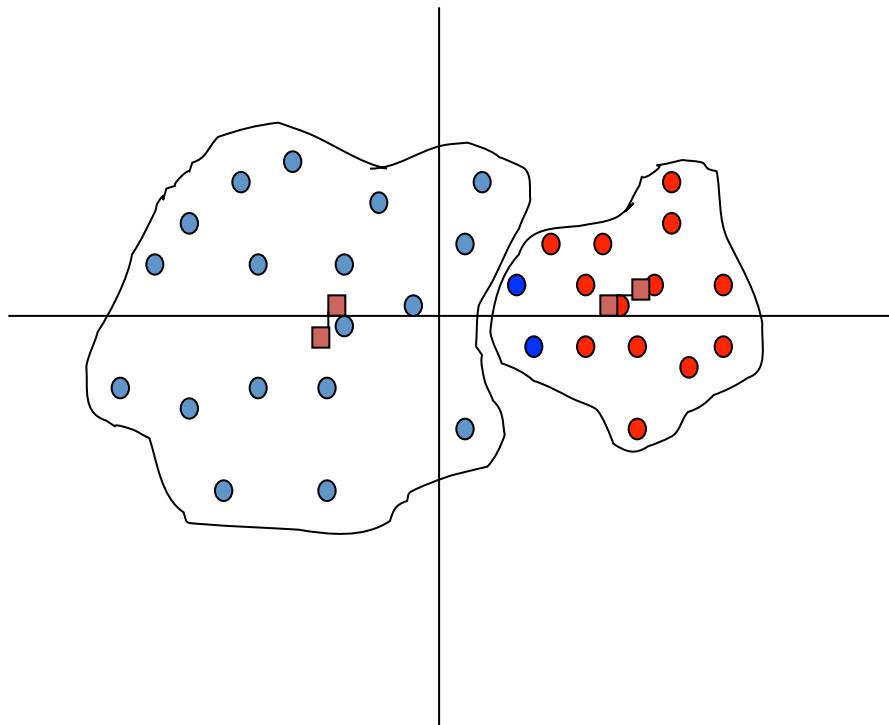
K-means para k=2

3. Recalcule os centroides
4. Redistribution points into two clusters, considering the new centroids



K-means para k=2

5. Repita os dois ultimos passos até que nenhum ponto mude de cluster



Características do k-means

- Selecionar aleatoriamente os pontos na fase inicial gera as seguinte propriedades
 - Não-Determinismo
 - Pode produzir clusters vazios
 - Uma solução é escolher os centros aleatoriamente a partir de padrões conhecidos

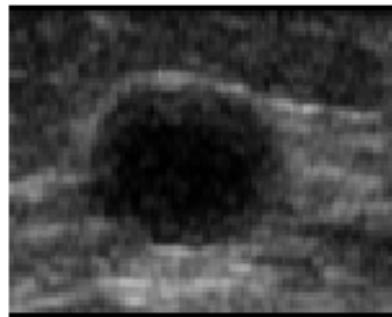
From “Data Analysis Tools for DNA Microarrays” by Sorin Draghici



Exemplos



(a) sunset



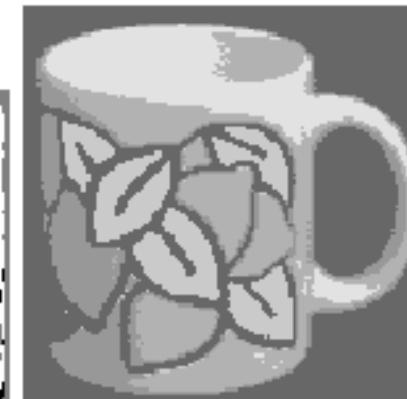
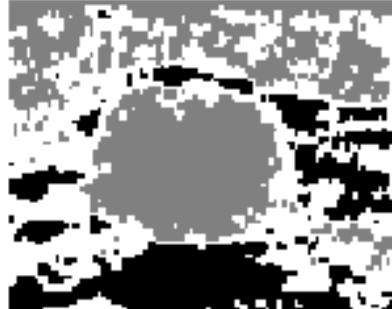
(b) breast tumor



(c) simple object



(d) lenna



Segmentação por descontinuidade

Detecção de pontos, linhas e bordas

Segmentação por descontinuidade

Segmentação por descontinuidade

- Detecção de pontos, linhas e bordas.
- O resultado R da detecção de cada um destes pode ser obtido por

$$R = M_{3 \times 3} * I_{l \times c},$$

em que

$$M = \begin{bmatrix} w_1 & w_2 & w_3 \\ w_4 & w_5 & w_6 \\ w_7 & w_8 & w_9 \end{bmatrix}$$



Segmentação por descontinuidade

- Pontos

$$M = \begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$$

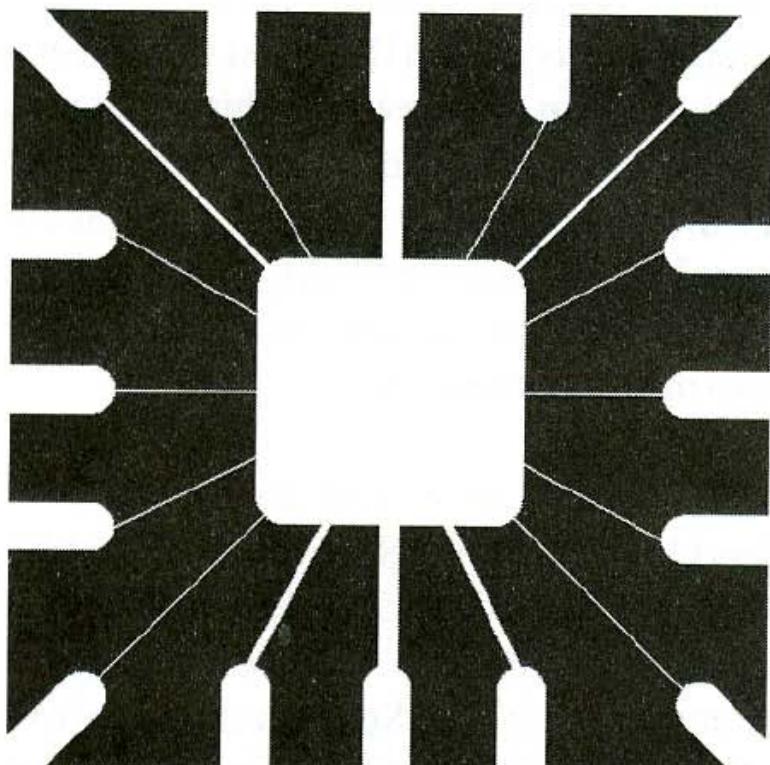
- Linhas

$$H = \begin{bmatrix} -1 & -1 & -1 \\ 2 & 2 & 2 \\ -1 & -1 & -1 \end{bmatrix}, V = \begin{bmatrix} -1 & 2 & -1 \\ -1 & 2 & -1 \\ -1 & 2 & -1 \end{bmatrix},$$

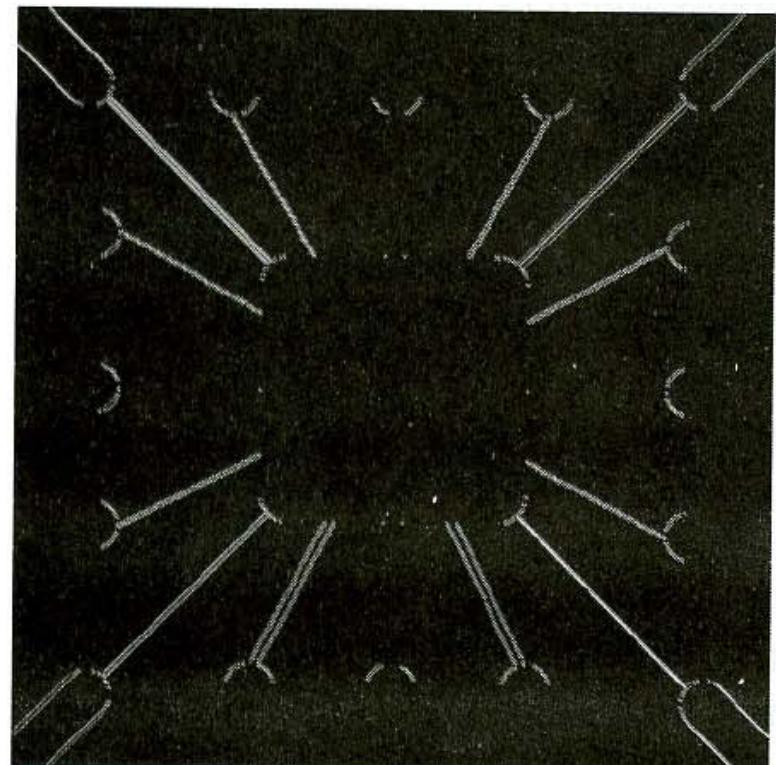
$$D_1 = \begin{bmatrix} -1 & -1 & 2 \\ -1 & 2 & -1 \\ 2 & -1 & -1 \end{bmatrix}, D_2 = \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}$$



Segmentação por descontinuidade



(a)



(b)

Figura 2.3: exemplo de detecção de linhas: a) imagem original e b) resultado da detecção de linhas na diagonal (GONZALEZ; WOODS, 2008).

Segmentação por descontinuidade

- Detecção de bordas

- Roberts

$$g(x, y) \cong \sqrt{(r_1^2 + r_2^2)}$$

$$r_1 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}; r_2 = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$$

- Prewwit

$$g(x, y) \cong \sqrt{(p_1^2 + p_2^2)}$$

$$p_1 = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix}; p_2 = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$

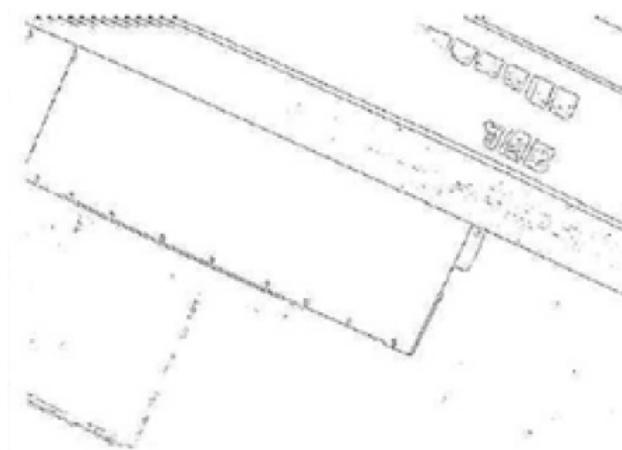
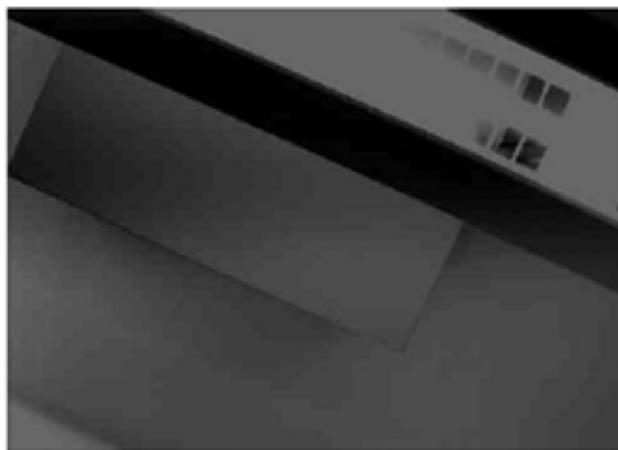
Segmentação por descontinuidade

- Detecção de bordas

- Sobel

$$g(x, y) \cong \sqrt{(s_1^2 + s_2^2)}$$

$$s_1 = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}; s_2 = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$



(a)

(b)

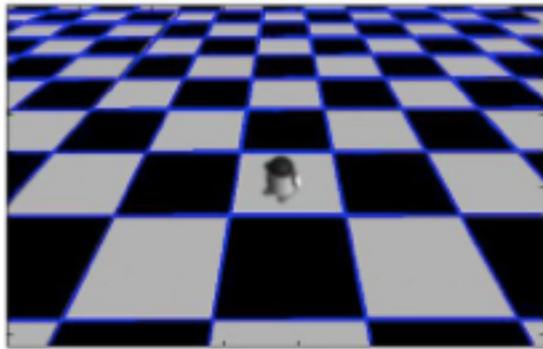
Figura 2.4: exemplo de aplicação do operador Sobel: a) imagem original e b) resultado do operador Sobel (SIEGWART; NOURBAKHSH, 2004).

Transformada de Hough

Segmentação por descontinuidade

Transformada de Hough

- encontrar formas em imagens
 - ex. retas, círculos e elipses (seções cônicas)



Transformada de Hough - **retas**

- Definição

$$y = mx + c$$

- Forma Homogênea

$$Ay + Bx + 1 = 0,$$

onde

$$A = -1/c \quad , \quad B = m/c$$

- Os pontos colineares (x_i, y_i) definem a reta (A, B) :

$$Ay_i + Bx_i + 1 = 0$$

- Repare que esta equação tem um caráter dual

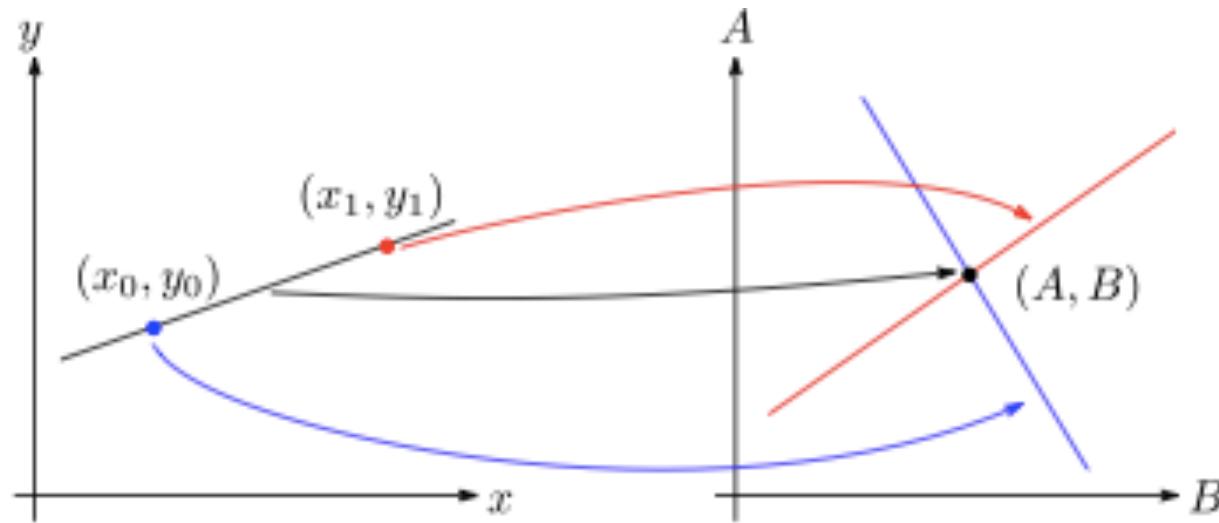
- podemos procurar os pontos (x_i, y_i) que pertencem a reta (A, B) , ou
 - podemos procurar a reta (A, B) que passa pelos pontos (x, y)



Transformada de Hough - retas

Espaço dual

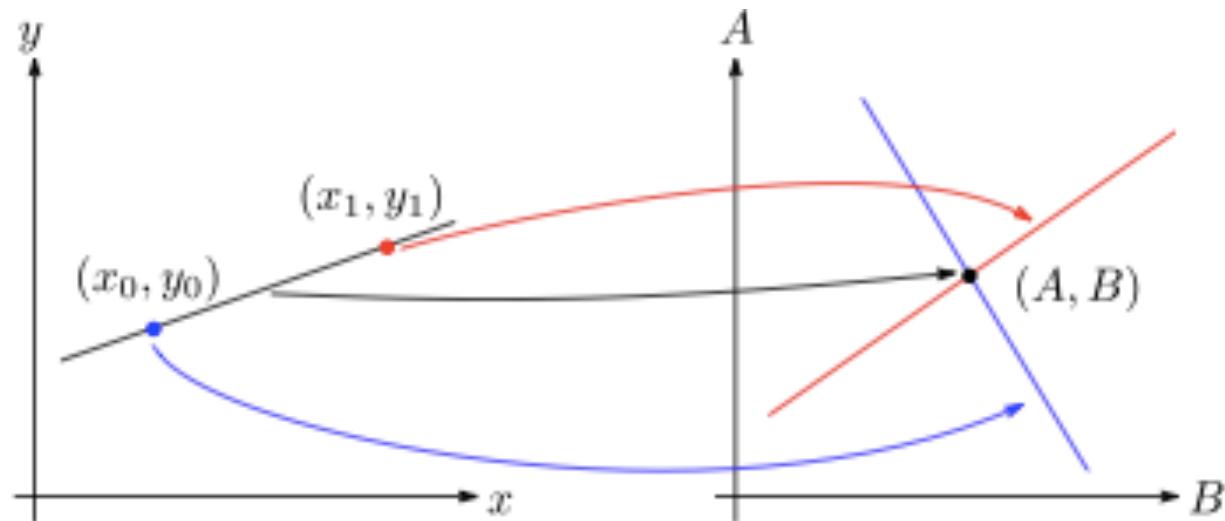
- pontos são transformados em retas, e vice-versa
- todos pontos colineares em uma imagem, definem o ponto de interseção (A, B) no espaço dual
- transformada de Hough
 - encontra a reta (A, B) rastreando o acumulo das evidências



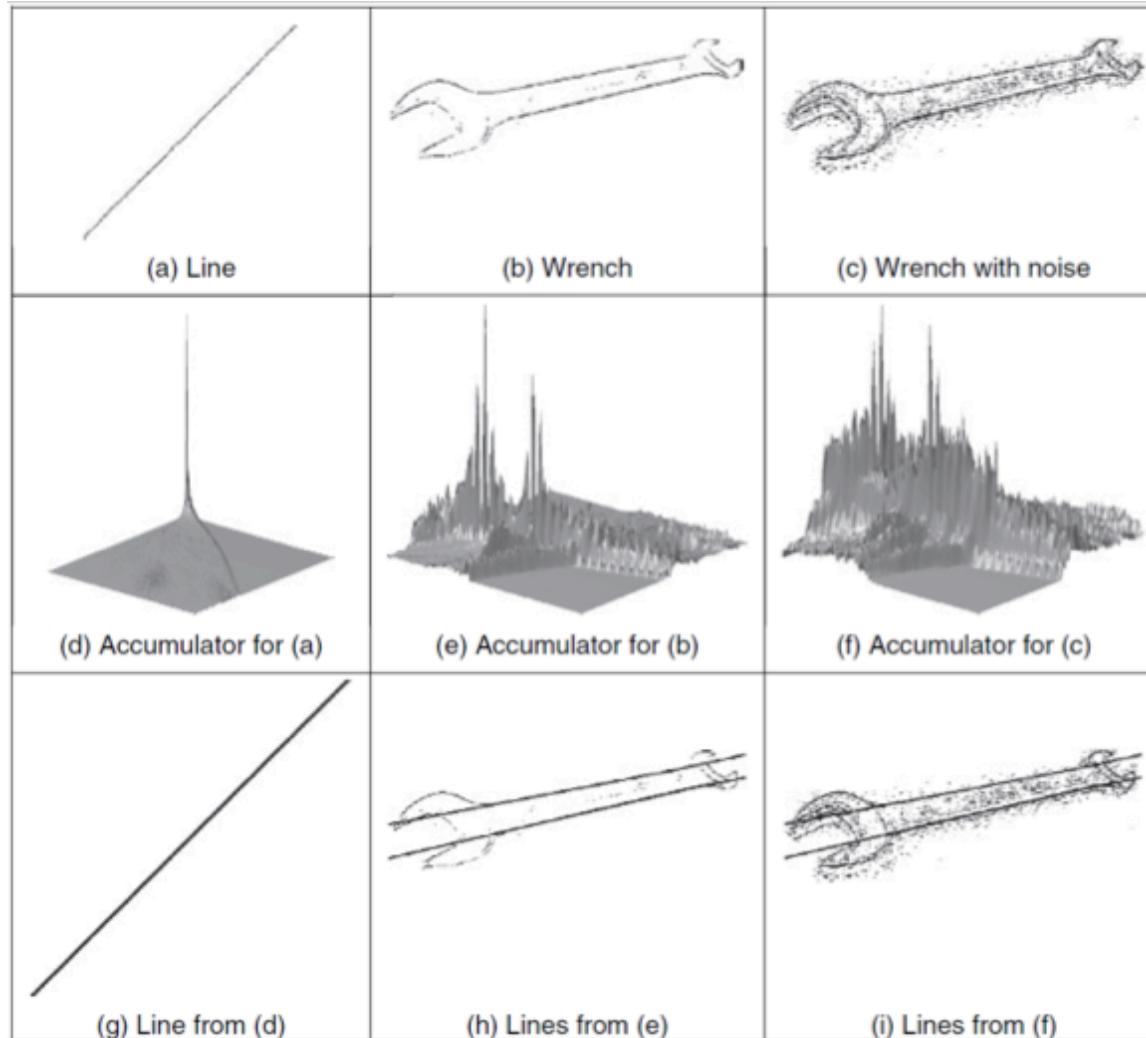
Transformada de Hough - retas

Votação

- Cada ponto (x_i, y_i) forma uma reta U_i no espaço dual
- Cada reta U_i vota em todos pontos pelos quais ela passa
- pontos que obtém muitos votos no espaço dual, são os candidatos para serem retas na imagem



Transformada de Hough - retas



Transformada de Hough - retas

Transf. Hough polar para retas

- valores limitados para os parâmetros

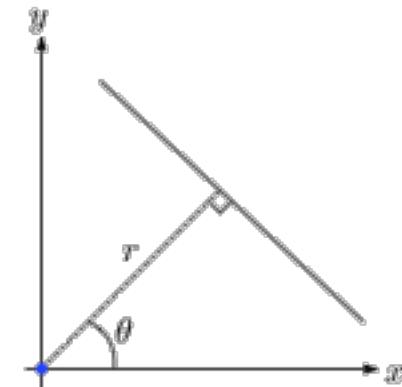
$$r = x \cos(\theta) + y \sin(\theta)$$

- $\theta \in [0, \pi]$ e $r \in [0, \sqrt{2}N]$
- podemos passar de uma parametrização à outra:

$$m = \frac{-1}{\tan \theta}$$

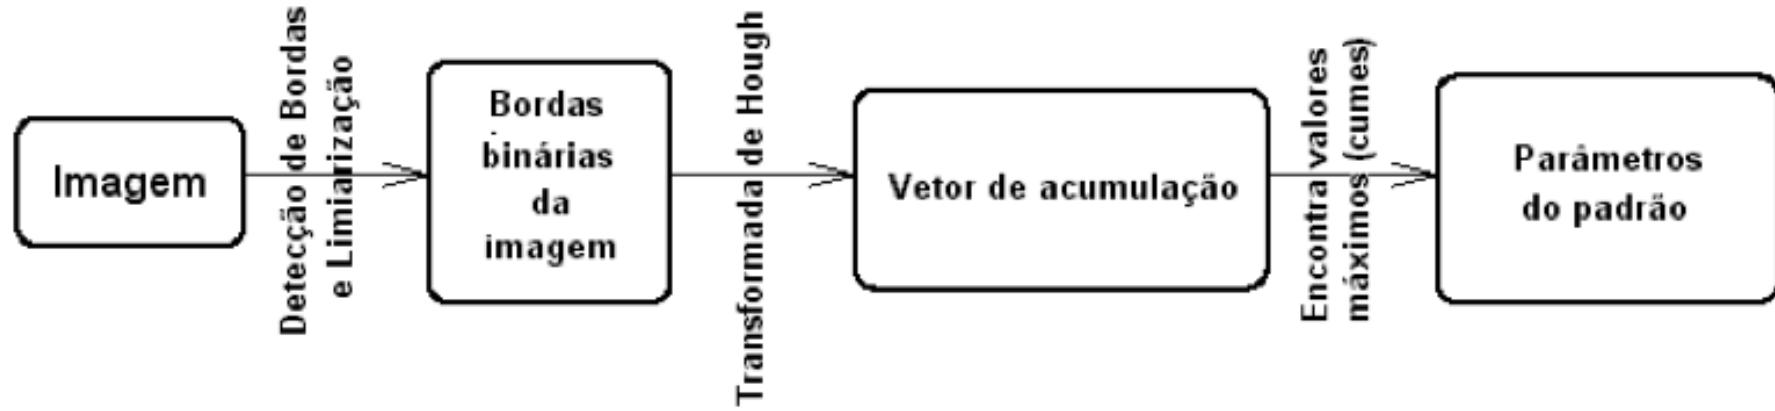
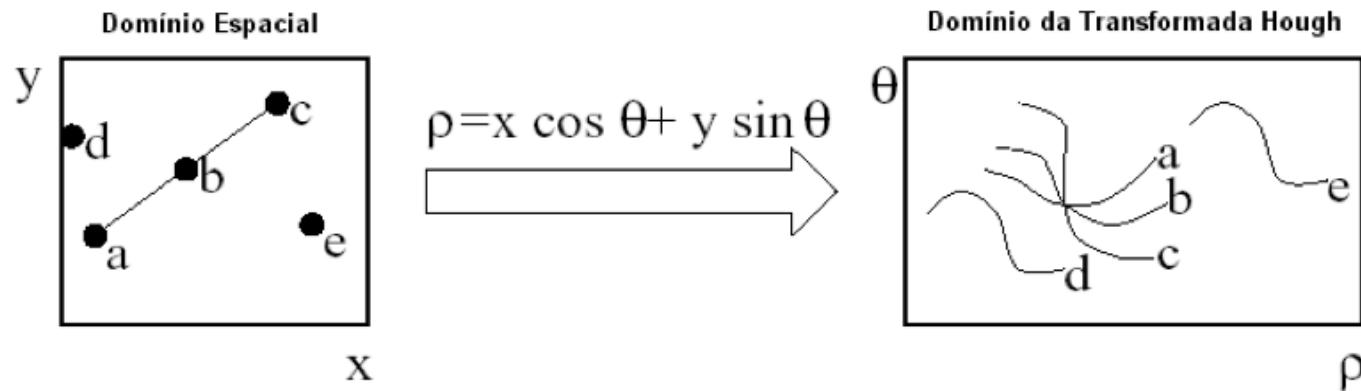
$$c = \frac{r}{\sin \theta}$$

- exemplo: quando temos $m = -1$ e $c = 1$ temos $r = \frac{\sqrt{2}}{2}$ e $\theta = \frac{\pi}{4}$
- os pontos são mapeados em senoidais
- a interseção das curvas marca as prováveis retas



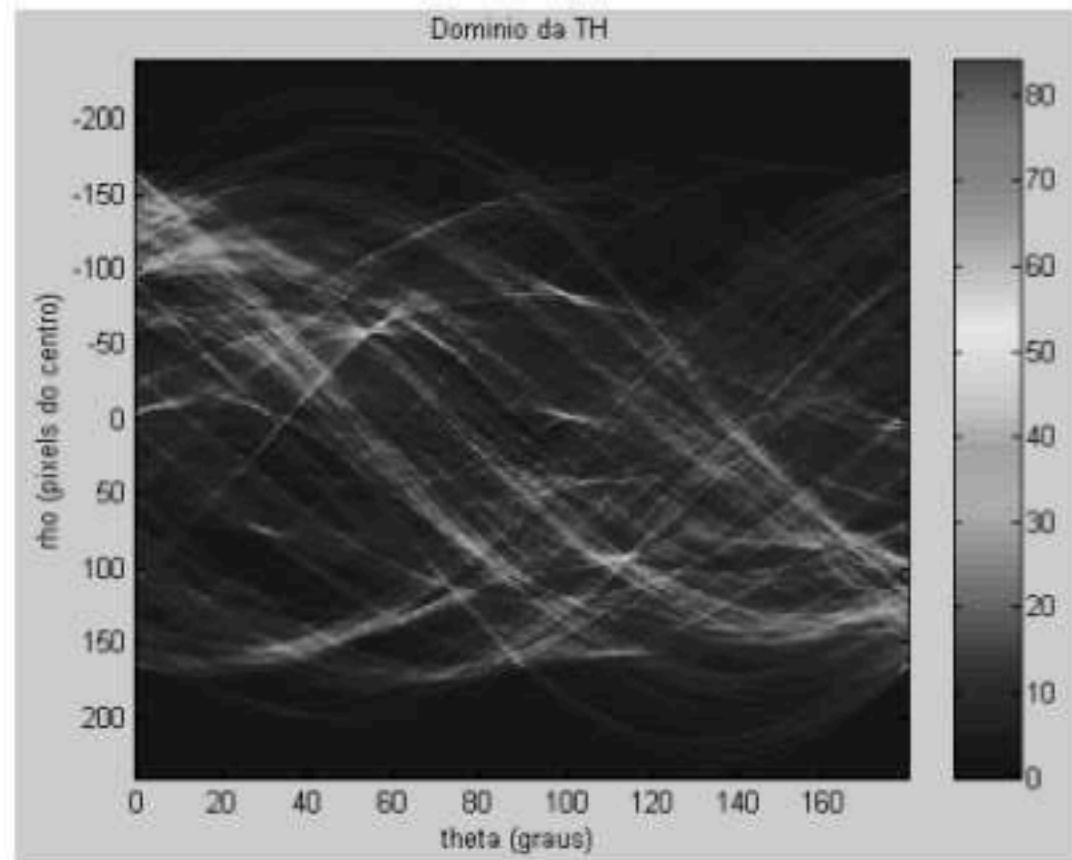
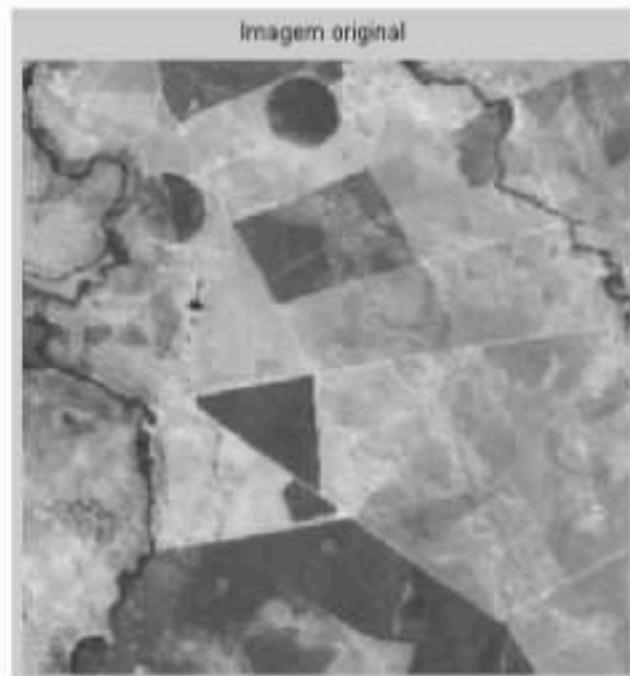
Transformada de Hough - retas

Transf. Hough polar para retas



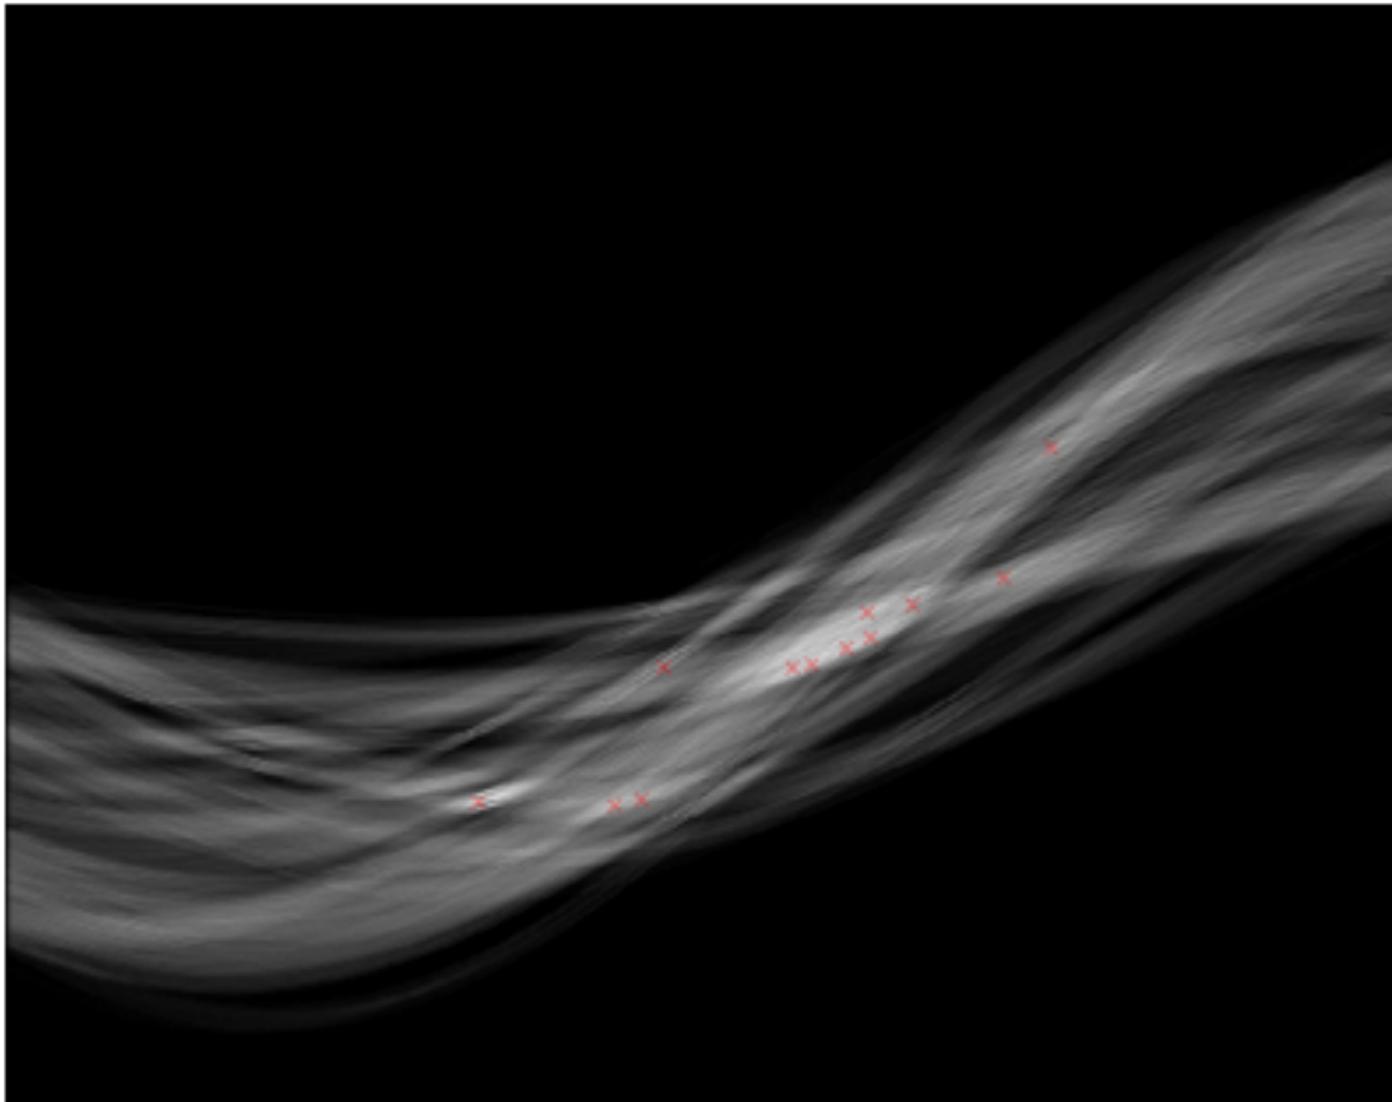
Transformada de Hough - retas

Transf. Hough polar para retas



Transformada de Hough - retas

Transf. Hough polar para retas



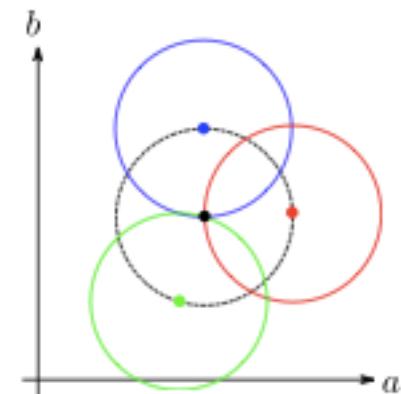
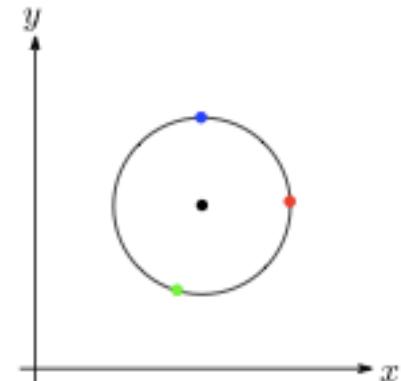
Transformada de Hough - círculos

- forma paramétrica

$$(x - a)^2 + (y - b)^2 = r^2$$

- três parâmetros (a, b, r)
- nosso espaço para votação agora está em 3D!
- cada ponto da imagem no espaço dual
 - gera um cone centrado no ponto
 - representa todos raios possíveis
- a votação em 3D encontra os círculos da imagem
- todos círculos com raio r no espaço dual intersectam no centro do círculo na imagem (a, b)

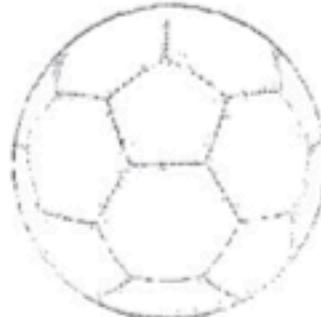
$$x = a + r \cos \theta, y = b + r \sin \theta$$



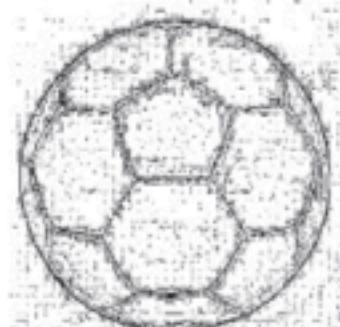
Transformada de Hough círculos



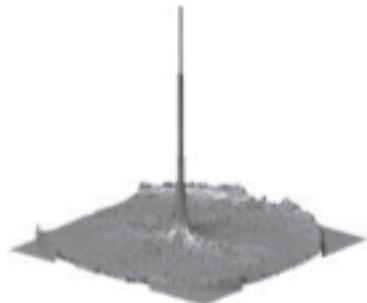
(a) Circle



(b) Soccer ball edges



(c) Noisy soccer ball edges



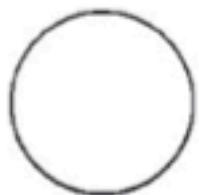
(d) Accumulator for (a)



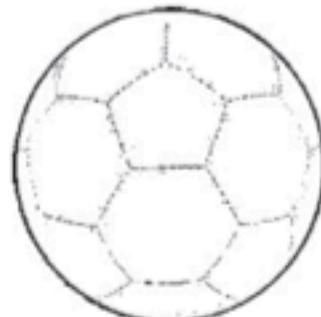
(e) Accumulator for (b)



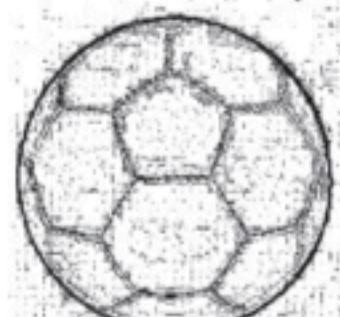
(f) Accumulator for (c)



(g) Circle from (d)



(h) Circle from (e)



(i) Circle from (f)

Transformada de Hough

Material extra - exemplos

Matlab

https://www.dropbox.com/s/oiy0hrhzk9uutsq/Transformada_de_Hough_Matlab.pdf?dl=0

OpenCv

<https://www.dropbox.com/sh/c9eac0urmmtv9o9/AADXJFl-BRHr-MySIHIFdpna?dl=0>

Watershed

Segmentação por descontinuidade

Watershed: O Divisor de Águas

1. Qualquer imagem Tom de Cinza pode ser considerado como uma superfície topográfica.
2. Se inundar esta superfície de seus mínimos e, se evitar a fusão das águas provenientes de diferentes fontes, nós dividimos a imagem em dois grupos diferentes:
 1. Bacias hidrográficas
 2. Linhas de bacias hidrográficas.
3. Se aplicarmos essa transformação ao gradiente de imagem, as bacias hidrográficas deve teoricamente correspondem às regiões de nível de cinza homogêneos desta imagem.

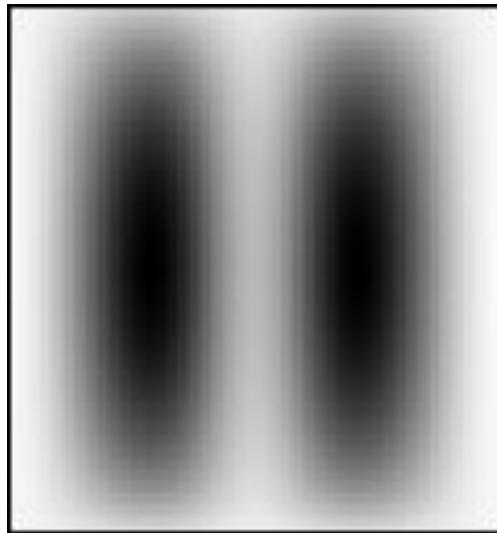
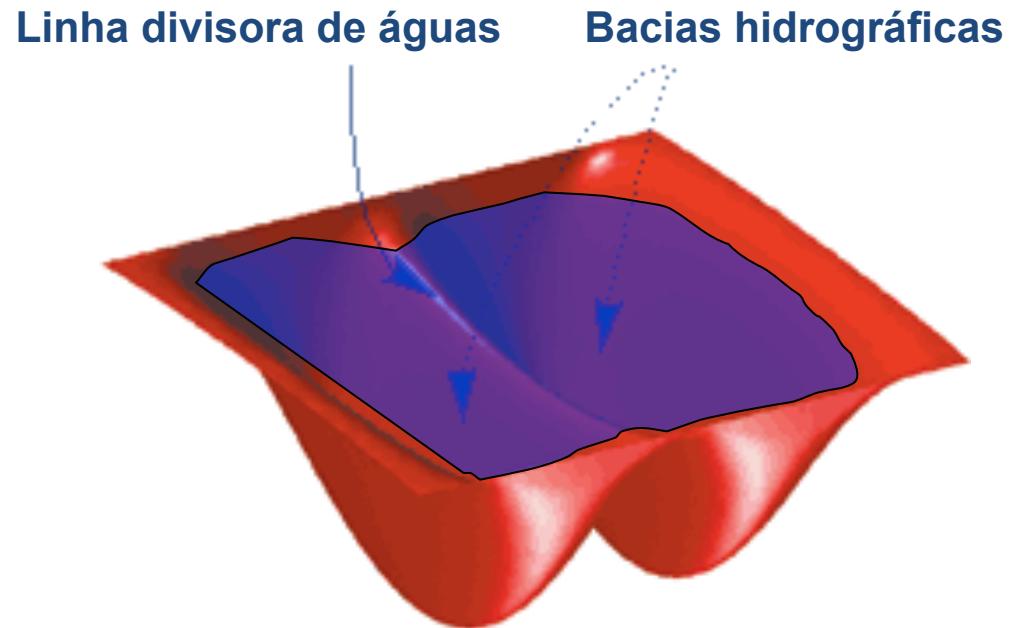
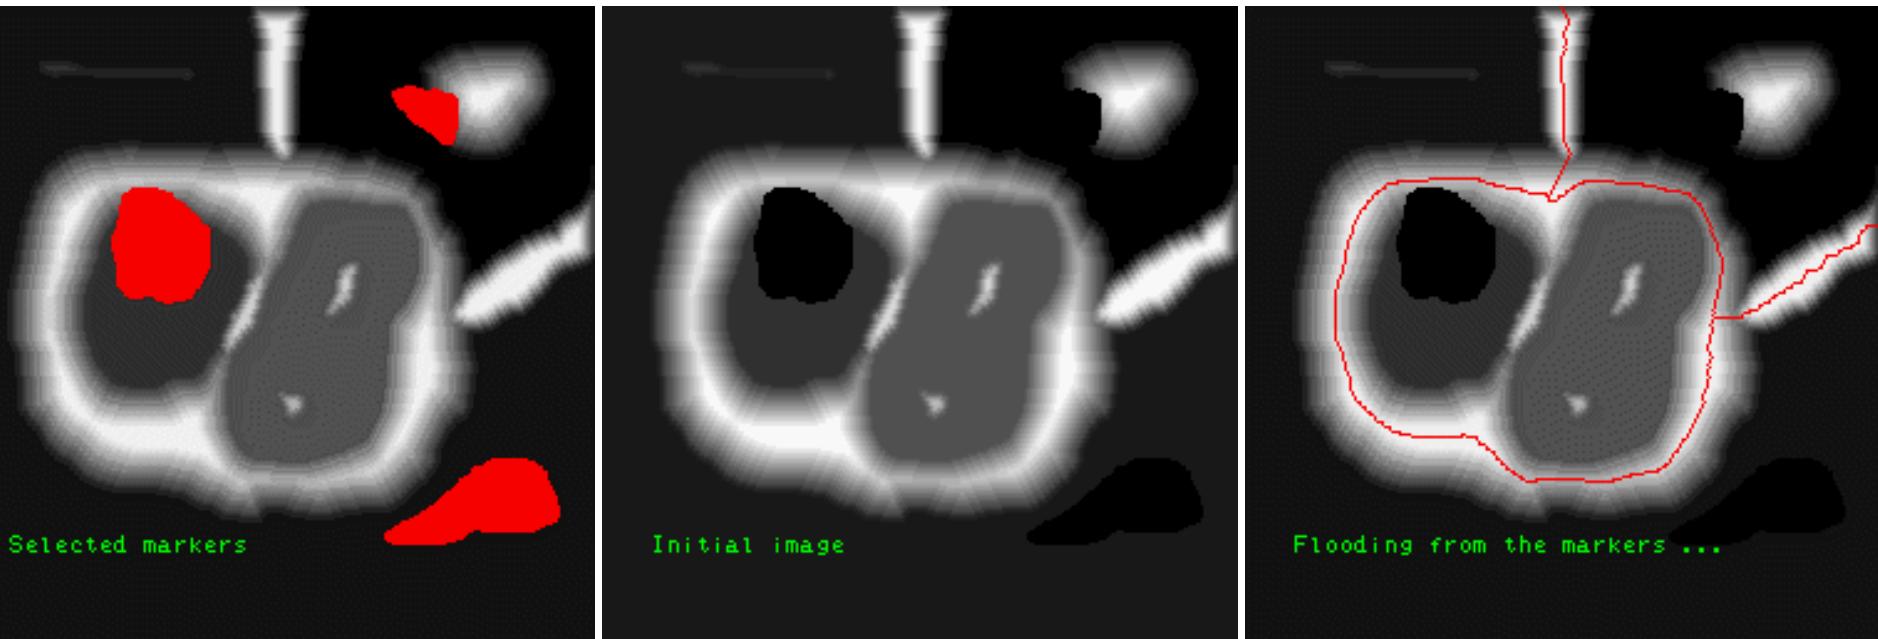


Imagen de gradientes



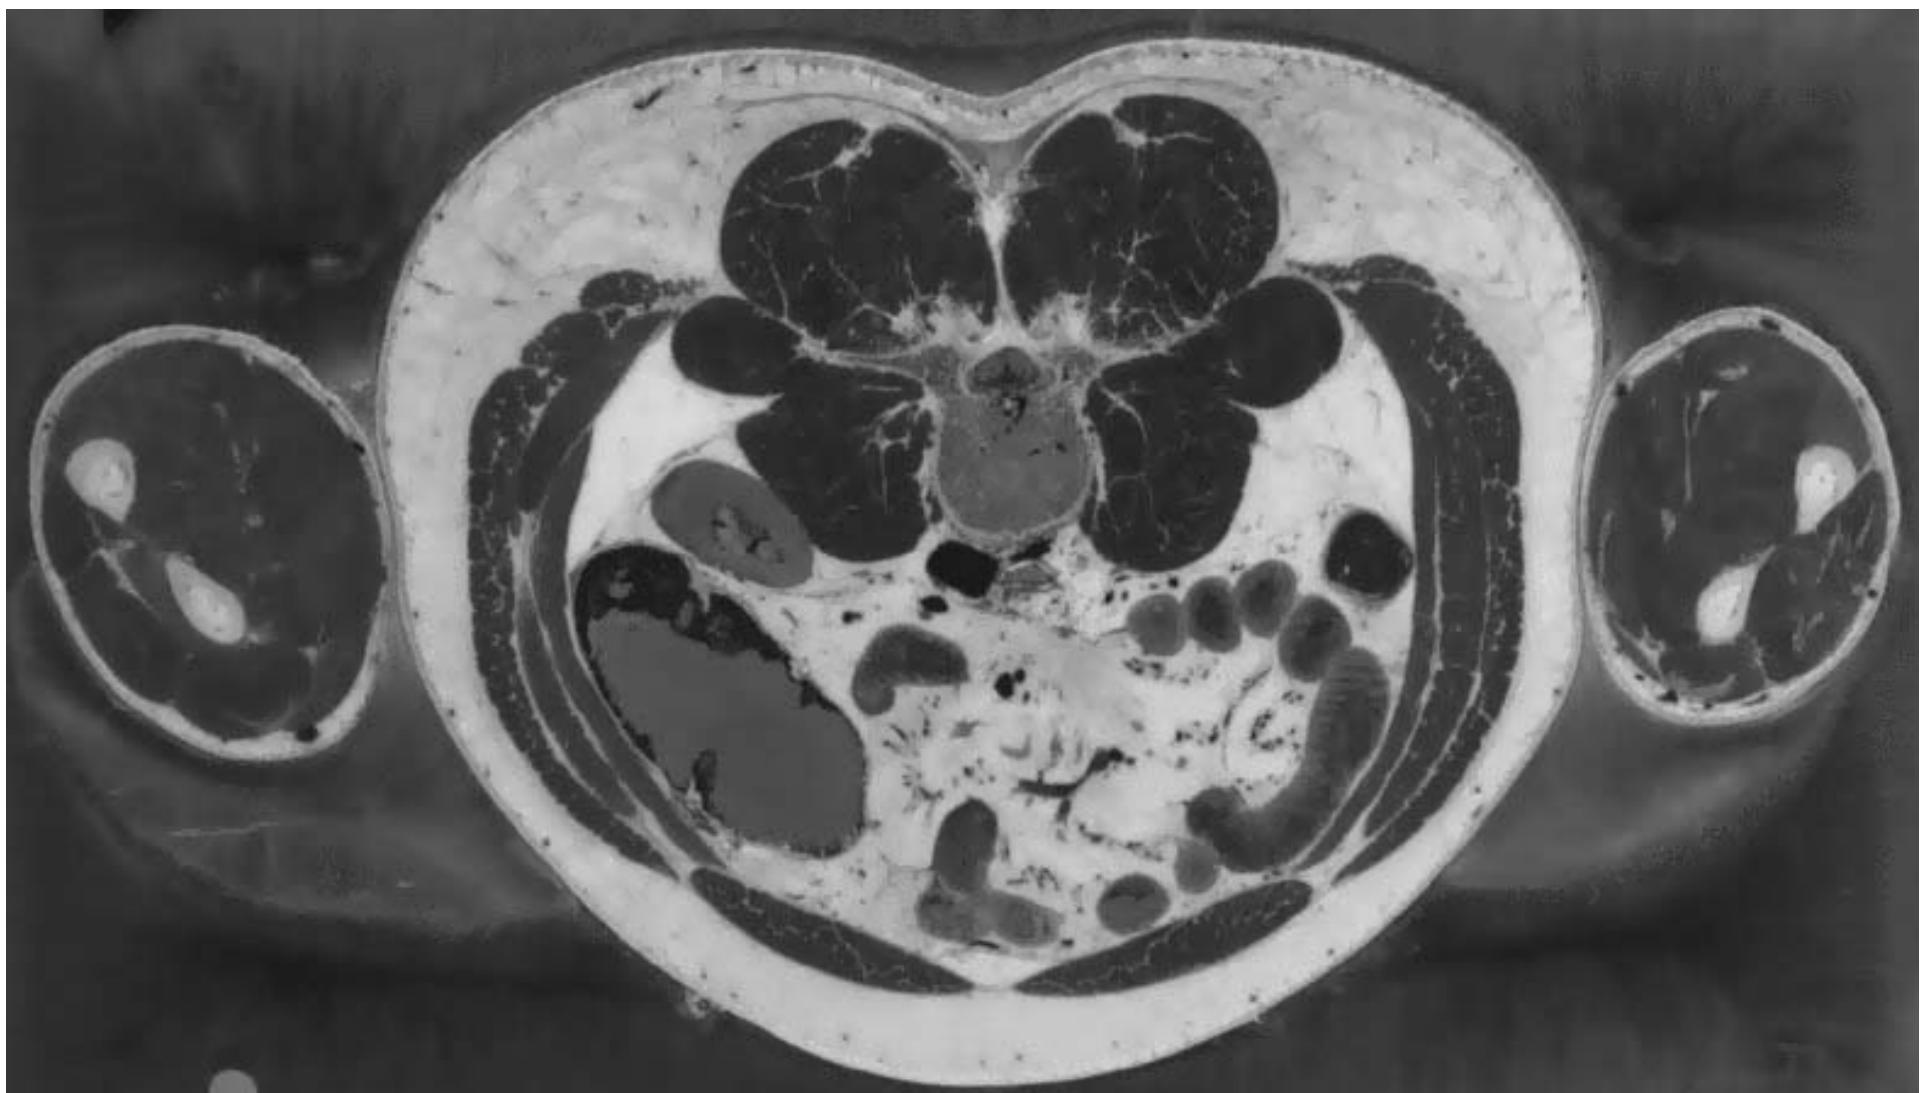
Watershed: O Divisor de Águas

1. Qualquer imagem Tom de Cinza pode ser considerado como uma superfície topográfica.
2. Se inundar esta superfície de seus mínimos e, se evitar a fusão das águas provenientes de diferentes fontes, nós dividimos a imagem em dois grupos diferentes:
 1. Bacias hidrográficas
 2. Linhas de bacias hidrográficas.
3. Se aplicarmos essa transformação ao gradiente de imagem, as bacias hidrográficas deve teoricamente correspondem às regiões de nível de cinza homogêneos desta imagem.



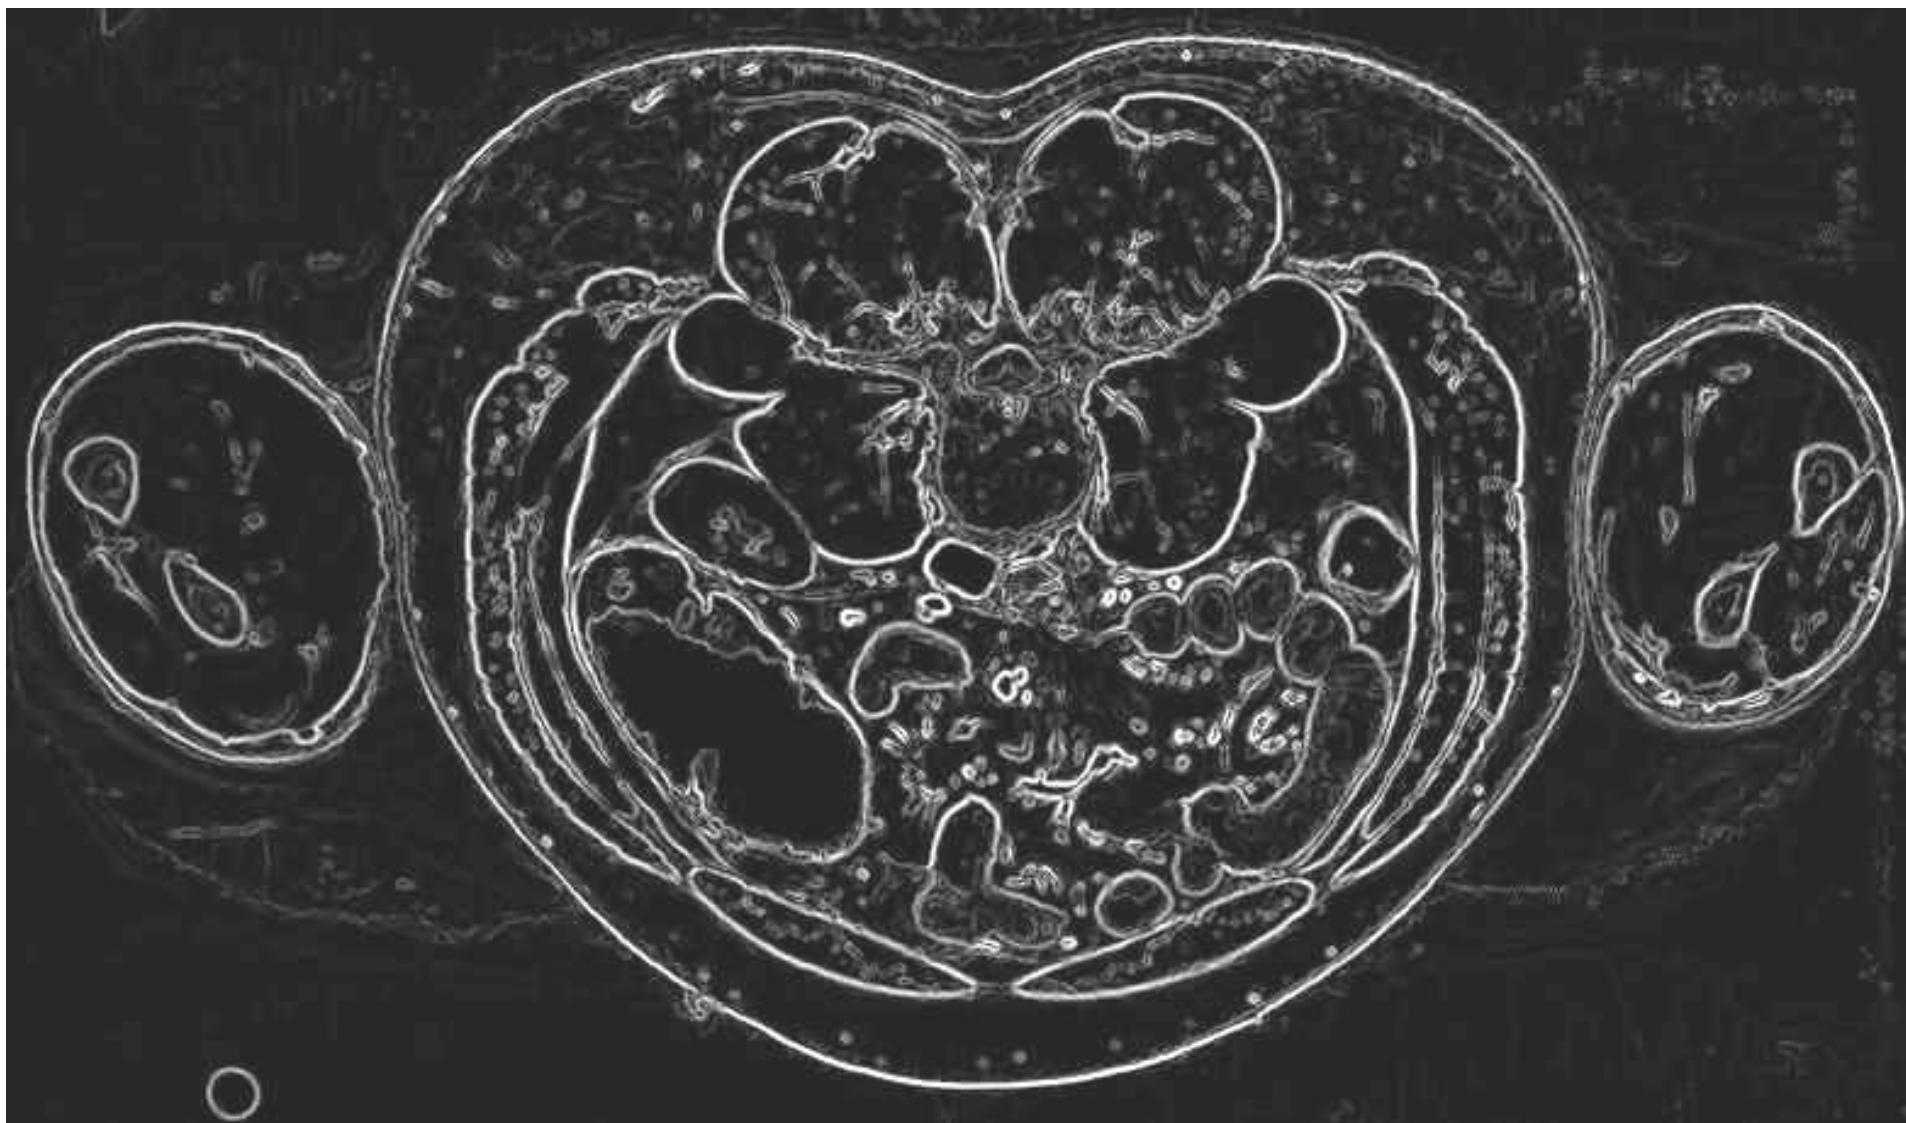
Watershed: Exemplo

- Passo 1: Temos uma imagem qualquer em tom de cinza de entrada



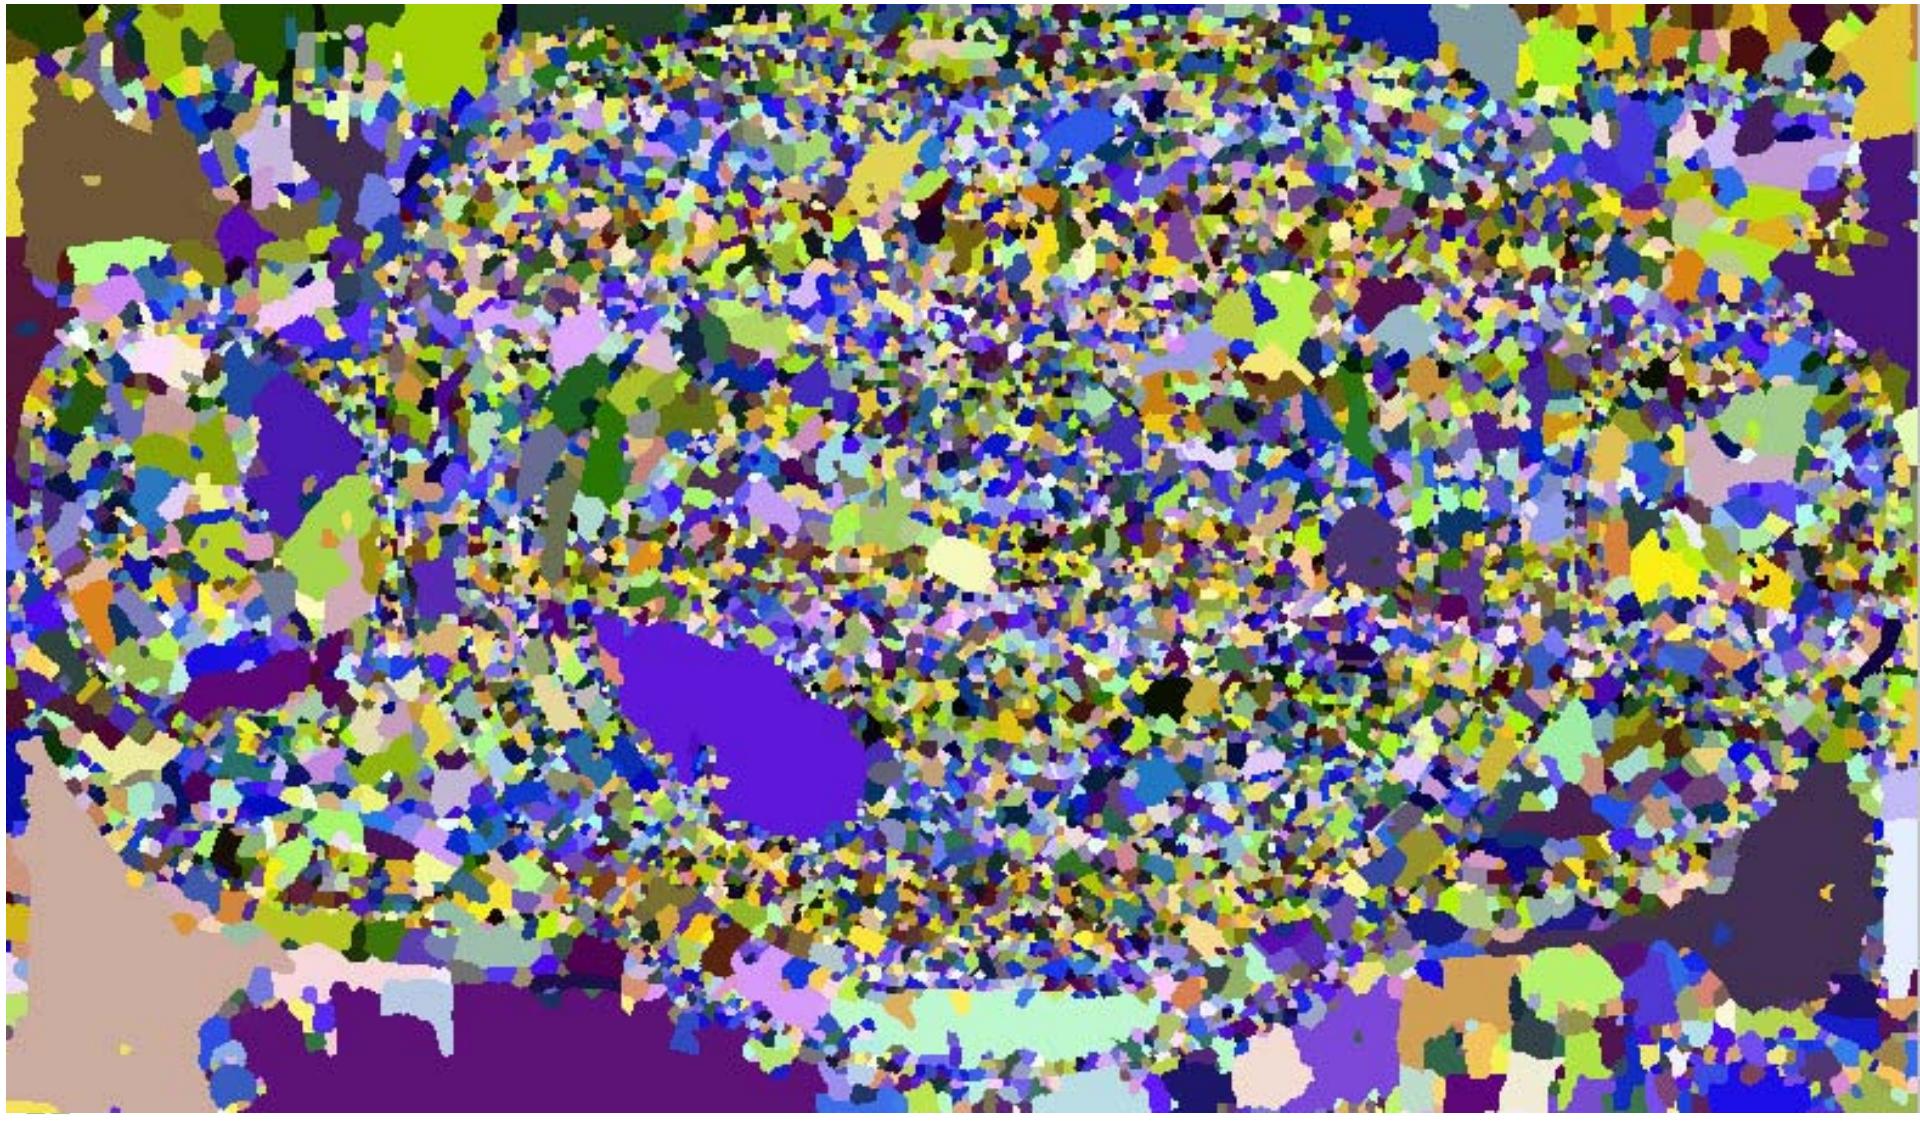
E4.4. Watershed: Exemplo

- Passo 2: Calculamos seu gradiente usando Sobel, Canny ou outro....



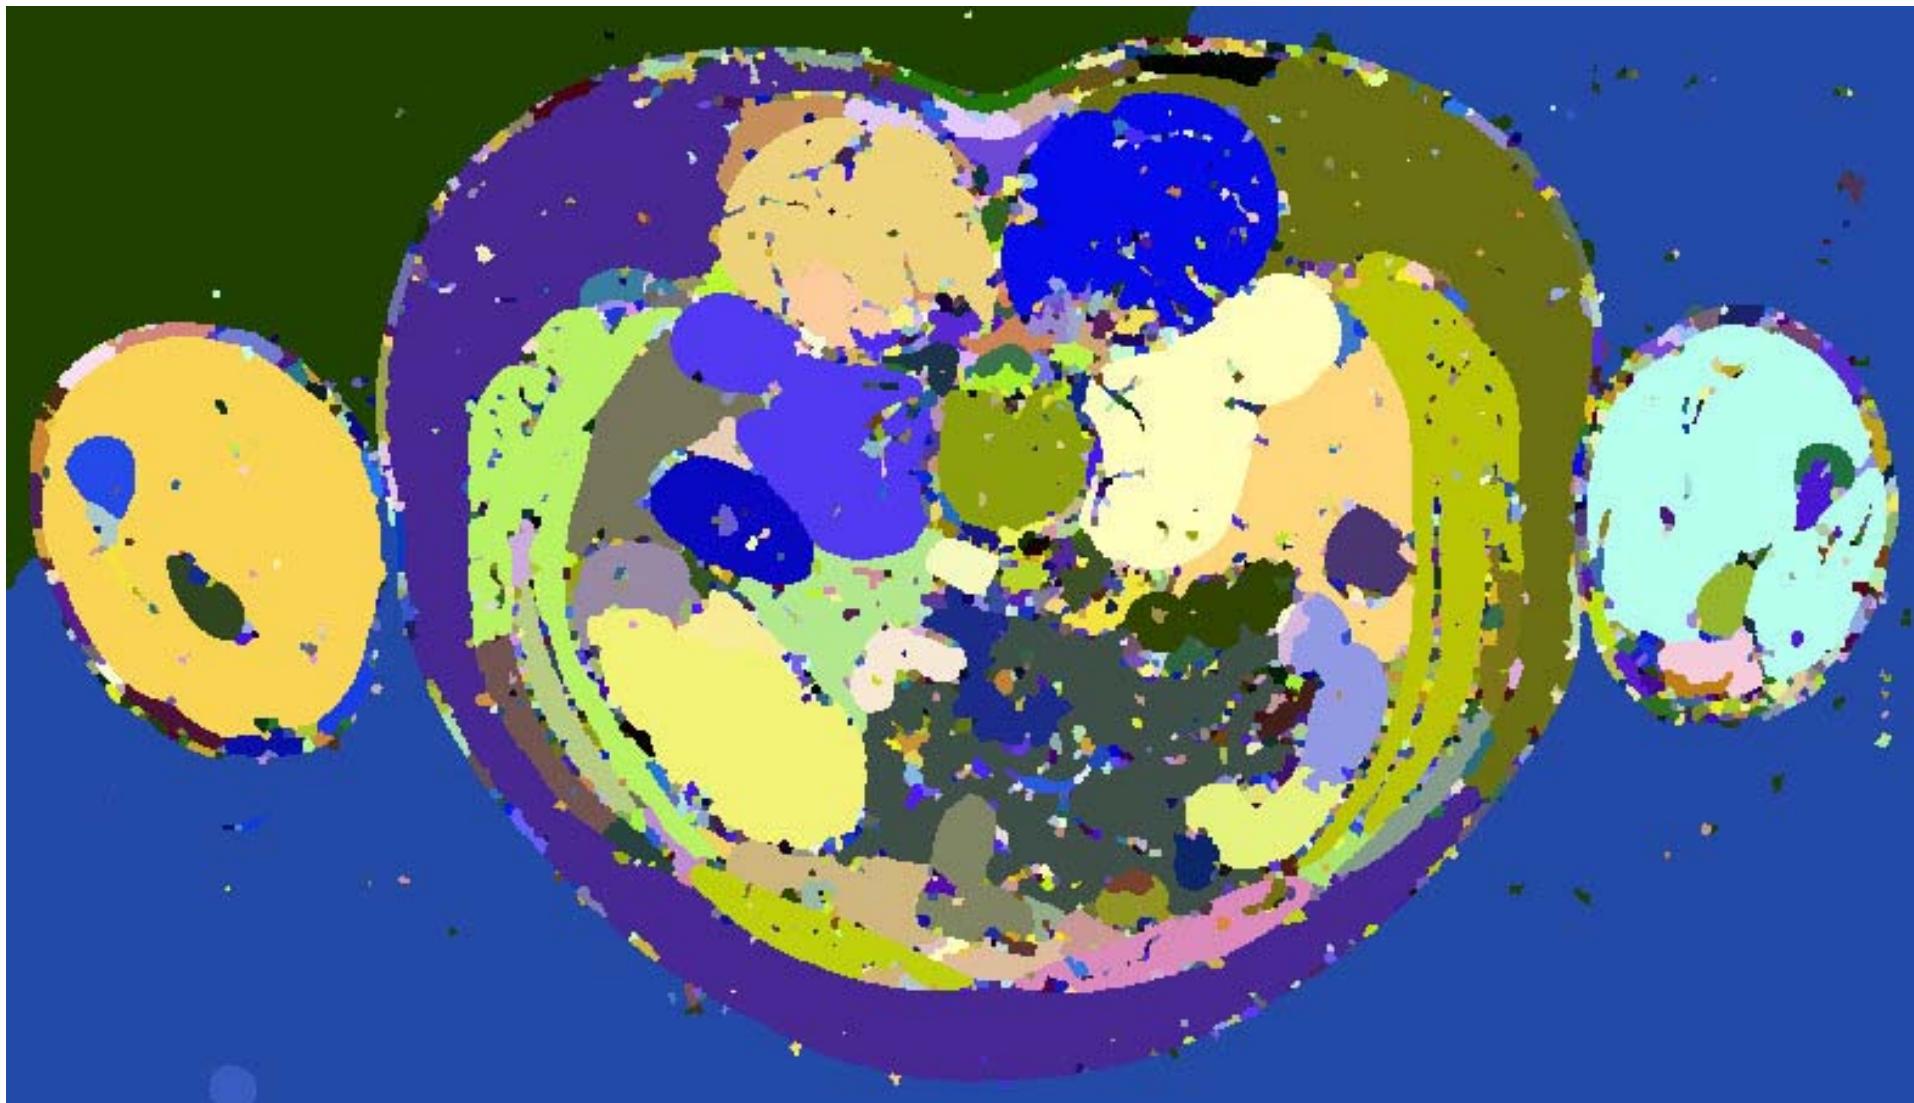
E4.4. Watershed: Exemplo

- Passo 3: Agrupamos pixels vizinhos de gradiente (praticamente) nulo....



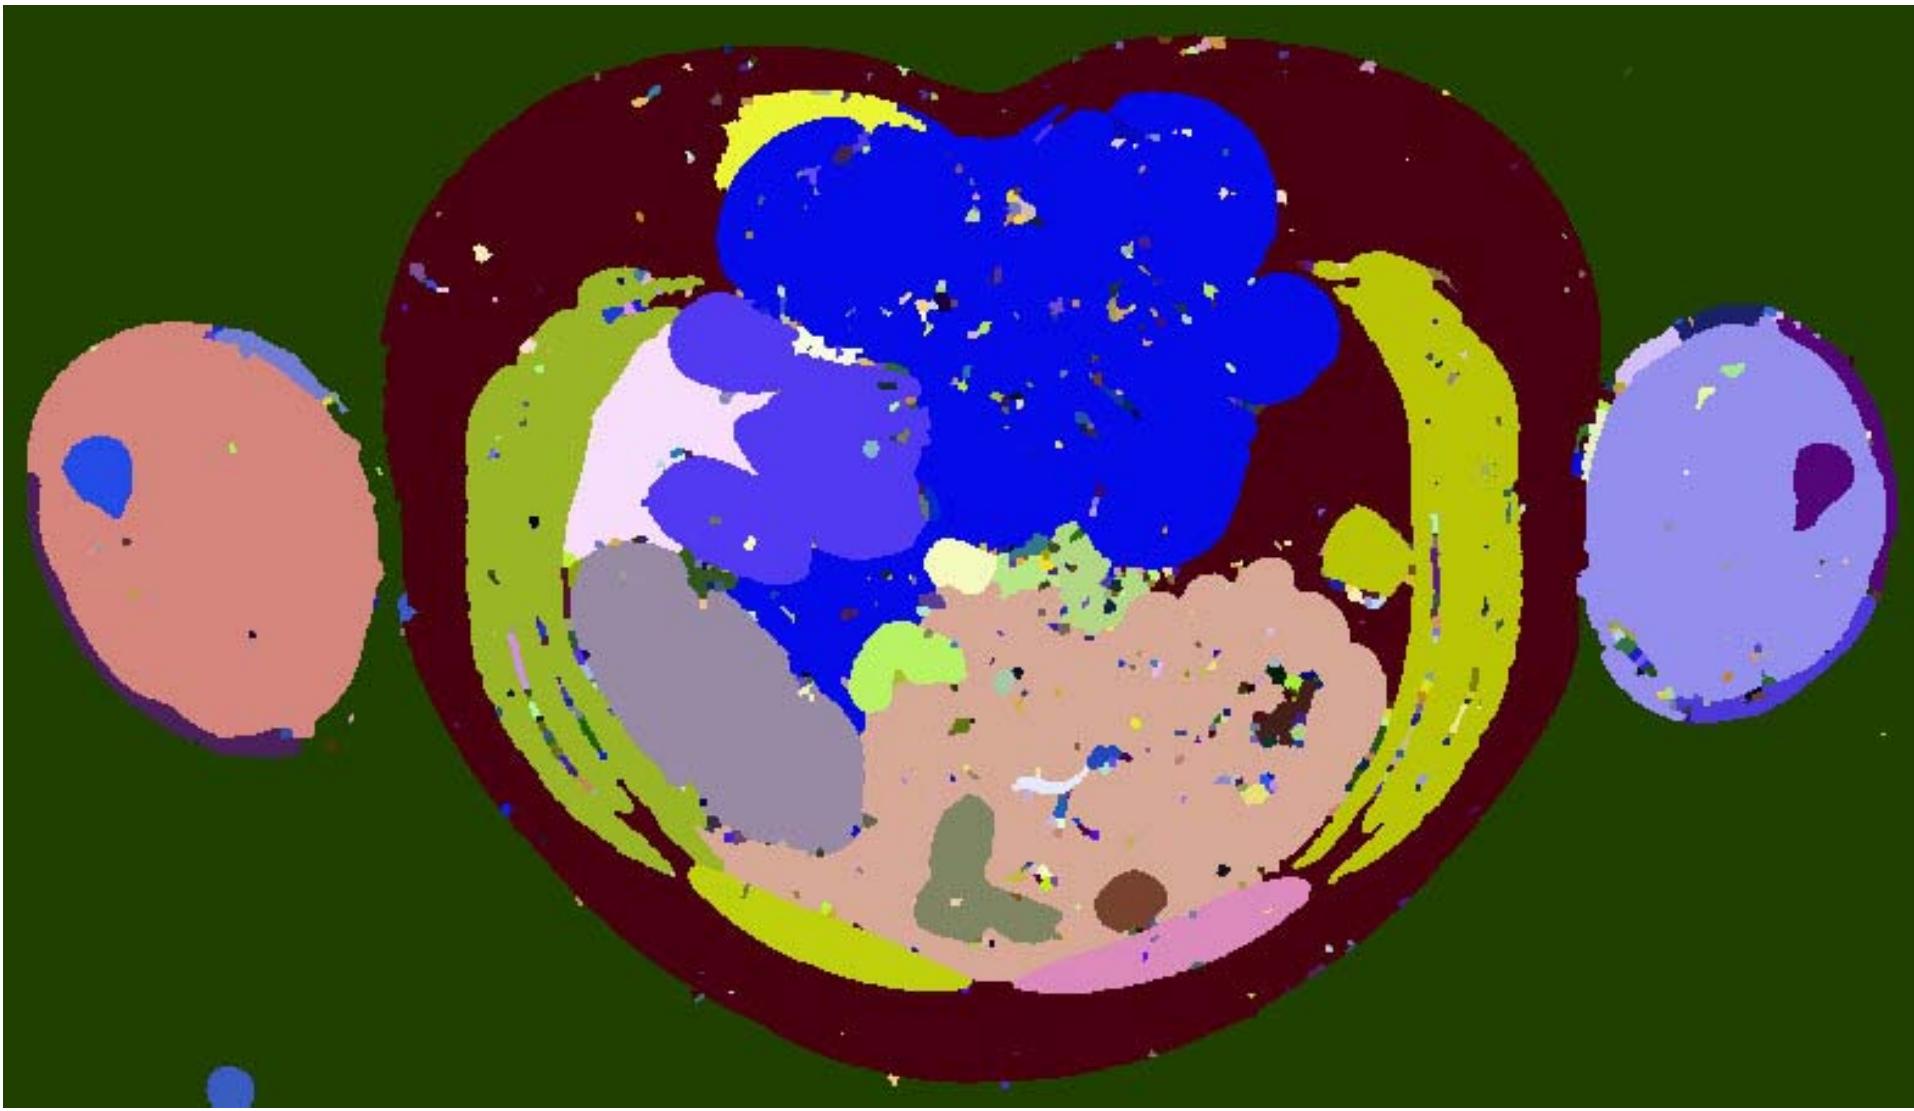
E4.4. Watershed: Exemplo

- Passo 4: Agrupamos regiões elevando o nível da água (função f)....



E4.4. Watershed: Exemplo

- Passo 5: Agrupamos mais as regiões elevando mais o “nível da água” ...



Método de Contornos Ativos

Segmentação por descontinuidade

Método de Contorno Ativo (MCA)

- Definição (KASS; WITKIN; TERZOPOULOS., 1987)
- Comporta-se como uma fita elástica (JÚNIOR, 2006)
- Vantagens (PICHUMANI, 1997):
 - facilidade de manipulação, pois, as forças externas se comportam de uma forma intuitiva;
 - autonomia e auto-adaptação na busca pelo estado de menor energia;
 - baixa sensibilidade ao ruído.
- MCAs:
 - Tradicional
 - Balão
 - GVF



MCA Tradicional

- Função de Energia determinada por (KASS; WITKIN; TERZOPOULOS., 1987):

$$E = \int_0^1 E_{int}[c(s)] + E_{ext}[c(s)] ds$$

em que a parametrização geométrica da curva c é dada por:

$$\begin{cases} [0, 1] & \rightarrow \mathbb{R}^2 \\ s & \rightarrow c(s) = [x(s), y(s)] \end{cases}$$



MCA Tradicional

- Iterações sucessivas de minimização de energia através da análise da vizinhança

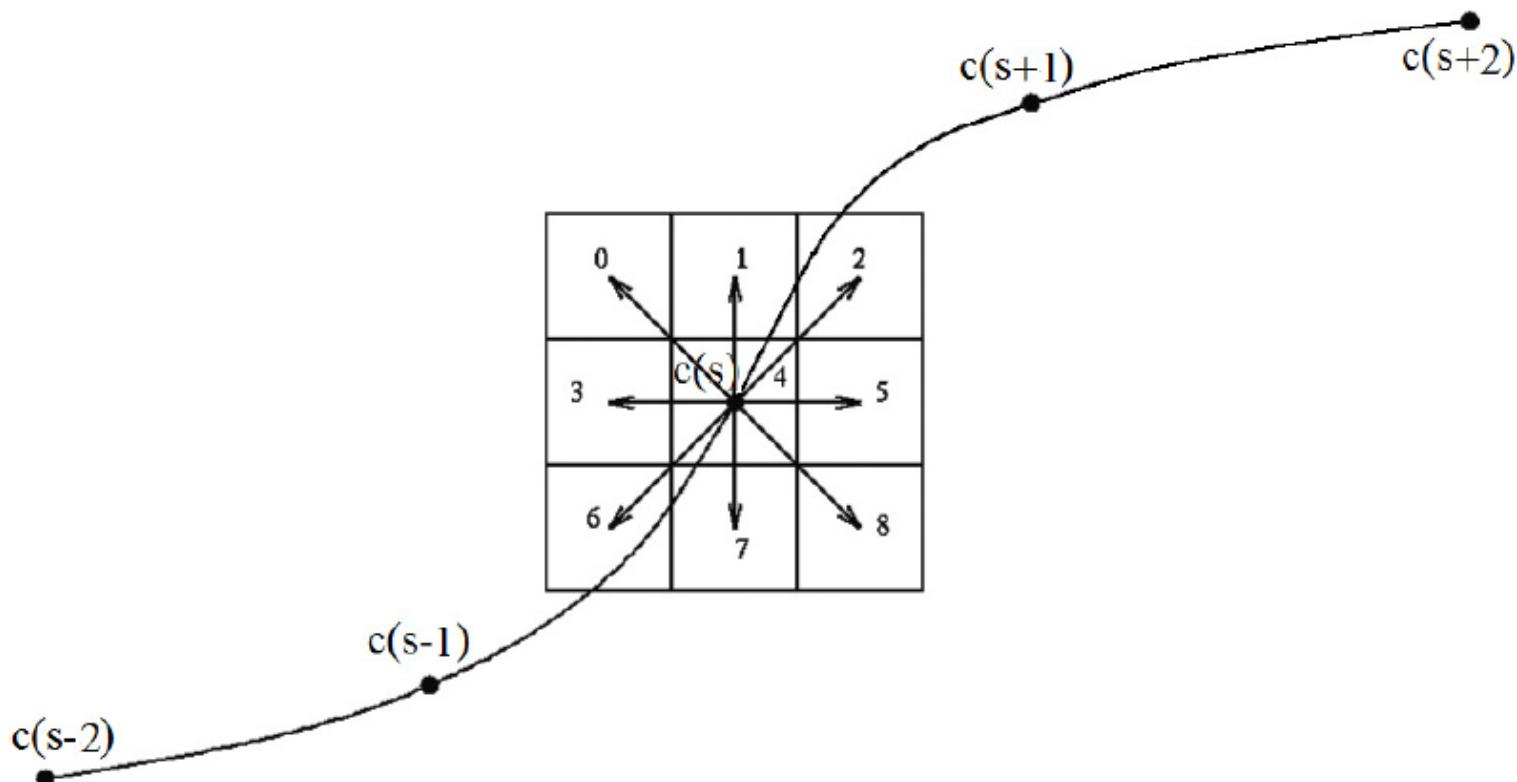


Figura 2.5: exemplo dos vizinhos considerados no cálculo da energia.

MCA Tradicional

- Energia interna

$$E_{\text{int}}[c(s)] = \alpha(s) \left| \frac{d}{ds} c(s) \right|^2 + \beta(s) \left| \frac{d^2}{ds^2} c(s) \right|^2$$

$\left| \frac{d}{ds} c(s) \right| \quad \triangleright \text{Força de continuidade } F_{\text{cont}}$

$\left| \frac{d^2}{ds^2} c(s) \right| \quad \triangleright \text{Força de curvatura } F_{\text{curv}}$

- Energia externa

$$E_{\text{externa}}(V_i) = w_{\text{line}} E_{\text{line}}(V_i) + w_{\text{grad}} E_{\text{grad}}(V_i) + w_{\text{term}} E_{\text{term}}(V_i)$$

\triangleright Operador de gradiente Sobel



MCA Tradicional

- MCA Greedy

$$E[c(s)] = \alpha(s) \left| \frac{dc(s)}{ds} \right|^2 + \beta(s) \left| \frac{d^2c(s)}{ds^2} \right|^2 + \gamma(s) E_{ext}[c(s)]$$

Aplicando a aproximação de Euler-Langrange (KASS; WITKIN; TERZOPOULOS., 1987)

$$\left| \frac{dc(s)}{ds} \right|^2 \approx |c(s) - c(s-1)|^2 = [x(s) - x(s-1)]^2 + [y(s) - y(s-1)]^2$$

Deste modo é dada por:

$$F_{cont} = \sqrt{[x(s) - x(s-1)]^2 + [y(s) - y(s-1)]^2}$$



MCA Tradicional

- MCA Greedy

$$F_{cont} = \sqrt{[x(s) - x(s-1)]^2 + [y(s) - y(s-1)]^2}$$

- Necessidade da distância média DM

$$DM = \frac{\sum_{i=0}^{N-1} \sqrt{(x_i - x_{i-1})^2 + (y_i - y_{i-1})^2}}{N}$$

- Inserindo DM na equação de F_{cont}

$$F_{cont} = \left| DM - \sqrt{[x(s) - x(s-1)]^2 + [y(s) - y(s-1)]^2} \right|$$



MCA Tradicional

- MCA Greedy

$$\left| \frac{d^2c(s)}{ds^2} \right|^2 \approx |c(s-1) - 2c(s) + c(s+1)|^2$$

Do mesmo modo, aplicando a aproximação de Euler-Langrange (KASS; WITKIN; TERZOPoulos., 1987) na segunda derivada :

resultando em (NIXON; AGUADO, 2002)

$$F_{curv} = \sqrt{[x(s-1) - 2x(s) + x(s+1)]^2 + [y(s-1) - 2y(s) + y(s+1)]^2}$$

MCA Tradicional

- Limitações
 - Parametrização (BOUHOURS, 2006)
 - Inicialização afastada das bordas (JÚNIOR, 2006)



(a)



(b)



(c)



(d)



(e)



(f)



(g)

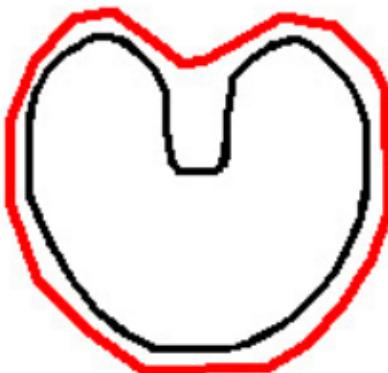


(h)

Figura 2.6: iteração do MCA Tradicional: a) inicialização, b) a g) iterações intermediárias e h) resultado final.

MCA Tradicional

- Limitações
 - Segmentação de objetos côncavos



(a)



(b)

Figura 2.7: aplicação do MCA Tradicional na segmentação de objetos côncavos:
a) inicialização e b) resultado final.

- MCA Balão e MCA GVF

MCA Balão

- Desenvolvida por Cohen (COHEN, 1991)
- Mesma energia externa do MCA Tradicional
- Nova energia interna dada por

$$E_{int}[c(s)] = w_{cont}F_{cont}[c(s)] + w_{bal}F_{bal}[c(s)]$$

em que

$$F_{bal}[c(s)] = \sqrt{E_x^2 + E_y^2},$$

sendo

$$E_x = x(s) - \left| \frac{x_t - x(s)}{x_{max}} \right|$$

$$E_y = y(s) - \left| \frac{y_t - y(s)}{y_{max}} \right|$$



MCA Balão

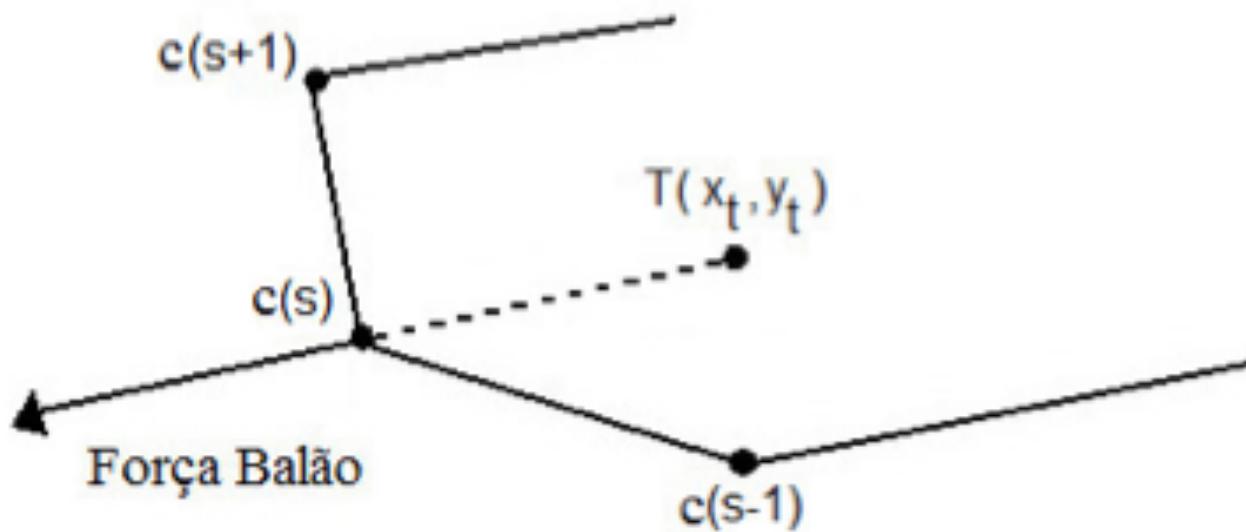


Figura 2.8: exemplo da atuação da força balão repulsando um ponto $c(s)$ em direção contrária ao baricentro $T(x_t, y_t)$.

MCA Balão

- Superando a limitação da inicialização interna e afastada das bordas



(a)



(b)



(c)



(d)

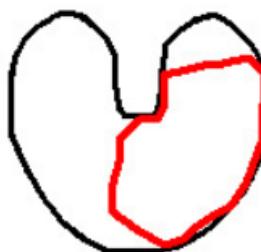
Figura 2.9: a) inicialização da curva, b) e c) são resultados das iterações intermediárias e d) resultado final da segmentação pelo MCA Balão.

MCA Balão

- limitação da inicialização interna, afastada das bordas e descentralizada



(a)



(b)



(c)



(d)

Figura 2.9: a) inicialização da curva, b) e c) são resultados das iterações intermediárias e d) resultado final da segmentação pelo MCA Balão.

MCA Gradient Vector Flow

Os principais problemas no uso do gradiente da imagem como uma força externa no MCA são (XU; PRINCE, 1997):

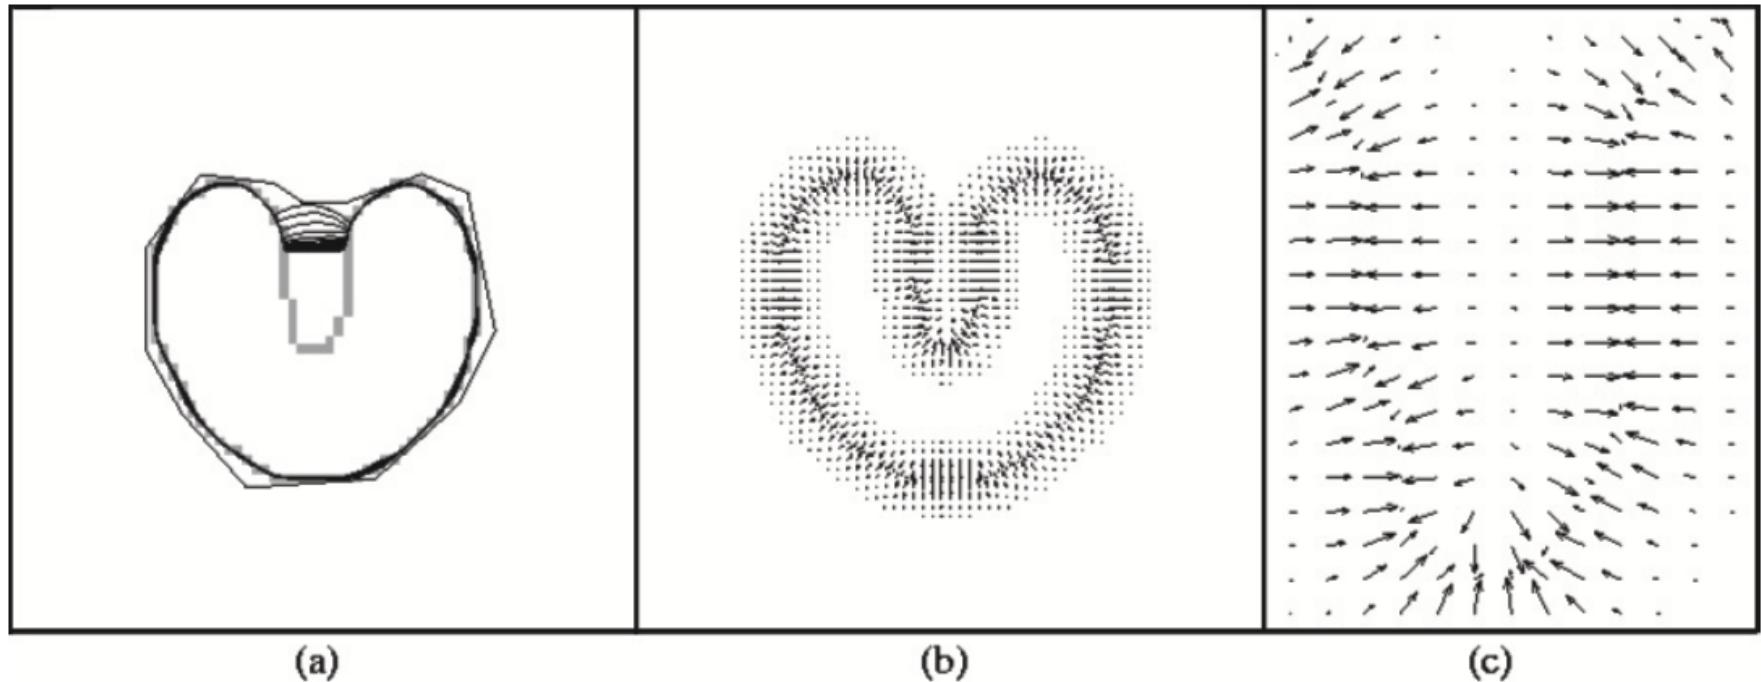


Figura 2.11: a) convergência do *snake*, b) campo de vetores gradiente, c) ampliação da concavidade do campo de gradiente (Xu and Price, 1997).

MCA Gradient Vector Flow

A energia deste método é dada por

$$\alpha(s) \left| \frac{dc(s)}{ds} \right|^2 + \beta(s) \left| \frac{d^2c(s)}{ds^2} \right|^2 + E_{ext}[c(s)] = 0$$

em que

$$E_{ext} = w(x, y)$$

sendo o fluxo de vetores gradiente $w(x, y)$ determinado por

$$w(x, y) = [u(x, y), v(x, y)]$$



MCA Gradient Vector Flow

$$w(x, y) = [u(x, y), v(x, y)]$$

Esta energia externa é uma expansão do mapa das bordas, gerada por iterações sucessivas de minimização da função

$$\varepsilon = \int \int \left\{ \mu \left(\frac{\partial u^2}{\partial x} + \frac{\partial u^2}{\partial y} + \frac{\partial v^2}{\partial x} + \frac{\partial v^2}{\partial y} \right) + |\nabla f|^2 |w - \nabla f|^2 \right\} dx dy$$



MCA Gradient Vector Flow

Utilizando $\mu = 0,1$ para 100, 200 e 400 iterações, têm-se



(a)



(b)



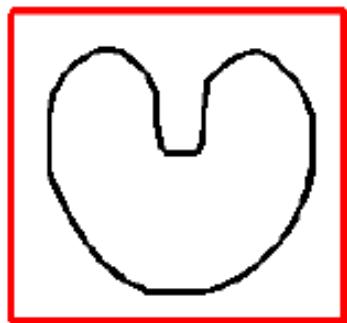
(c)

Figura 2.12: fluxo Gradiente obtido com a) 100 iterações, b) 200 iterações, e c) 400 iterações.

MCA Gradient Vector Flow

O MCA GVF é avaliado neste trabalho utilizando as limitações encontradas nos MCAs Tradicional e Balão

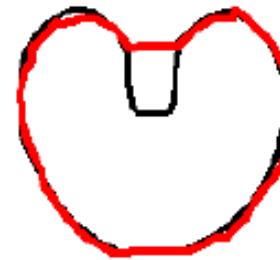
- A primeira limitação do MCA Tradicional, corrigida pelo MCA GVF, é a inicialização fora do objeto com concavidades



(a)



(b)



(c)



(d)

Figura 2.13: primeira limitação do MCA Tradicional superada pelo MCA GVF: a) inicialização da curva, b) e c) iterações intermediárias d) resultado final da segmentação.

MCA Gradient Vector Flow

O MCA GVF é avaliado neste trabalho utilizando as limitações encontradas nos MCAs Tradicional e Balão

- A segunda limitação do MCA Tradicional, corrigida pelo MCA GVF, inicialização da curva dentro do objeto e afastada das suas bordas



(a)



(b)



(c)



(d)

Figura 2.14: segunda limitação do MCA Tradicional, corrigida pelo MCA GVF: a) inicialização da curva, b) e c) iterações intermediárias e d) resultado final da segmentação pelo MCA GVF.

MCA Gradient Vector Flow

O MCA GVF é avaliado neste trabalho utilizando as limitações encontradas nos MCAs Tradicional e Balão

- A limitação do MCA Balão também ocorre no MCA GVF, inicialização da curva dentro do objeto, afastada das suas bordas e descentralizada



(a)



(b)



(c)



(d)

Figura 2.15: limitação dos MCAs Tradicional, Balão e GVF: a) inicialização da curva, b) e c) iterações intermediárias, e d) resultado final da segmentação pelo método GVF.

Aplicações de Contornos Ativos

Segmentação utilizando MCA na área médica

- segmentação do coração em imagens de ressonância magnética (PLUEMPITIWIRIYAWEJ; SOTTHIVIRAT, 2005)
- segmentação do cérebro em imagens de ressonância magnética (LIANG, 2008; SOUZA, 2003; HADZIAVDIC, 2000)
- segmentação do coração em imagens de ultrassom (TAUBER; BATATIA; AYACHE, 2005; LI; ACTON, 2007)
- segmentação de abdomens em imagens de TC (SHEN; KASSIM, 2007)
- segmentação dos pulmões em imagens de TC (ITAI; KIM; ISHIKAWA, 2007).
 - Depende da inicialização próxima das bordas
 - Doenças, ruído, falta de distinção das regiões com ar



Método de Contornos Ativos

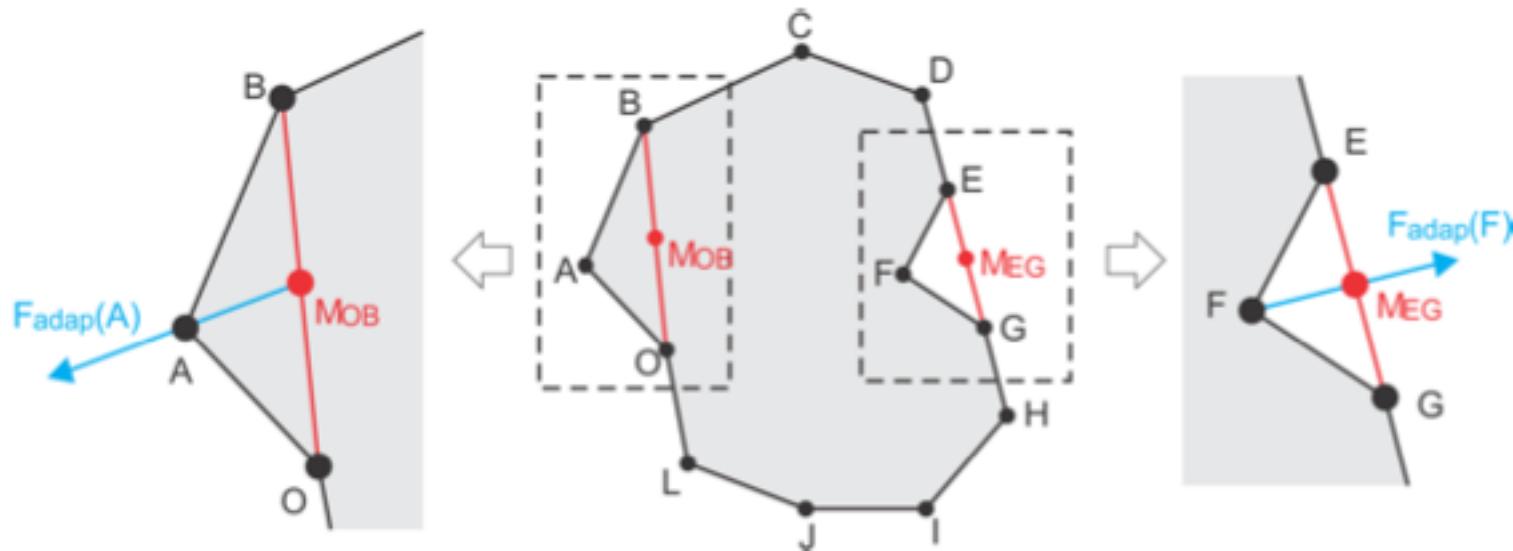
Doutorado do Prof. Pedro Pedrosa

Método de Contornos Ativos

Nova energia interna

Doutorado do Prof. Pedro Pedrosa

Energia Interna Balão Adaptativo



$$F_{adap}[c(s)] = \sqrt{E_x^2 + E_y^2},$$

$$E_x = |x(s) \pm x_m|$$

$$E_y = |y(s) \pm y_m|$$



Energia Interna Balão Adaptativo



Método de Contornos Ativos

Nova energia externa

Doutorado do Prof. Pedro Pedrosa

Energia Externa Crisp Adaptativo

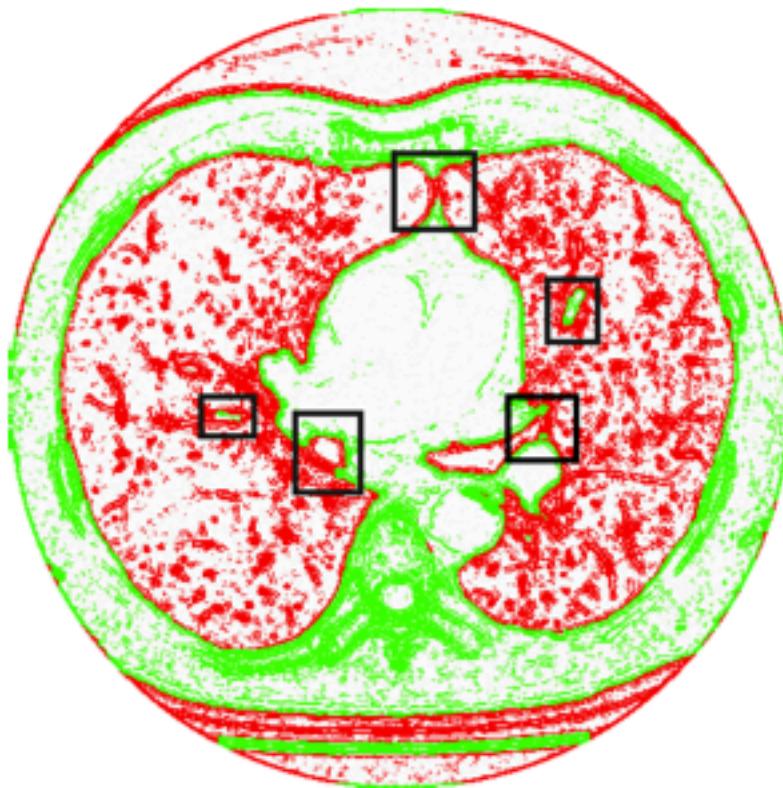
Análise das Densidades Pulmonares (ADP) – Mestrado do Prof. Pedro Pedrosa

- u_0 - hiperaeradas (-1000 a -950 UH) ;
- u_1 - normalmente aeradas (-950 a -500 UH);
- u_2 - pouco aeradas (-500 a -100 UH);
- u_3 - não aeradas (-100 a 100 UH);
- u_4 - osso (600 a 2000 UH);
- u_5 - áreas não classificadas (densidades que não se enquadram nas demais).



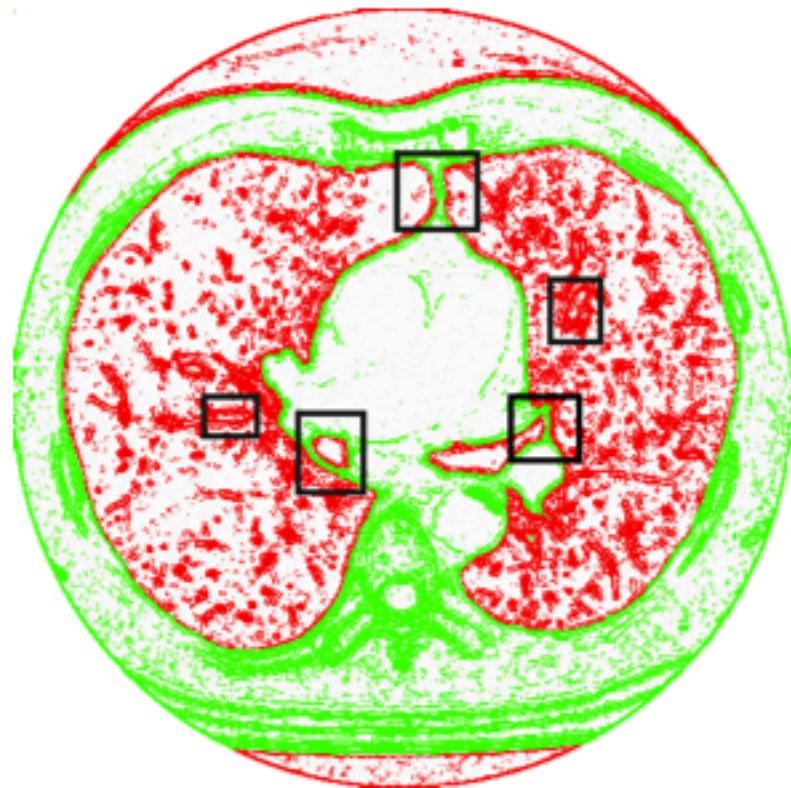
Energia Externa Crisp Adaptativo

ADP



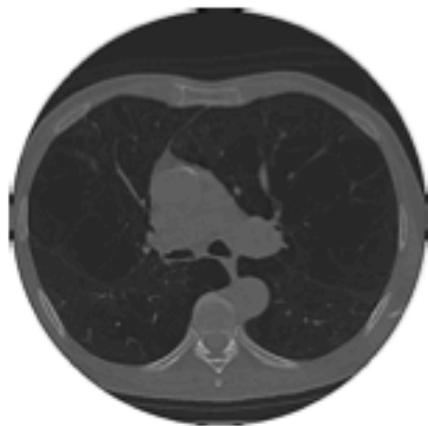
(a)

ADP – RNA MLP

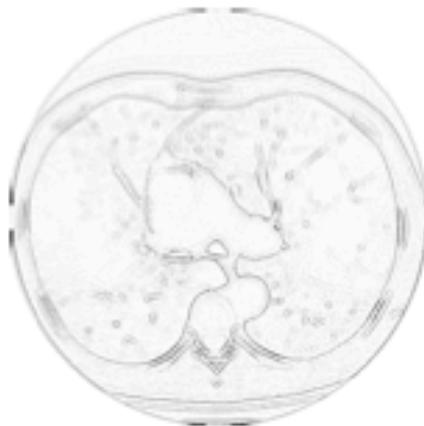


(b)

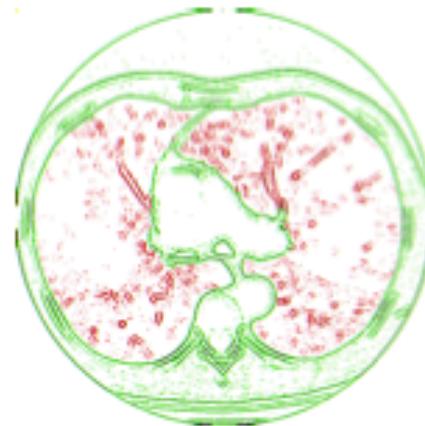
Energia Externa Crisp Adaptativo



(a)



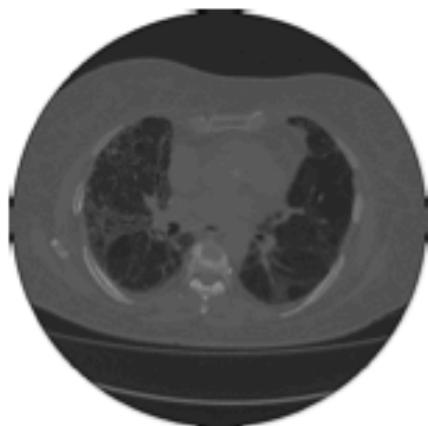
(b)



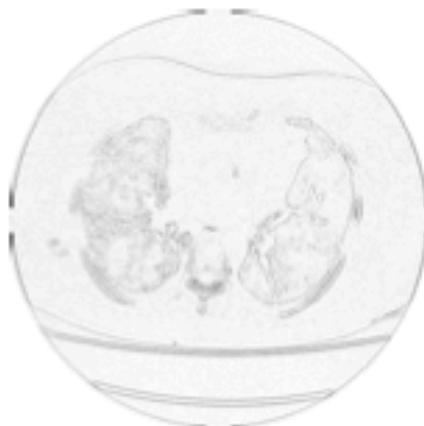
(c)



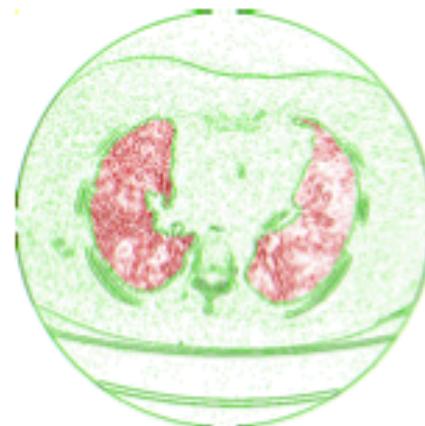
(d)



(e)



(f)



(g)



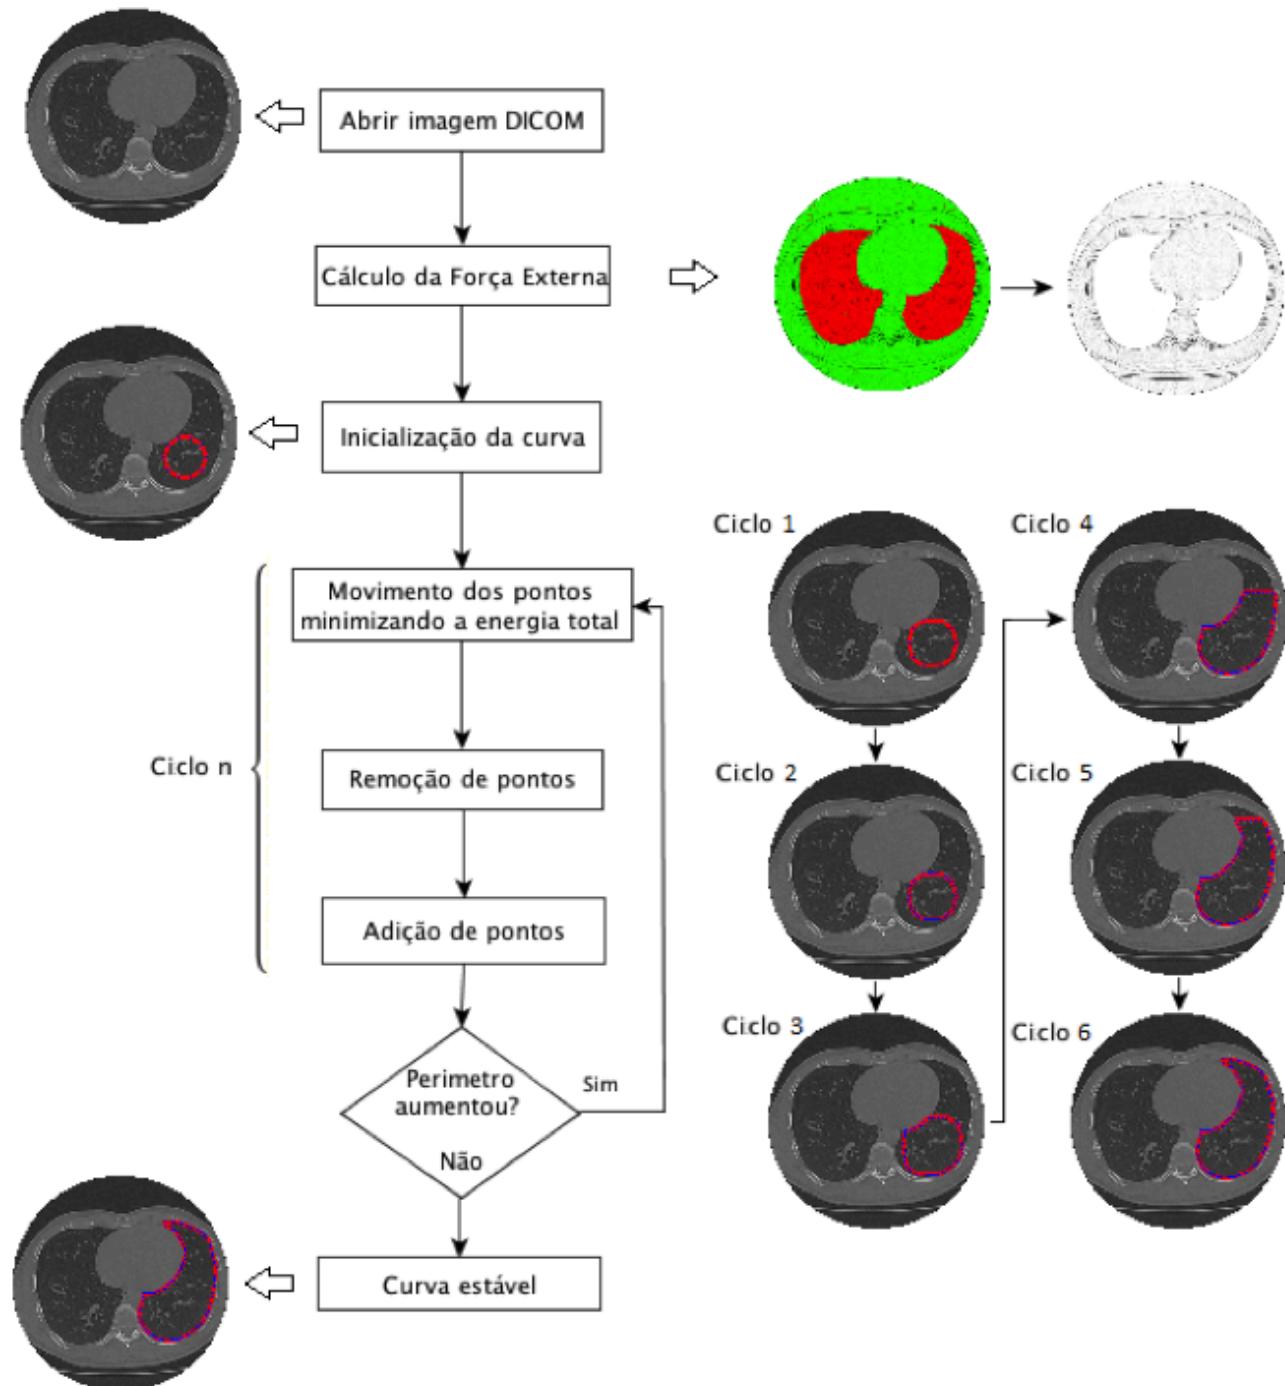
(h)

Método de Contornos Ativos

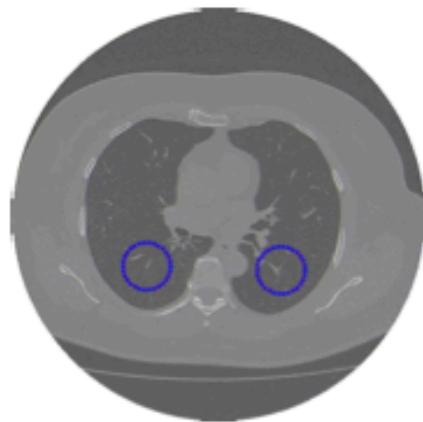
MCA Crisp Adaptativo

Doutorado do Prof. Pedro Pedrosa

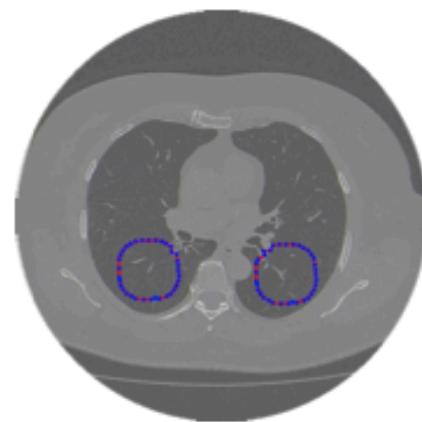
MCA Crisp Adaptativo



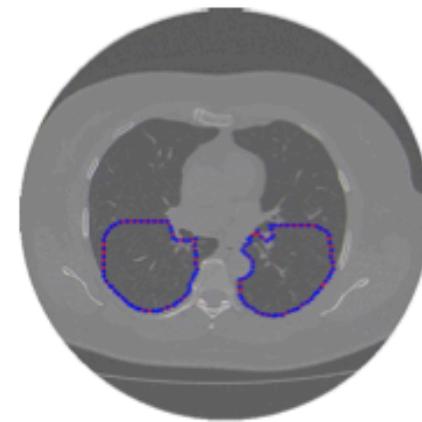
MCA Crisp Adaptativo



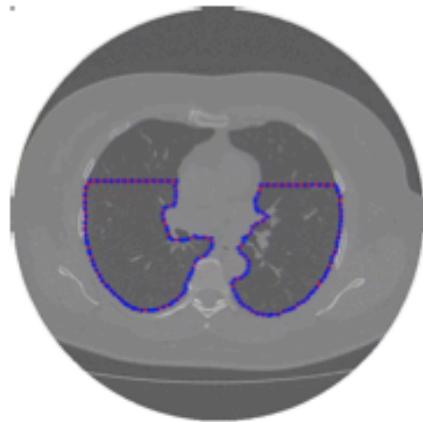
(a)



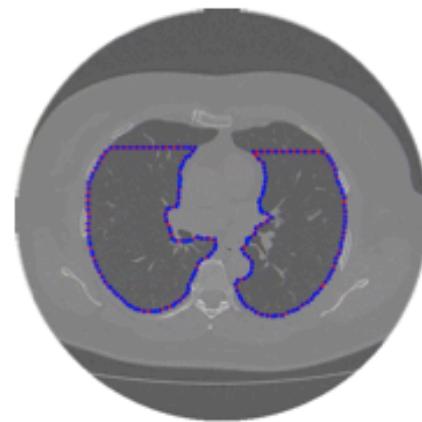
(b)



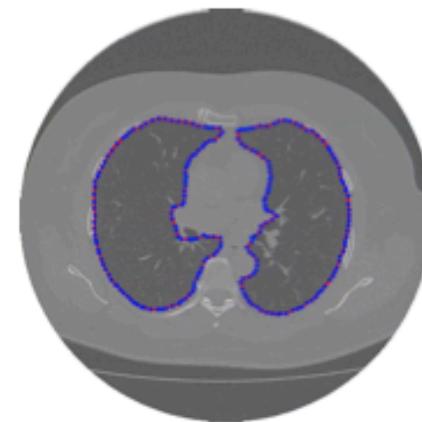
(c)



(d)



(e)



(f)

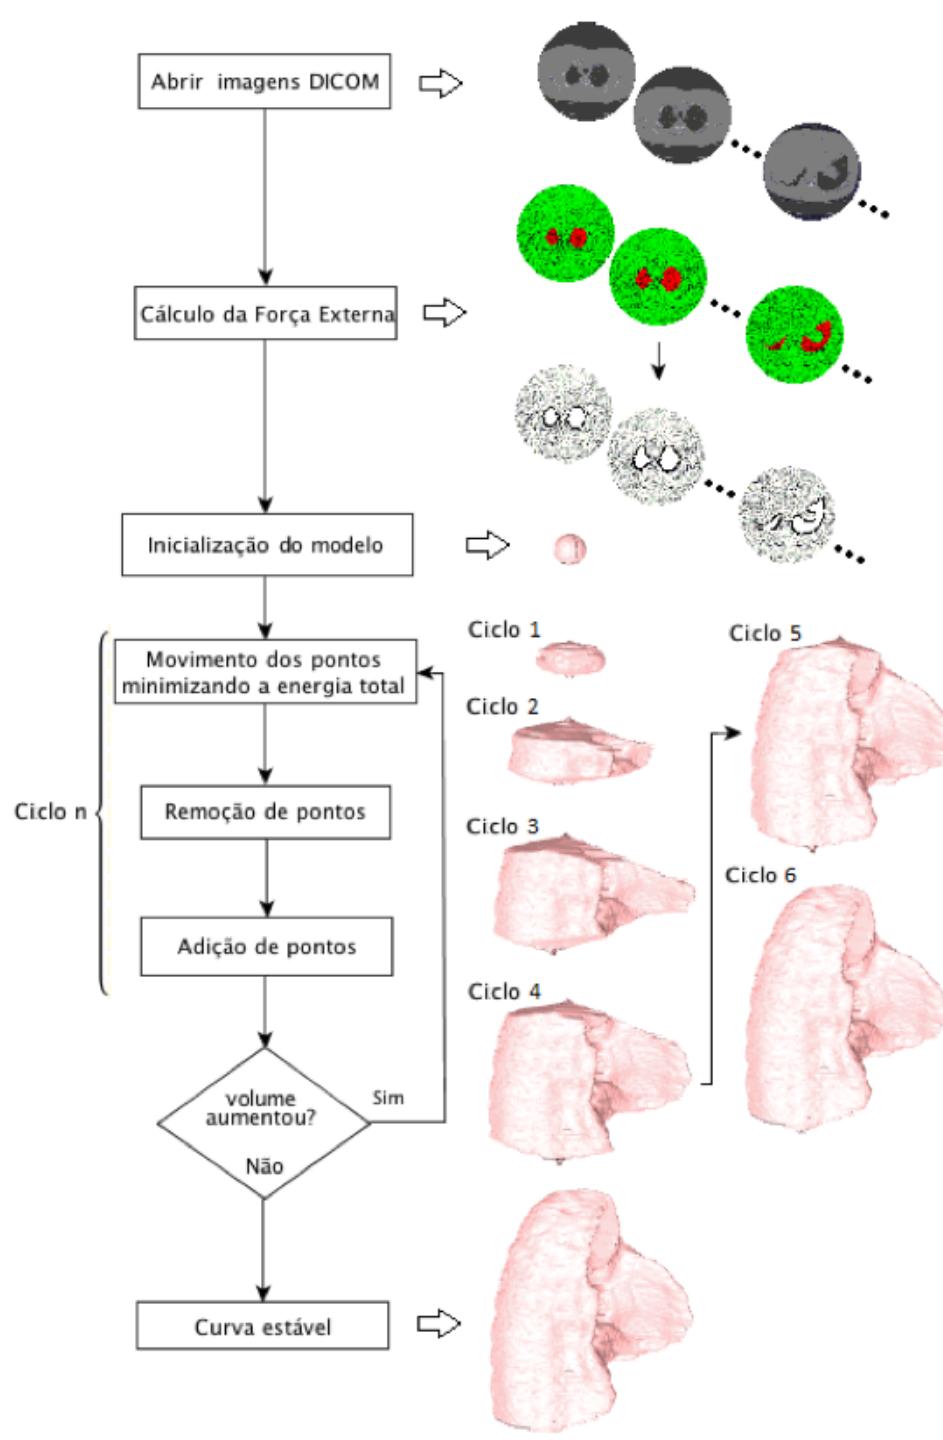
Método de Contornos Ativos

MCA Crisp Adaptativo

Expansão para 3D

Doutorado do Prof. Pedro Pedrosa

MCA Crisp Adaptativo 3D



Videos do doutorado do prof Pedro Pedrosa

1. MCA Balão Adaptativo – https://www.dropbox.com/s/ntnrqkc1b5iaiox/MCA_Bal%C3%A3o_Adaptativo_2D.m4v?dl=0

2. MCA Crisp Adaptativo – Pulmões

Sadios: https://www.dropbox.com/s/isb06flbj7riwos/2D_Doutorado_Sadio.m4v?dl=0

Fibrose: https://www.dropbox.com/s/xvam878g3ge0uti/2D_Doutorado_Fibrose.m4v?dl=0

3. MCA Balão Adaptativo 3D – Modelos Sintéticos 3D

https://www.dropbox.com/s/hn5y9d98k761npk/3D_Sintetico_Ampulheta.m4v?dl=0

4. MCA Crisp Adaptativo 3D – Pulmões

Exemplo: https://www.dropbox.com/s/h8dujn8ex6hnyyt/Doutorado_01_Messejana_01.m4v?dl=0

Aplicações: https://www.dropbox.com/s/bobx0b06sadcvis/Doutorado_00_Demonstra%C3%A7%C3%A3o.m4v?dl=0



Encaminhamentos

- Dúvidas?
- Próximo assunto
 - Segmentação de objetos por descontinuidade

