**Instituto Federal de Educação, Ciência e Tecnologia do Ceará**
**PPGER – PPGCC**

# Aula 8: Segmentação em imagens

**Visão Computacional**

Prof. Dr. Pedro Pedrosa

**pedrosarf@ifce.edu.br**

**professorpedrosa.com**

# INTRODUÇÃO

- Sistema de Visão Computacional

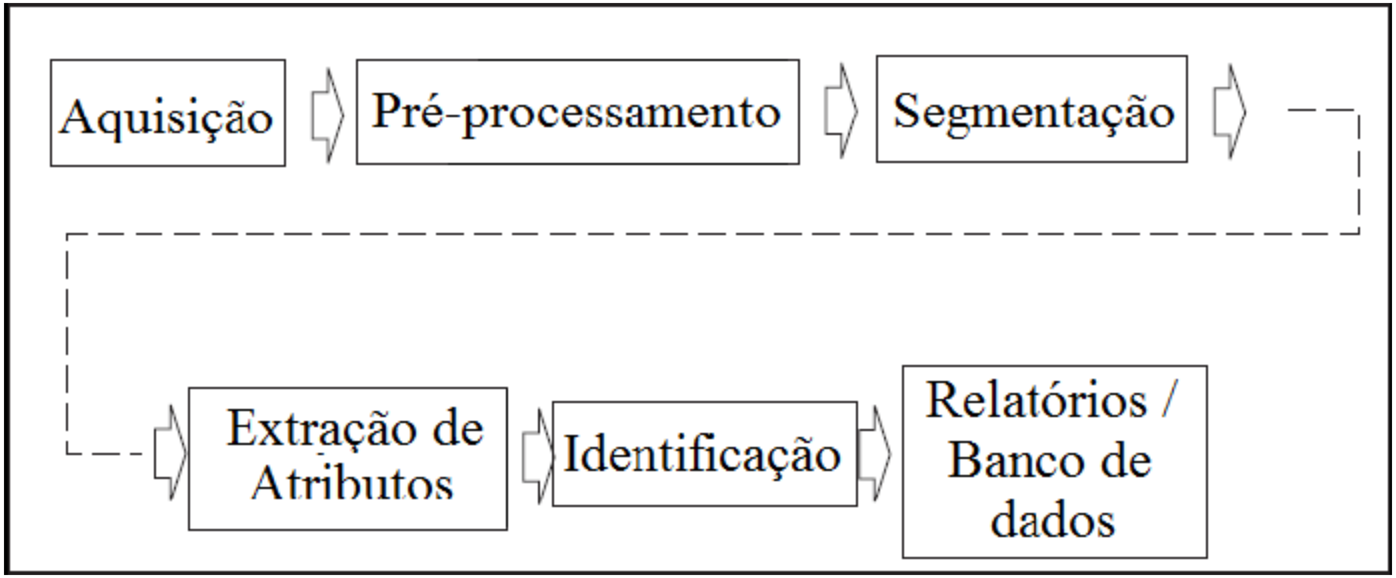

# Introdução à Segmentação

- Identificar e destacar na imagem as regiões de interesse (ROI)
- Tipos:
  - *Similaridade*
    - *Limiarização*
    - *Crescimento de Região*
    - *Clusterização*
  - *Descontinuidade*
    - *Detecção de pontos*
    - *Detecção de linhas*
    - *Detecção de bordas*
    - *Watershed*
    - *Métodos de Contornos Ativos*

# Limiarização

Segmentação por similaridade

# Limiarização

- Depende da escolha de um limiar
  - Fixo

$$B(x,y) = \begin{cases} 1, & \text{se} \quad I(x,y) > L \\ 0, & \text{caso contrário.} \end{cases}$$

  - Automático
    - BERNSEN, 1986
    - COCQUEREZ; PHILLIP, 1995
    - JOHANNSEN; BILLE, 1982
    - Otsu, 1979
  - *Multilimiarização*

$$R(x,y) = \begin{cases} 0, & \text{para} \quad 0 < I(x,y) < 86 \\ 1, & \text{para} \quad 85 < I(x,y) < 171 \\ 2, & \text{para} \quad 170 < I(x,y) < 256 \end{cases}$$

# Limiarização

- Exemplo


Figura 2.1: exemplo de aplicação da limiarização: a) imagem original e b) resultado (ALBUQUERQUE, 2006).

# Exemplos de *Thresholding*

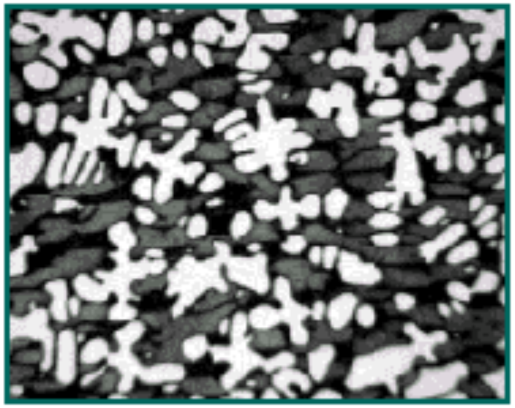

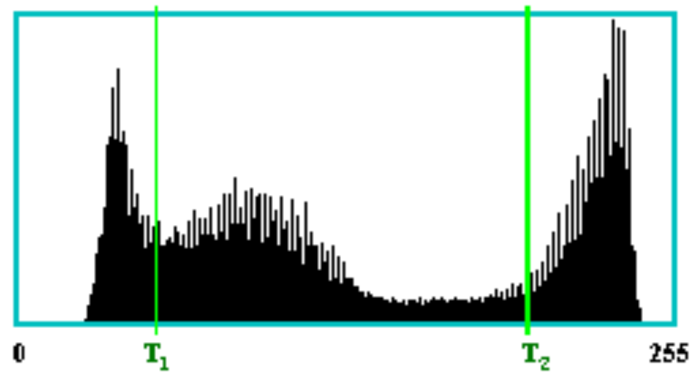


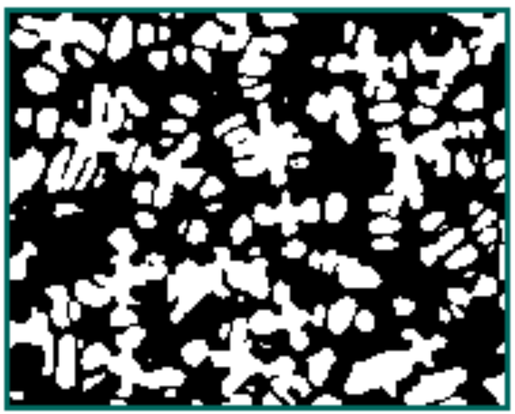

Fase clara ($t>T_2$)

Fase média ($T_1<t<T_2$)

problema !

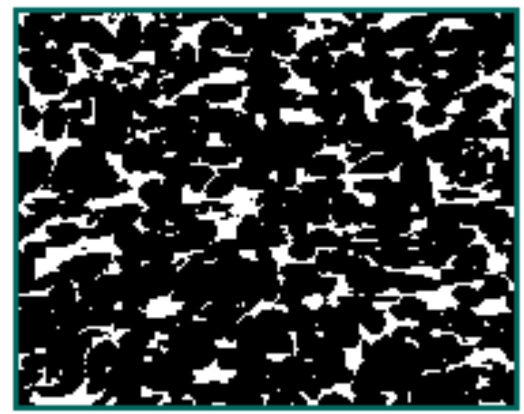

Fase escura ($t<T_1$)

# Detecção do Limiar ($T$)

- Tem-se informação "a priori"? ➡ Simples
  - exemplo: detecção de caracteres em um folha papel
- Análise do formato do histograma
  - bi-modal: Objetos de mesmo NC + fundo

Objetos: + escuros

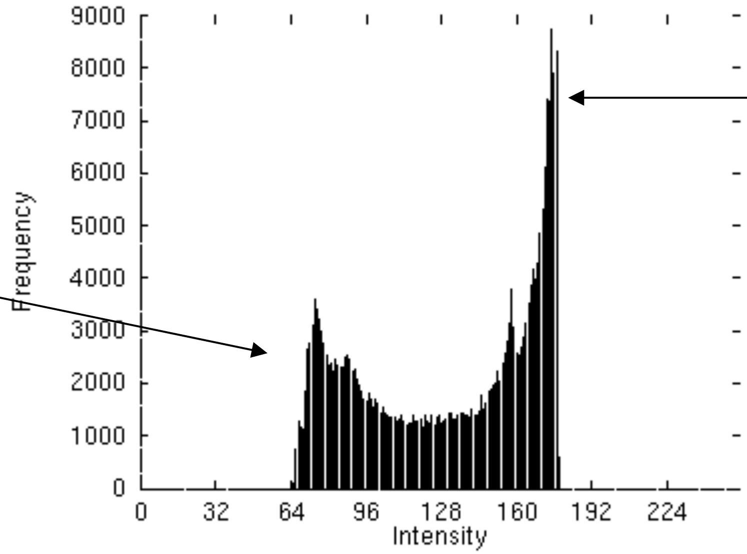


Fundo: + claro

# Limiarização global simples

- Pode ser utilizado quando as distribuições de intensidade entre o fundo e os objetos são suficientemente diferentes.
- Um único limiar para toda a imagem (global)
- Em muitas aplicações, no entanto, a variação das imagens é grande e o limiar muda, mesmo quando a abordagem global for adequada.

# Algoritmo Limiarização global simples

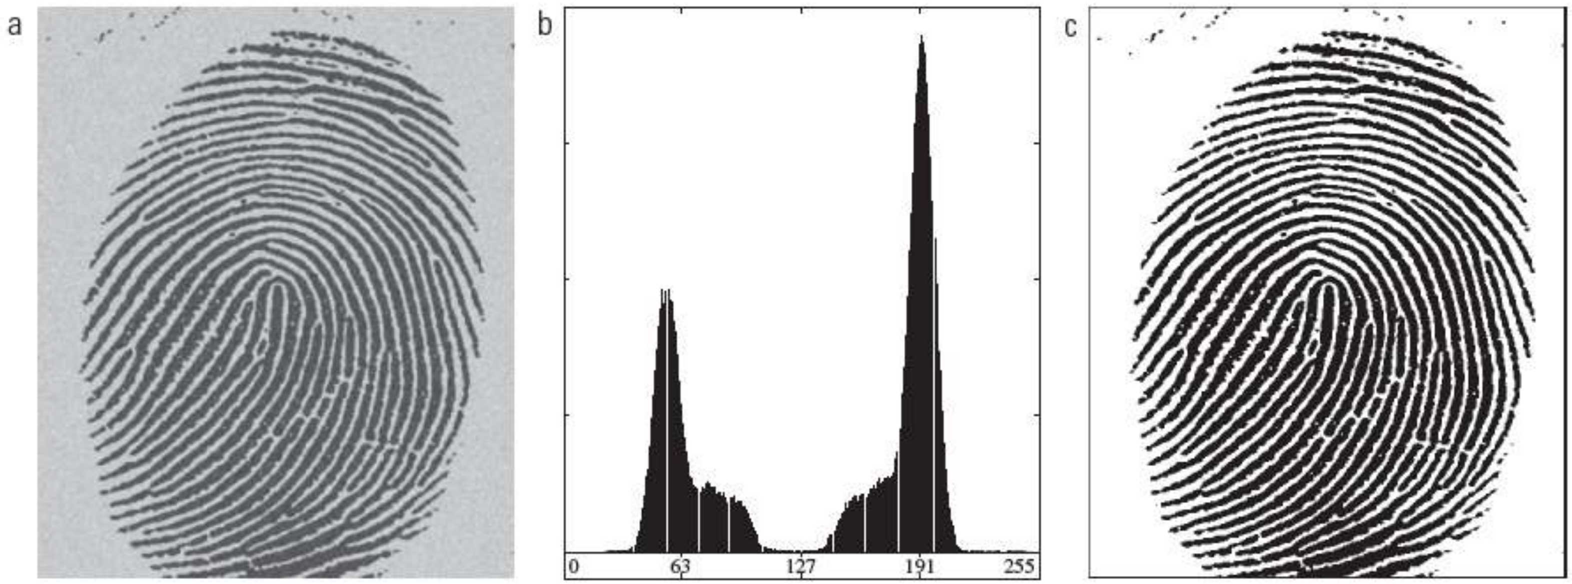


**Figura 10.38** (a) Impressão digital ruidosa. (b) Histograma. (c) Segmentação resultante usando um limiar global (a moldura da imagem foi adicionada para maior clareza). (Original cortesia do National Institute of Standards and Technology.)

# Algoritmo Limiarização global simples

1. Estimar um limiar global inicial
2. Segmentar a imagem usando a regra tradicional de limiarização. Dois grupos se formarão: G1 com pixeis > T e G2 com pixeis < = T
3. Calcular a intensidade média de cada grupo $m_1$ e $m_2$
4. Calcular novo $T = (m_1+m_2)/2$
5. Repita 2 a 4, até que a diferença entre interações sucessivas de T seja menor que um $\Delta T$

# Limiar Ótimo

- Limiar escolhido como o nível de cinza mais próximo correspondente a probabilidade mínima entre dois pontos de máximo de duas ou mais distribuições normais.

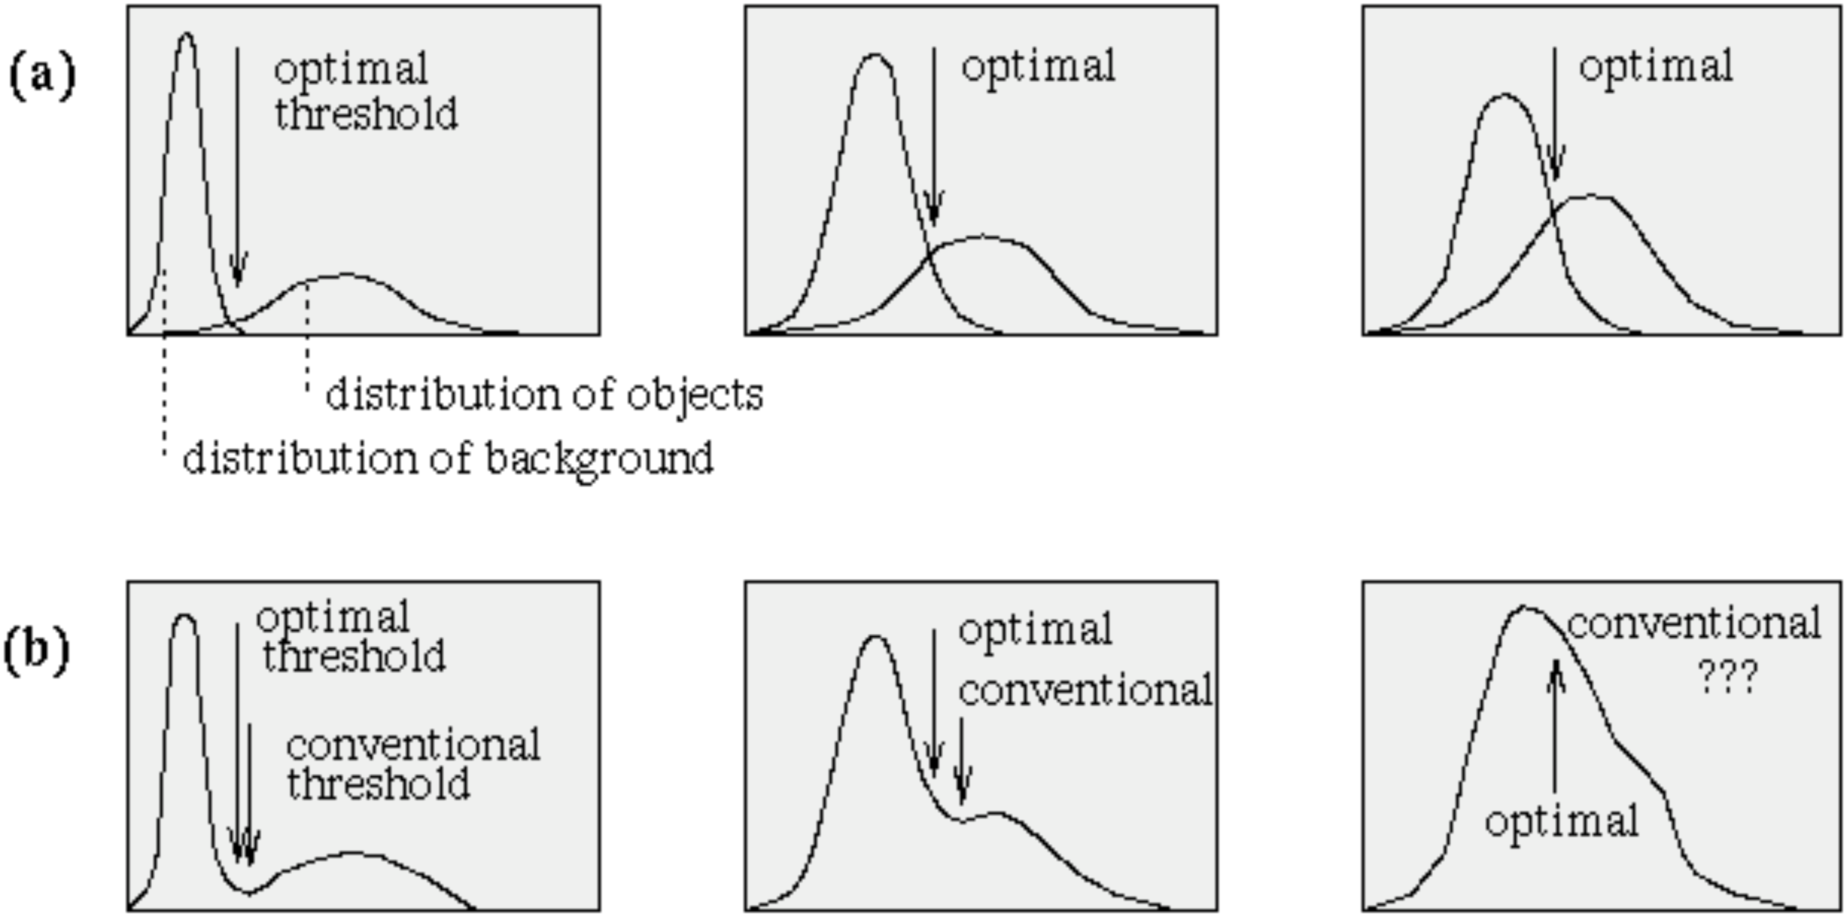

# Limiarização de Otsu

## Segmentação de Imagens

# Método de Otsu (1979)

- Determina o tom de corte que maximiza a medida de variância entre o objeto e o fundo
- Idéia bastante simples: encontrar o limiar que minimiza a variância ponderada ***intra*** classe (*within-class variance*)
    - Isso equivale a maximizar a variância ***entre*** classes (*between-class variance*)
- Tudo se baseia em cálculos no vetor 1D do histograma da imagem.

# Método de Otsu (+custoso)

- A variância ponderada intra classes é a soma ponderada das variâncias de cada classe

$$\sigma_w^2(t) = q_1(t)\sigma_1^2(t) + q_2(t)\sigma_2^2(t)$$

- As probabilidades das classes são dadas por

$$q_1(t) = \sum_{i=1}^{t} P(i) \qquad q_2(t) = \sum_{i=t+1}^{I} P(i)$$

# Método de Otsu (+custoso)

e as médias das classes são dadas por

$$\mu_1(t) = \frac{1}{q_1(t)} \sum_{i=1}^{t} iP(i) \qquad \mu_2(t) = \frac{1}{q_2(t)} \sum_{i=t+1}^{I} iP(i)$$

As variâncias individuais das classes

$$\sigma_1^2(t) = \sum_{i=1}^{t} [i - \mu_1(t)]^2 \frac{P(i)}{q_1(t)} \qquad \sigma_2^2(t) = \sum_{i=t+1}^{I} [i - \mu_2(t)]^2 \frac{P(i)}{q_2(t)}$$

Pronto. Precisamos apenas percorrer toda a faixa de valores de T [1,256] e escolher o valor que minimiza $\sigma_w^2(t)$

– Isso é um pouco custoso...

# Otsu (variâncias)

- Ao subtrairmos a variância intra classes da variância total do histograma (ambas as classes), obtemos a variância entre classes (between-class variance)

$$\sigma 2_{\mathrm{Between}}(T) = \sigma 2 - \sigma 2_{\,Within}(T)$$
$$= q1(T)\,[\mu_1(T) - \mu]^2 + q_2(T)\,[\mu 2(T) - \mu]^2$$

- Note que a variância entre classes é apenas a variância ponderada da média dos clusters sobre a media global.

Imagem original com iluminação irregular

Imagem corrigida com filtro passa-altas, 49x49, 4 iterações

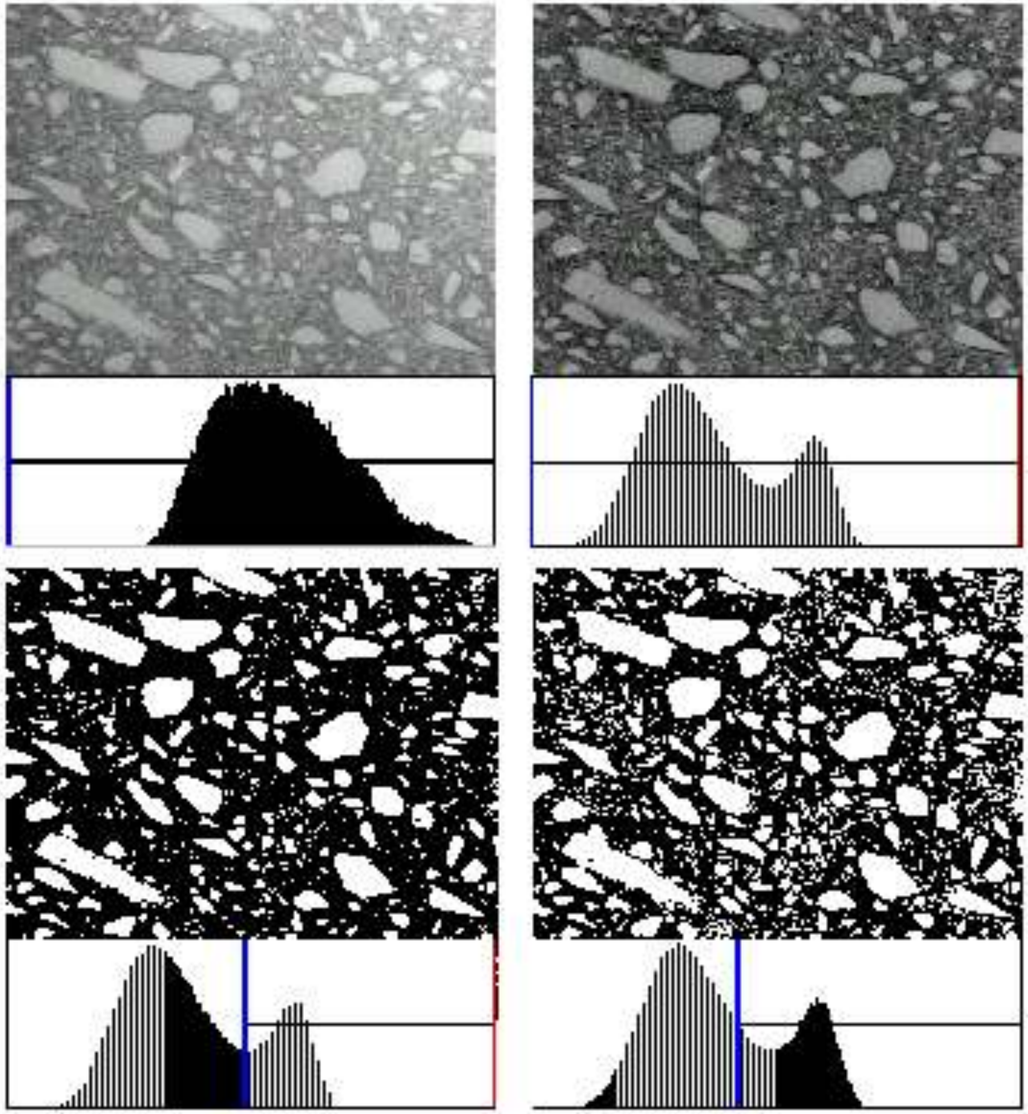

Imagem segmentada com limiar no mínimo

Imagem sementada pelo método de Otsu

# Otsu - Exemplos

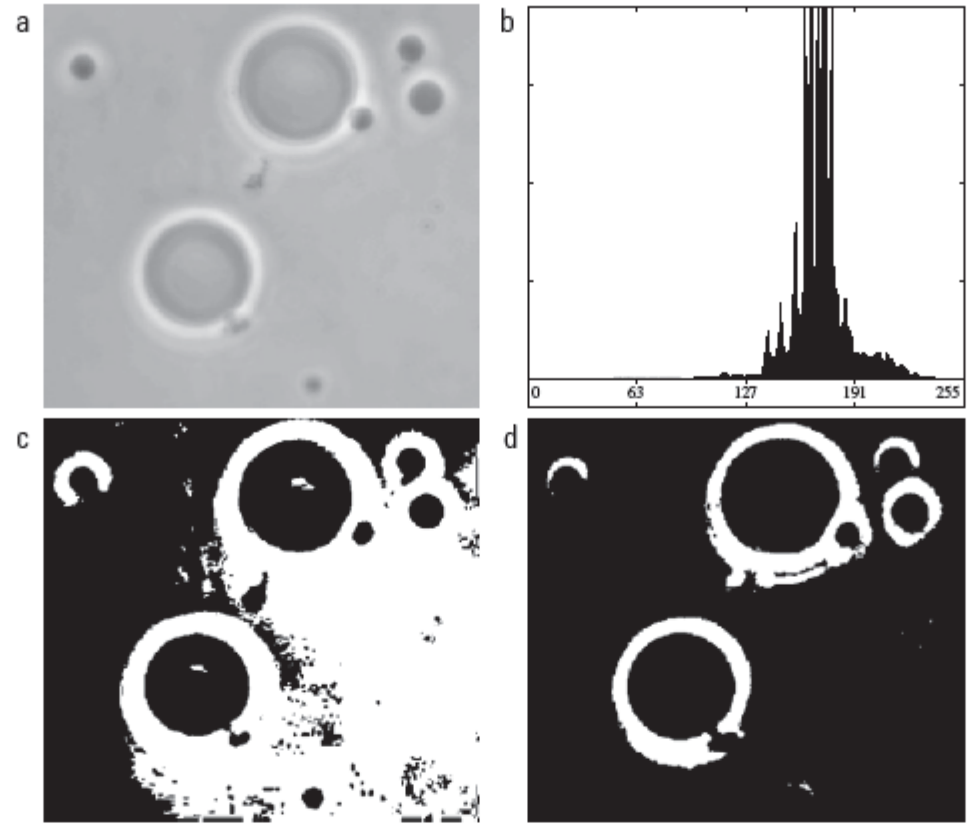


**Figura 10.39** (a) Imagem original. (b) Histograma (os picos elevados foram cortados para realçar os detalhes nos valores mais baixos). (c) Resultado da segmentação utilizando o algoritmo global básico da Seção 10.3.2. (d) Resultado obtido pelo método de Otsu. (Imagem original: cortesia do Professor Daniel A. Hammer, da Universidade da of Pennsylvania.)

# Otsu - Exemplos

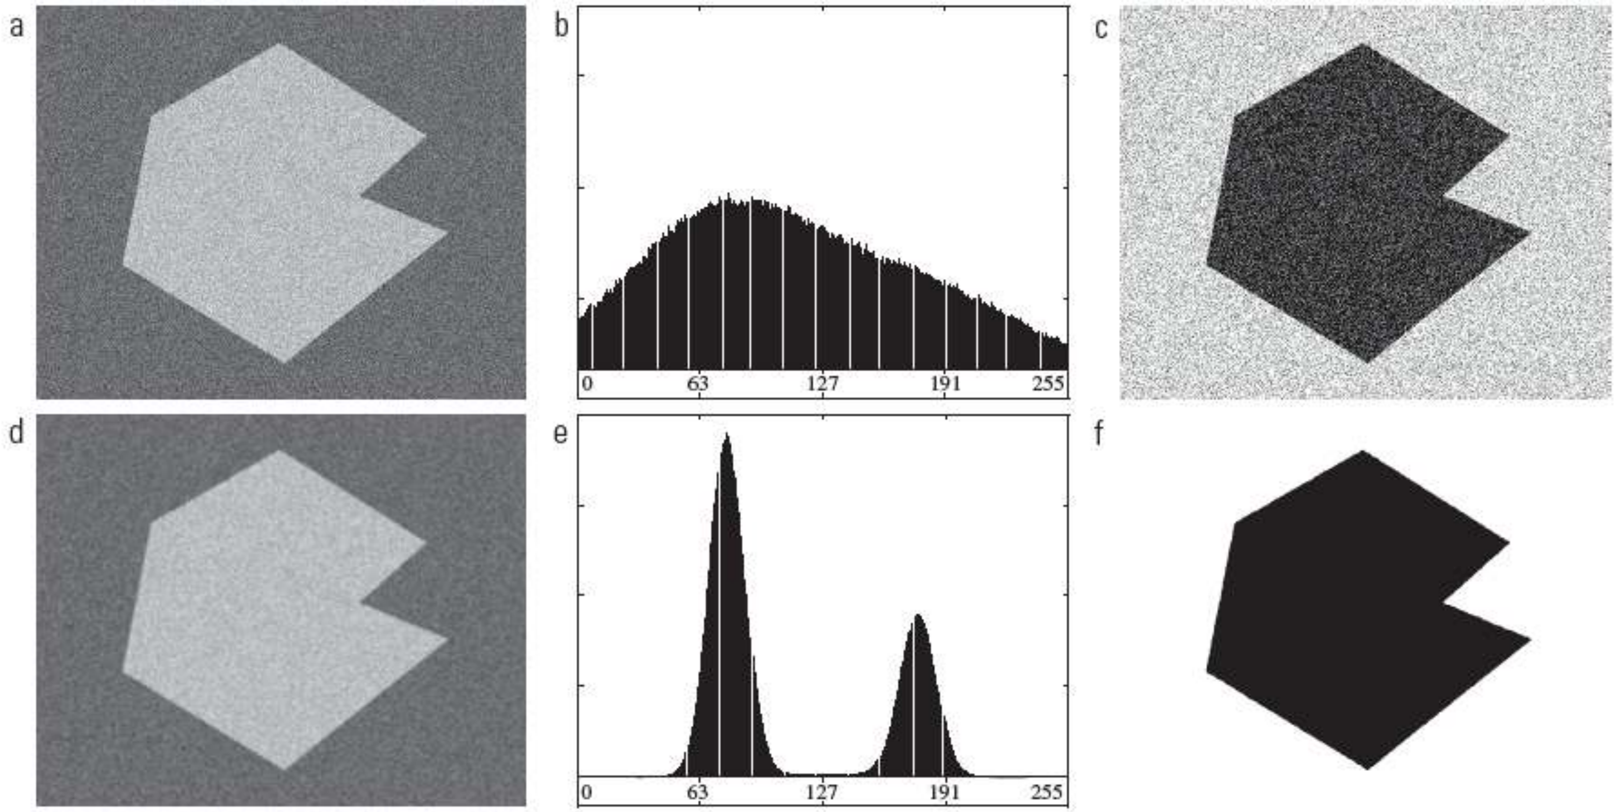


**Figura 10.40** (a) Imagem ruidosa da Figura 10.36 e (b) seu histograma. (c) Resultado obtido pelo método de Otsu. (d) Imagem ruidosa suavizada usando uma máscara de média de tamanho 5 × 5 e (e) seu histograma. (f) Resultado da limiarização pelo método de Otsu.

# Limiarização por médias móveis

- Calcular a média de uma janela (máscara)

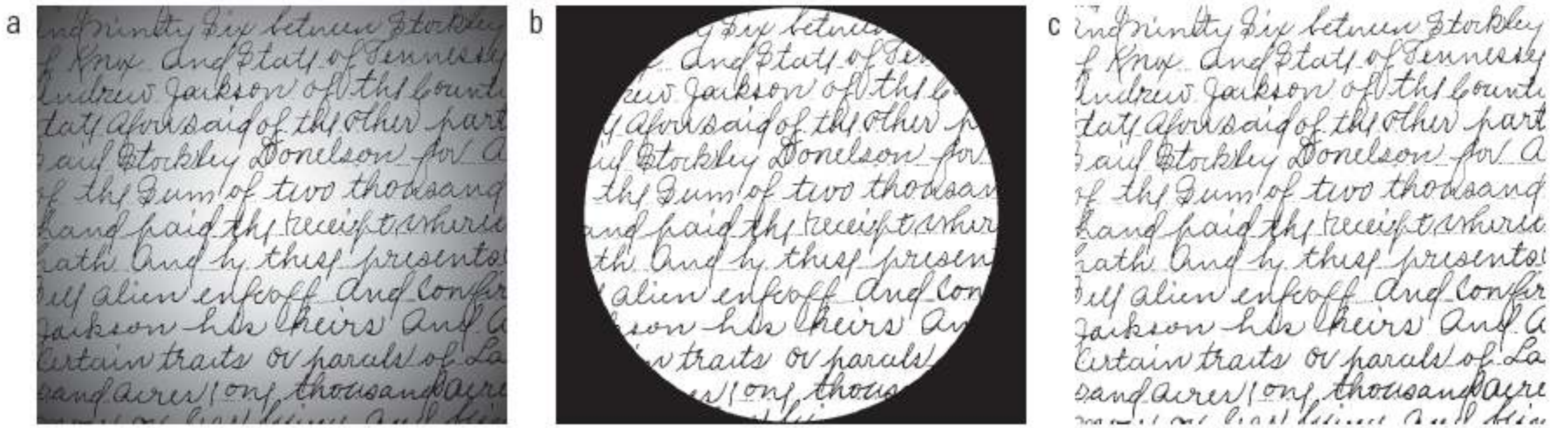

**Figura 10.49** (a) Imagem de texto corrompido por sombreamento pontual. (b) Resultado da limiarização global pelo método de Otsu. (c) Resultado da limiarização local usando médias móveis.

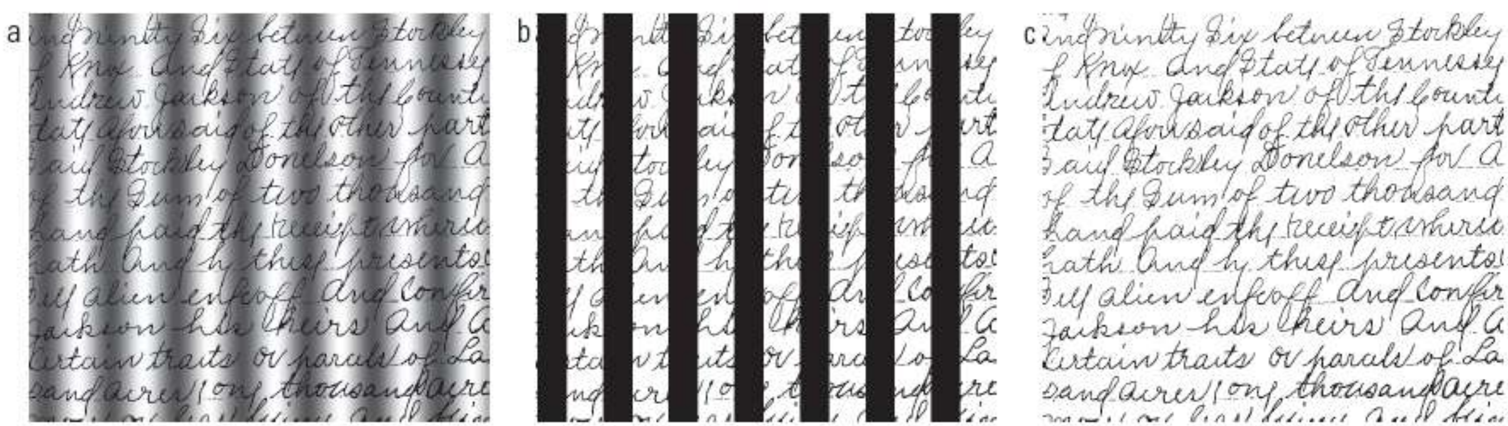

**Figura 10.50** (a) Imagem de texto corrompida pelo sombreamento senoidal. (b) Resultado da limiarização global pelo método de Otsu. (c) Resultado da limiarização local usando médias móveis.

# Gradiente - Canny

Segmentação de Imagens

# Gradiente - Canny

1. Presente na OpenCv e no Matlab
2. Link dos detalhes: [Download]

(a) Original

(b) Smoothed

(c) Gradient magnitudes

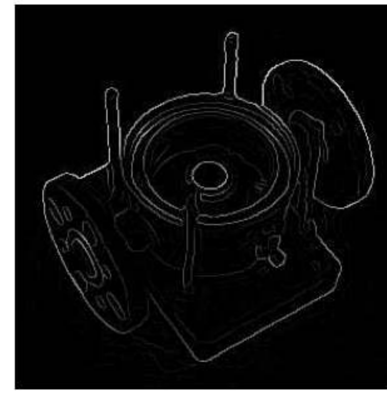

(d) Edges after non-maximum suppression

(e) Double thresholding

(f) Edge tracking by hysteresis

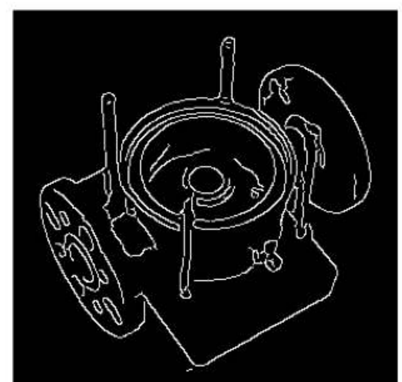

(g) Final output

# Crescimento de Regiões

Segmentação de Imagens

# Crescimento de Região

- Semente
- Regra de agregação

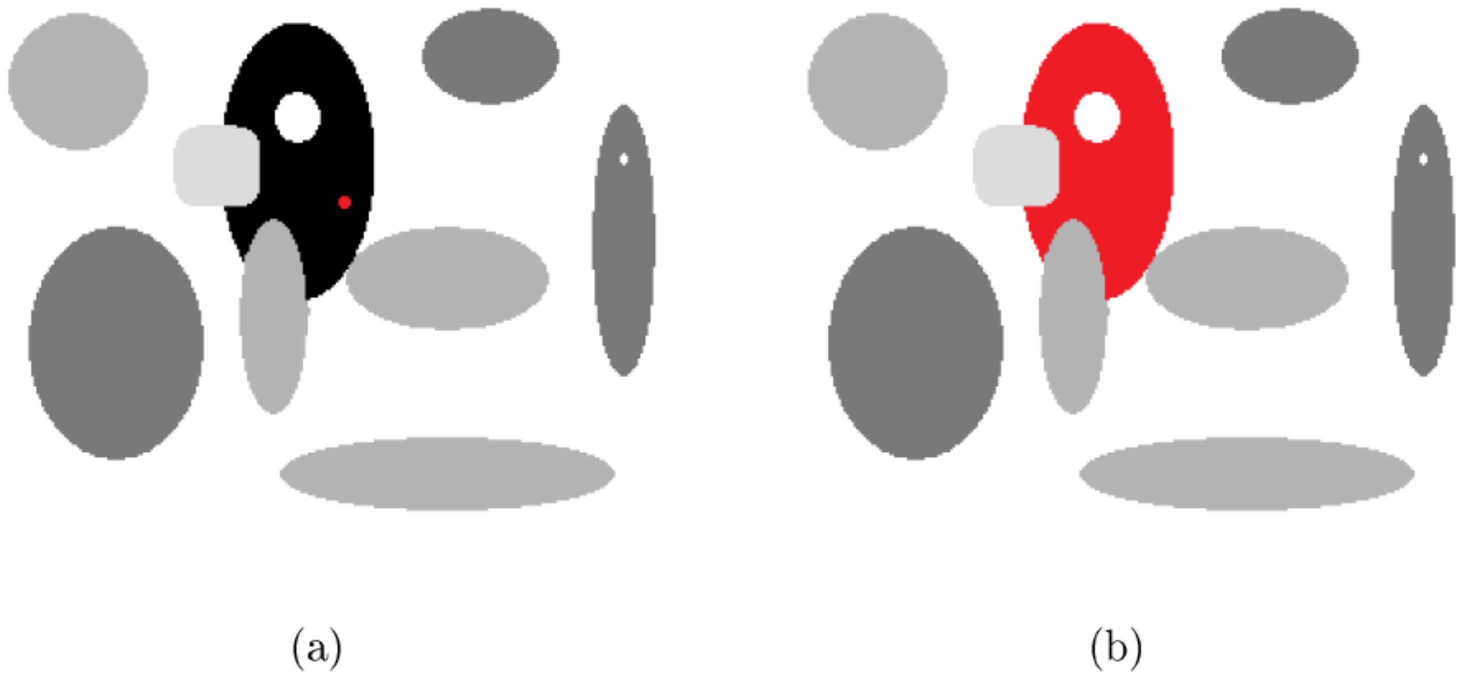


Figura 2.2: exemplo de aplicação da técnica de Crescimento de Região: a) imagem original com a semente em vermelho, b) resultado da segmentação em vermelho.

# Crescimento de Região

- Semente
- Regra de agregação

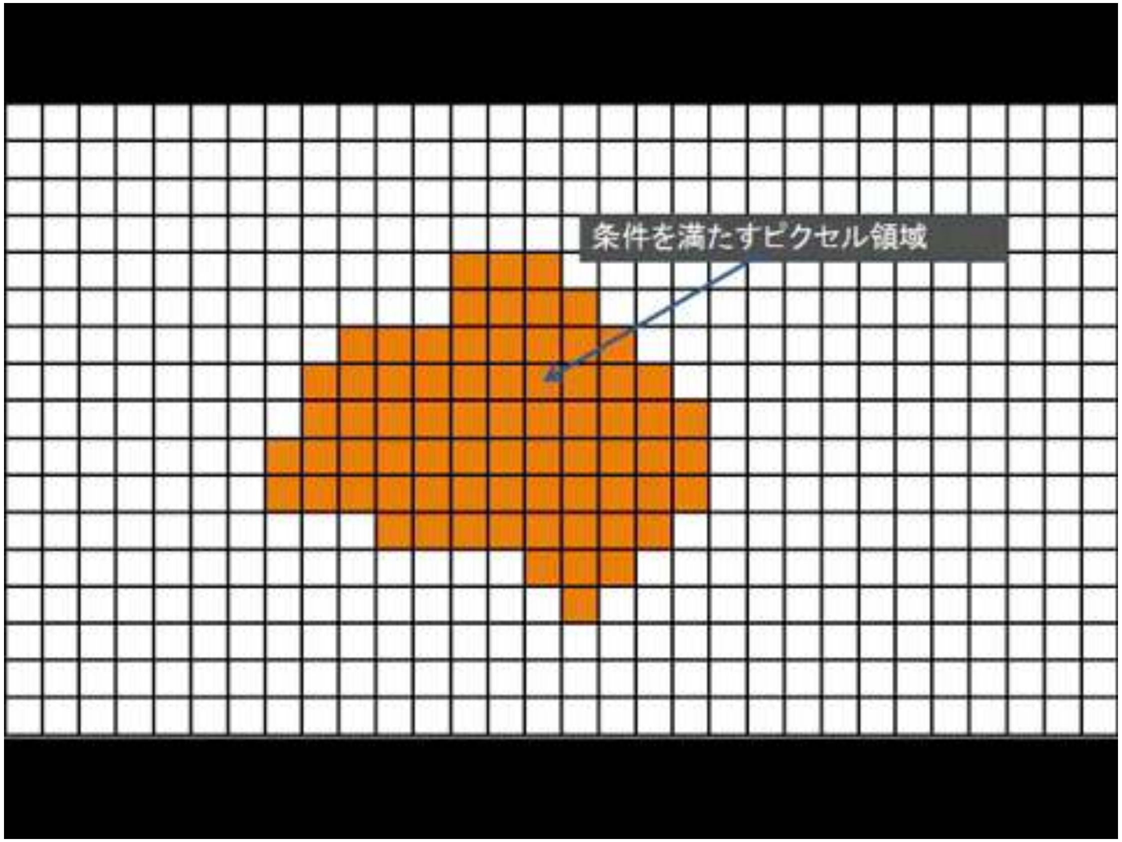


http://youtu.be/IjK774GwRGk

# Crescimento de Região 3D

- Expansão do 2D

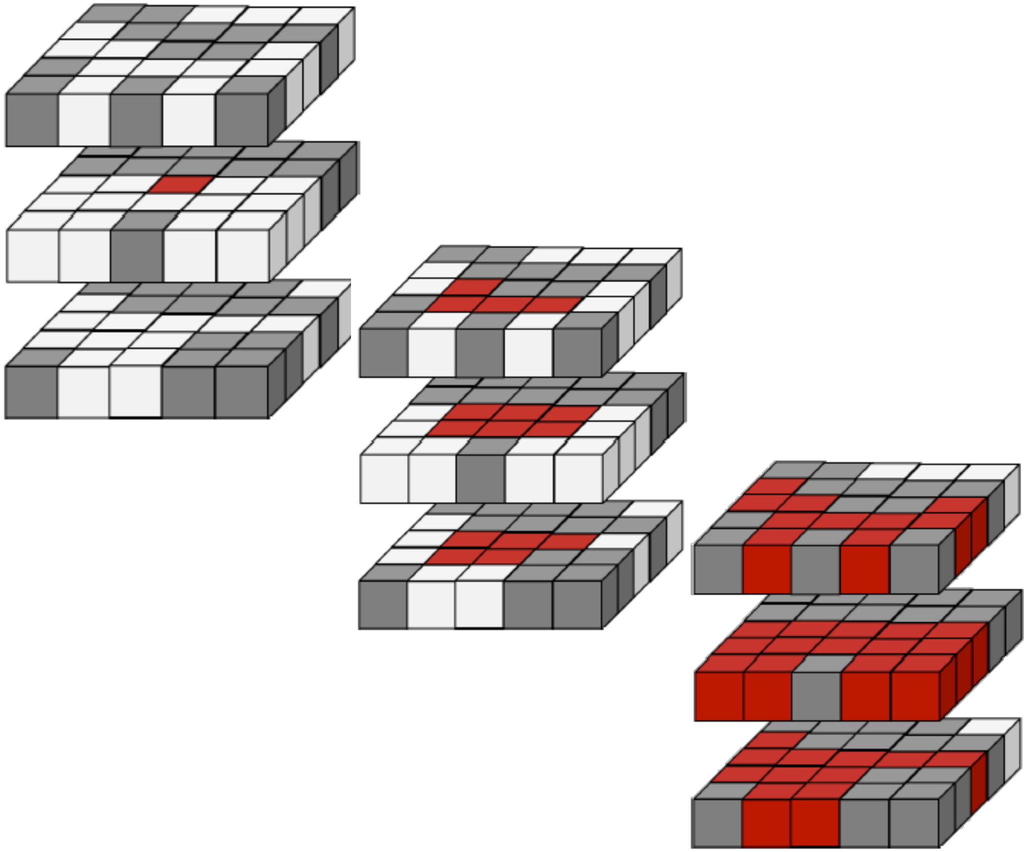

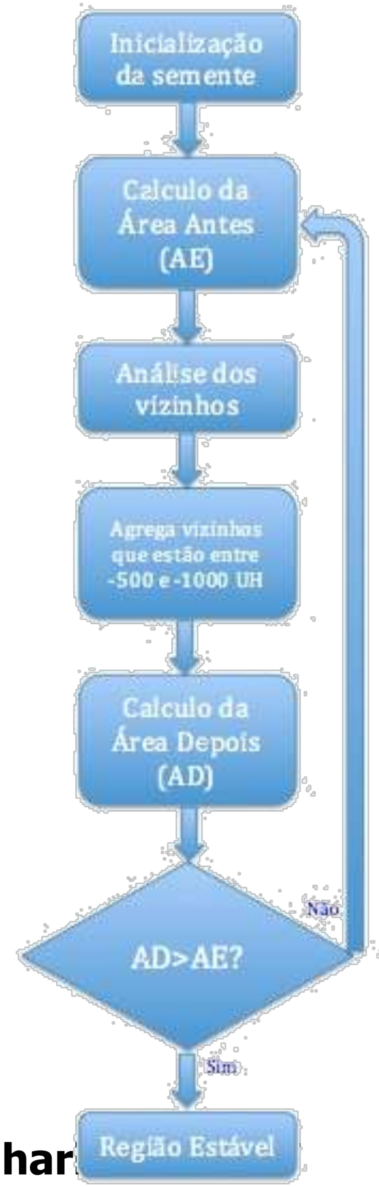

# Crescimento de Região 3D

- Exemplo – [Link do artigo ]

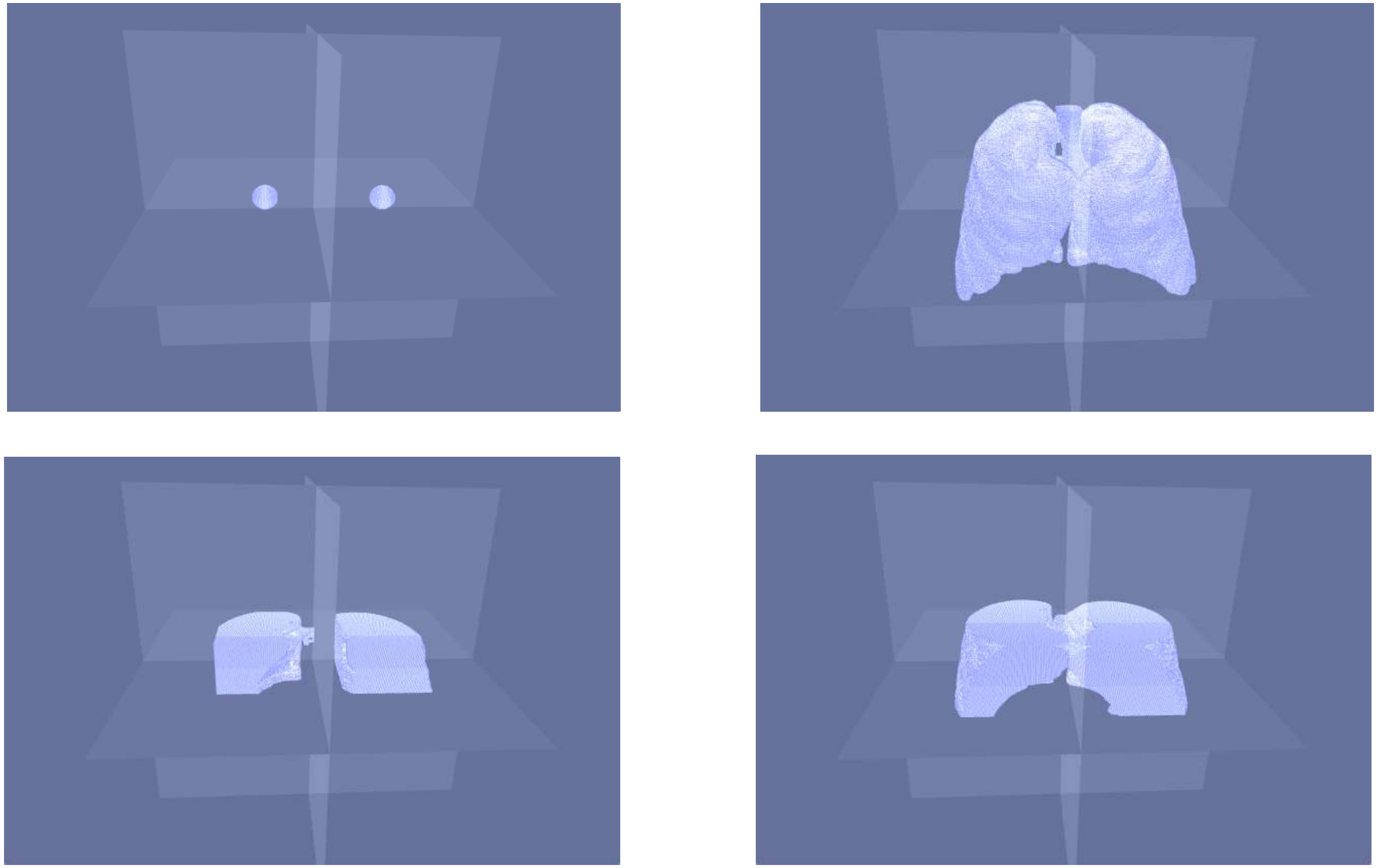

# Clusterização pelo método k-médias

Segmentação de Imagens

# K-means Clustering Segmentation

- Dado um Conjunto de n pontos no espaço d-dimensional em um inteiro k

- Queremos encontrar um conjunto de k pontos no espaço d-dimensional que minimiza a distância media quadrática de cada ponto para seu centro mais próximo.

- Não existe algoritmo polinomial para esse problema

"A Local Search Approximation Algorithm for k-Means Clustering" by Kanungo et. al

# K-means Algorithm

- O KM converge para uma solução local ótima.

- Mas pode convergir para uma solução arbitrária ruim

- Por que ?

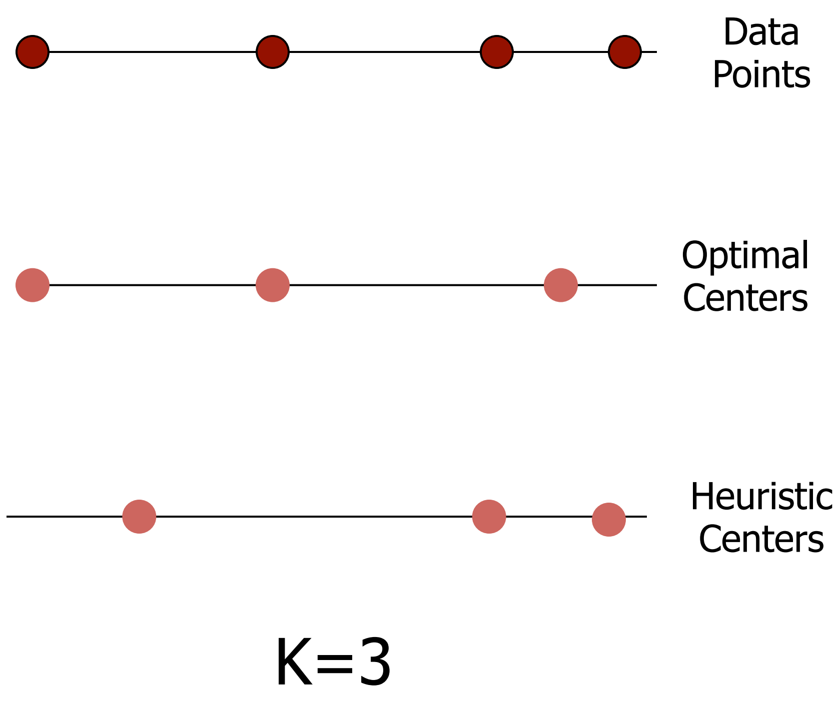

# K-means Clustering Segmentation

- **Definição formal**

Seja $X = \{x_1, x_2, x_3, \ldots, x_n\}$ um conjunto de dados e $C = \{c_1, c_2, c_3, \ldots, c_k\}$ para $k \ll n$, um conjunto de *clusters*, onde cada elemento $x_i$ pode pertencer a somente um elemento $c_i$. O K-Means é um método iterativo que agrupa os $n$ elementos de $X$ pelos $k$ *clusters* de $C$.

$$J(C) = \sum_{k=1}^{K} \sum_{x_i \in c_k} ||x_i - \mu_k||^2$$

# K-means Algorithm

1 – Escolha k pontos iniciais aleatoriamente

2 – Clusterize os dados usando uma distância qualquer (a mais usada é a distância euclidiana)

3 – Compute novos centros para cada cluster usando apenas pontos dentro de cada cluster

4 – Re-compute todos os dados usando os novos centros

(esse passo pode provocar mudança de cluster de um ponto)

5 – Repita os passos 3 e 4 até que nenhum ponto no passo quatro tenha mudado de cluster ou outro critério de convergência.

From “Data Analysis Tools for DNA Microarrays” by Sorin Draghici

# Exemplo para k=2

1. Escolha k=2

2. Clusterize os pontos em torno de K=2 controides

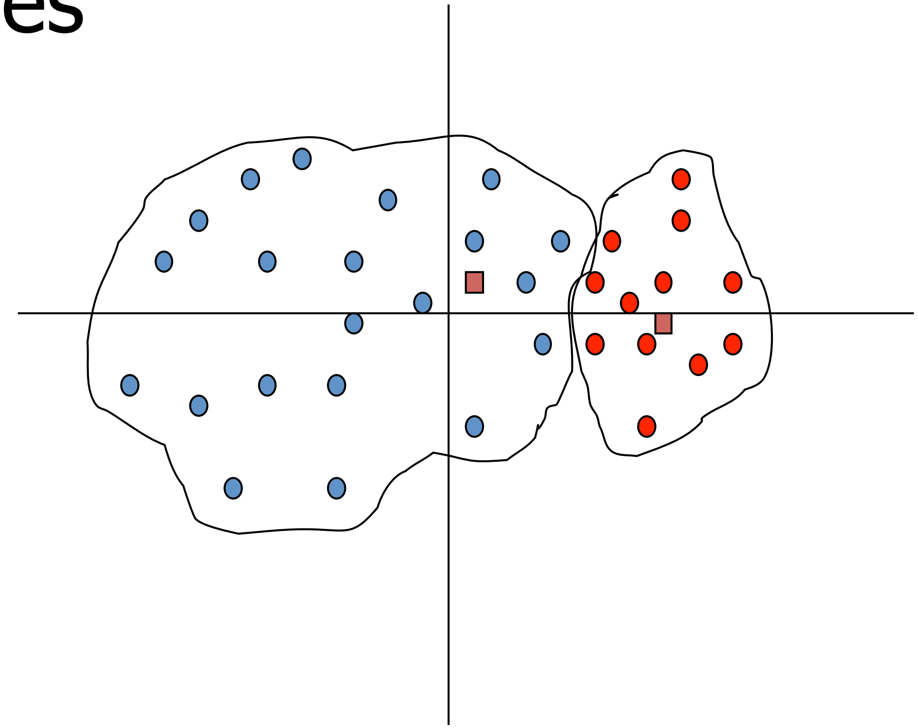

# K-means para k=2

3. Recalcule os centroides

4. Redistribua os pontos ao pelos dois clusters, considerando os novos centroides

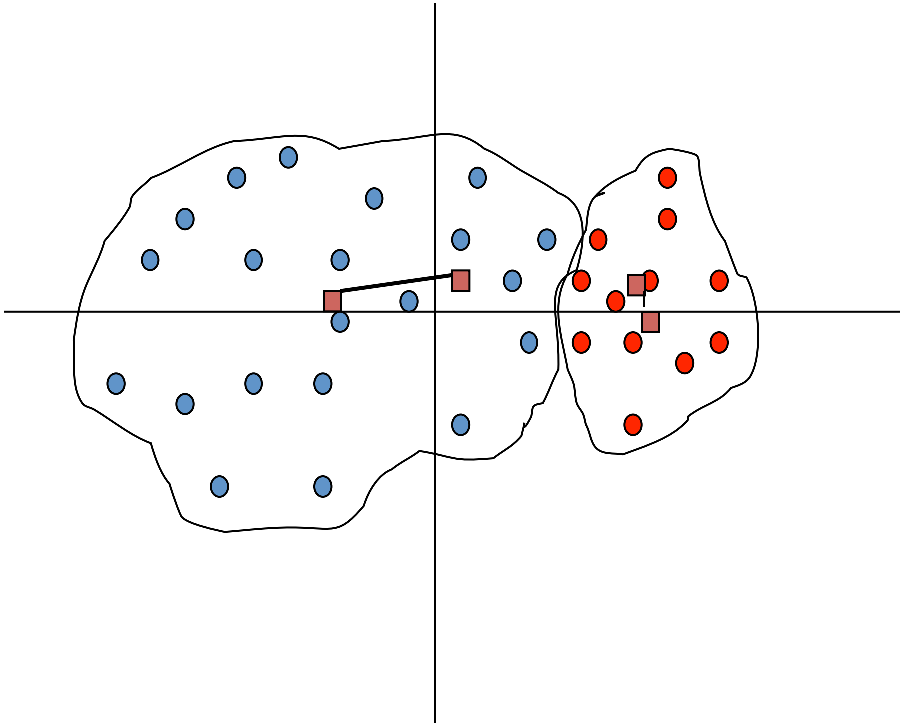

# K-means para k=2

3. Recalcule os centroides

4. Redistribua os pontos ao pelos dois clusters, considerando os novos centroides

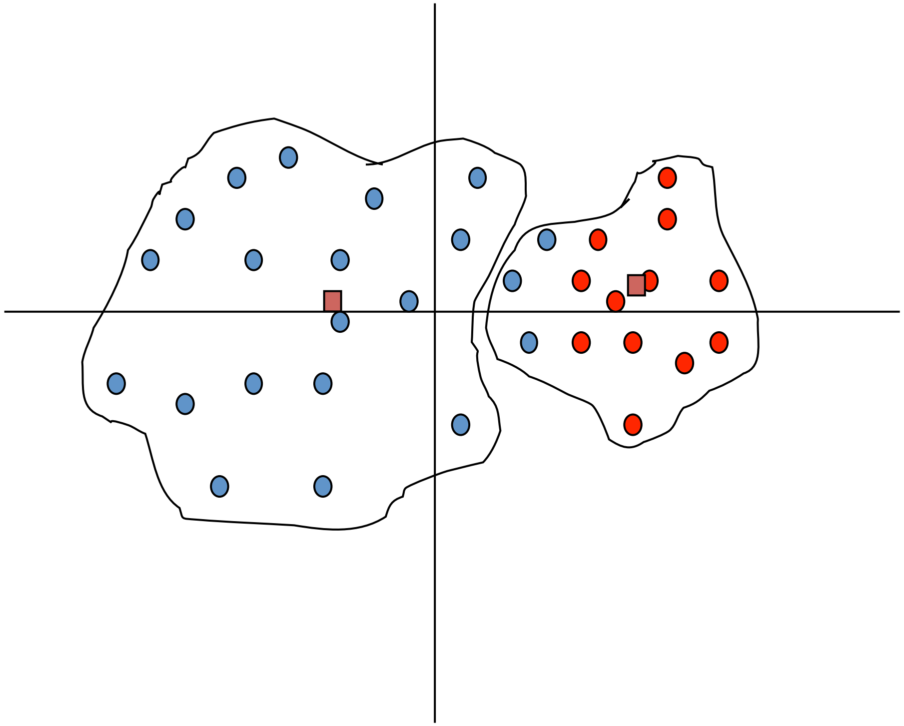

# K-means para k=2

5. Repita os dois ultimos passos até que nenhum ponto mude de cluster

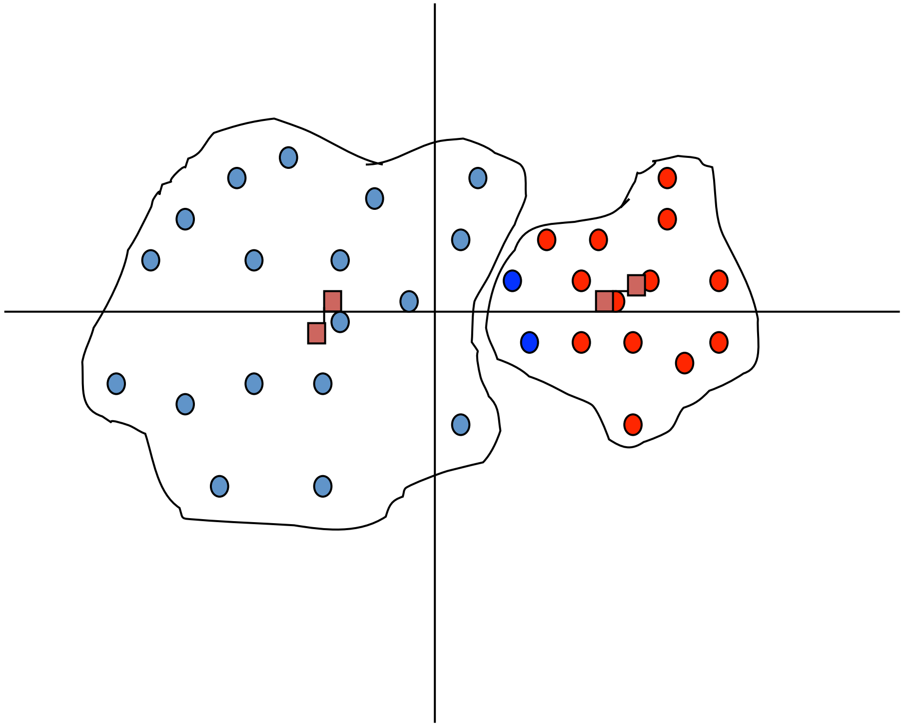

# Características do k-means

- Selecionar aleatoriamente os pontos na fase inicial gera as seguinte propriedades

  – Não-Determinismo
  – Pode produzir clusters vazios
    - Uma solução é escolher os centros aleatoriamente a partir de padrões conhecidos

From "Data Analysis Tools for DNA Microarrays" by Sorin Draghici

# Exemplos

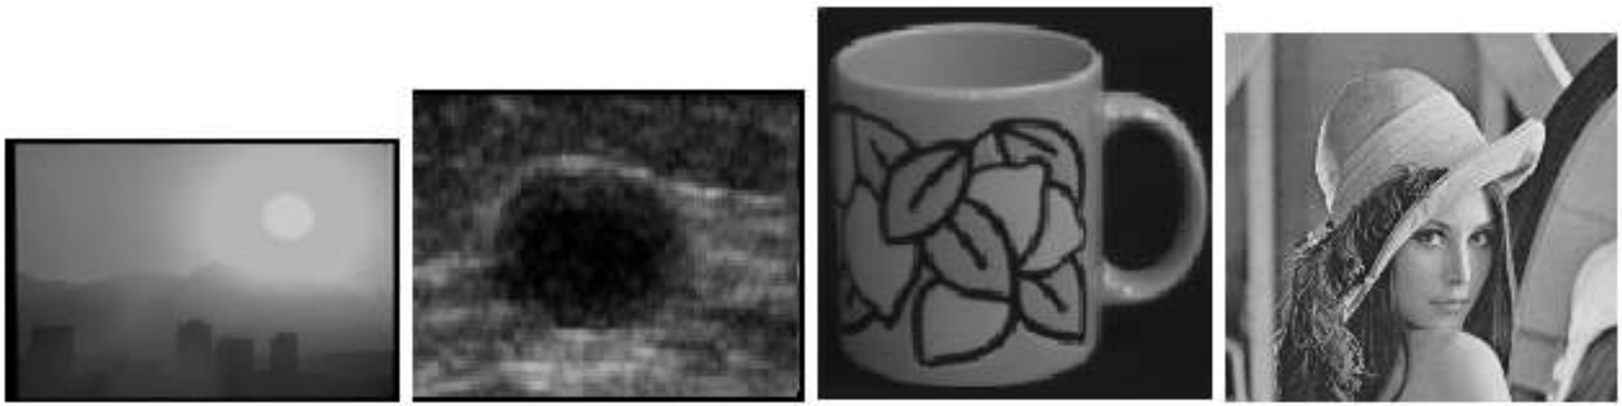

(a) sunset (b) breast tumor (c) simple object (d) lenna

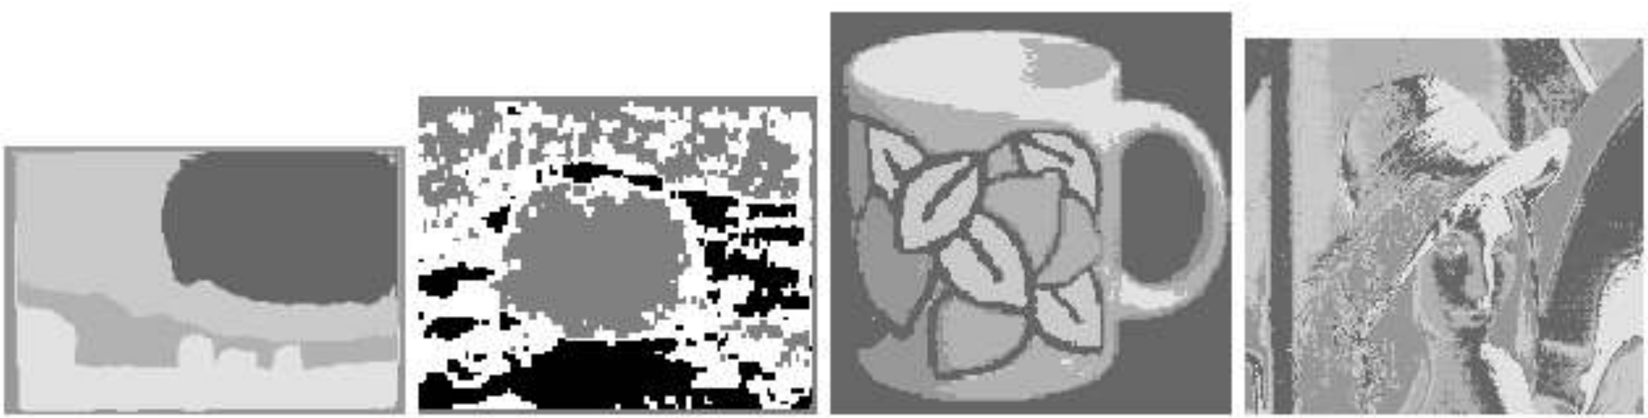

# Segmentação por descontinuidade

# Detecção de pontos, linhas e bordas

## Segmentação por descontinuidade

# Segmentação por descontinuidade

- Detecção de pontos, linhas e bordas.
- O resultado *R da detecção de cada um destes pode ser obtido* por

$$R = M_{3\times 3} * I_{l\times c},$$

em que

$$M = \begin{bmatrix} w_1 & w_2 & w_3 \\ w_4 & w_5 & w_6 \\ w_7 & w_8 & w_9 \end{bmatrix}$$

# Segmentação por descontinuidade

- Pontos

$$M = \begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$$

- Linhas

$$H = \begin{bmatrix} -1 & -1 & -1 \\ 2 & 2 & 2 \\ -1 & -1 & -1 \end{bmatrix}, \quad V = \begin{bmatrix} -1 & 2 & -1 \\ -1 & 2 & -1 \\ -1 & 2 & -1 \end{bmatrix},$$

$$D_1 = \begin{bmatrix} -1 & -1 & 2 \\ -1 & 2 & -1 \\ 2 & -1 & -1 \end{bmatrix}, \quad D_2 = \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}$$

# Segmentação por descontinuidade

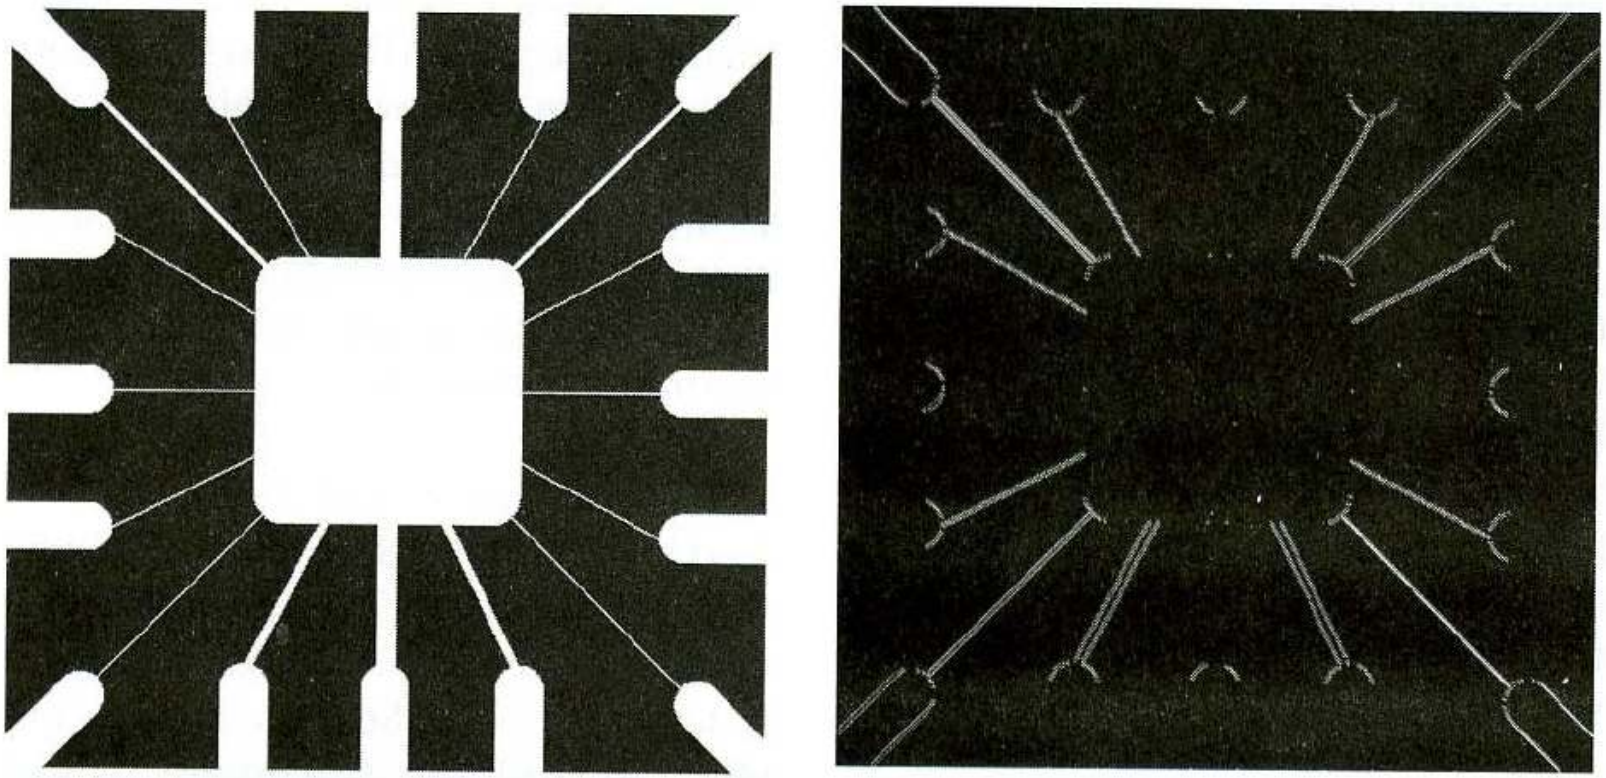

(a) (b)

Figura 2.3: exemplo de detecção de linhas: a) imagem original e b) resultado da detecção de linhas na diagonal (GONZALEZ; WOODS, 2008).

# Segmentação por descontinuidade

- Detecção de bordas
  - Roberts

$$g(x,y) \cong \sqrt{({r_1}^2 + {r_2}^2)} \qquad r_1 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}; r_2 = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$$

  - Prewwit

$$g(x,y) \cong \sqrt{({p_1}^2 + {p_2}^2)} \qquad p_1 = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix}; p_2 = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$

# Segmentação por descontinuidade

- Detecção de bordas
  - Sobel

$$g(x,y) \cong \sqrt{({s_1}^2 + {s_2}^2)} \qquad s_1 = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}; s_2 = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

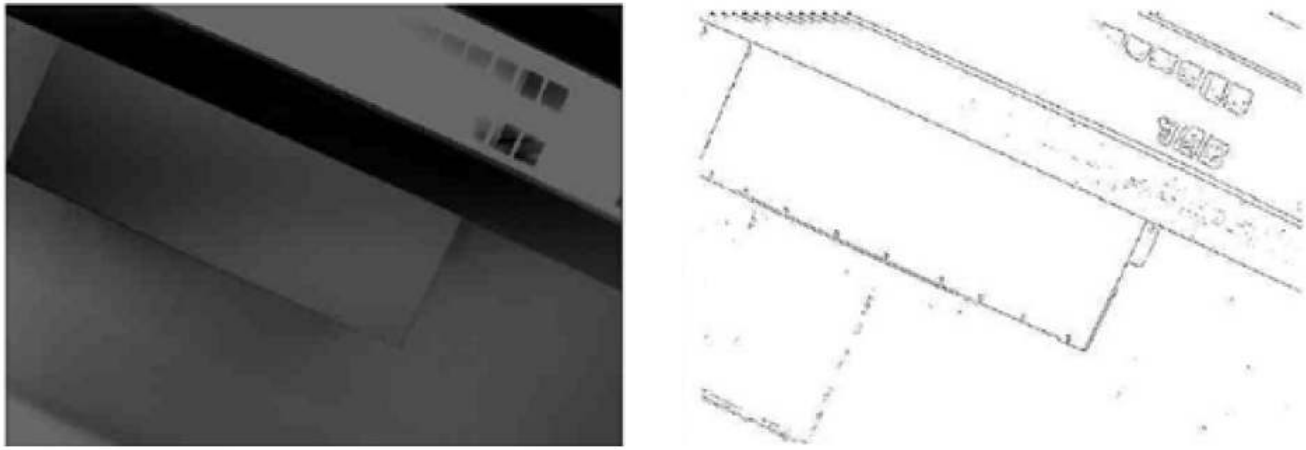

(a) (b)

Figura 2.4: exemplo de aplicação do operador Sobel: a) imagem original e b) resultado do operador Sobel (SIEGWART; NOURBAKHSH, 2004).

# Transformada de Hough

Segmentação por descontinuidade

# Transformada de Hough

- encontrar formas em imagens
  - ex. retas, círculos e elipses (seções cônicas)

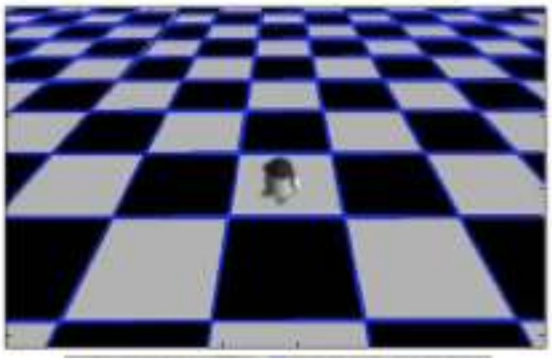

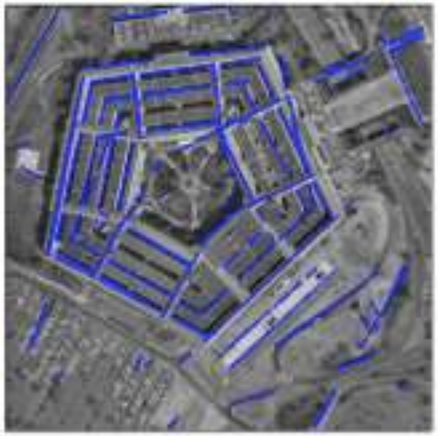

# Transformada de Hough - retas

- Definição

$$y = mx + c$$

- Forma Homôgenea

$$Ay + Bx + 1 = 0,$$

onde

$$A = -1/c \quad , B = m/c$$

- Os pontos colineares $(x_i, y_i)$ definem a reta (A, B):

$$Ay_i + Bx_i + 1 = 0$$

- repare que esta equação tem um caráter dual
  - podemos procurar os pontos (xi , yi ) que pertencem a reta (A, B), ou
  - podemos procurar a reta (A,B) que passa pelos pontos (x,y)

# Transformada de Hough - retas

## Espaço dual

- pontos são transformados em retas, e vice-versa
- todos pontos colineares em uma imagem, definem o pontos de interseção (A,B) no espaço dual
- transformada de Hough
  - encontra a reta (A,B) rastreando o acumulo das evidências

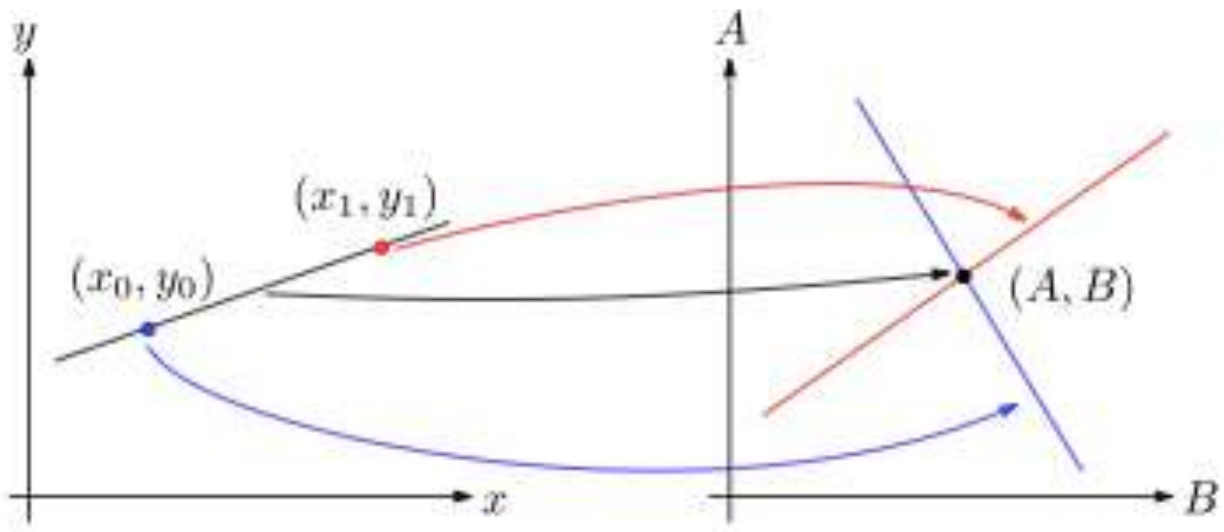

# Transformada de Hough - retas

## Votação

- Cada ponto (xi,yi) forma uma reta Ui no espaço dual
- Cada reta Ui vota em todos pontos pelos quais ela passa
- pontos que obtém muitos votos no espaço dual, são os candidatos para serem retas na imagem

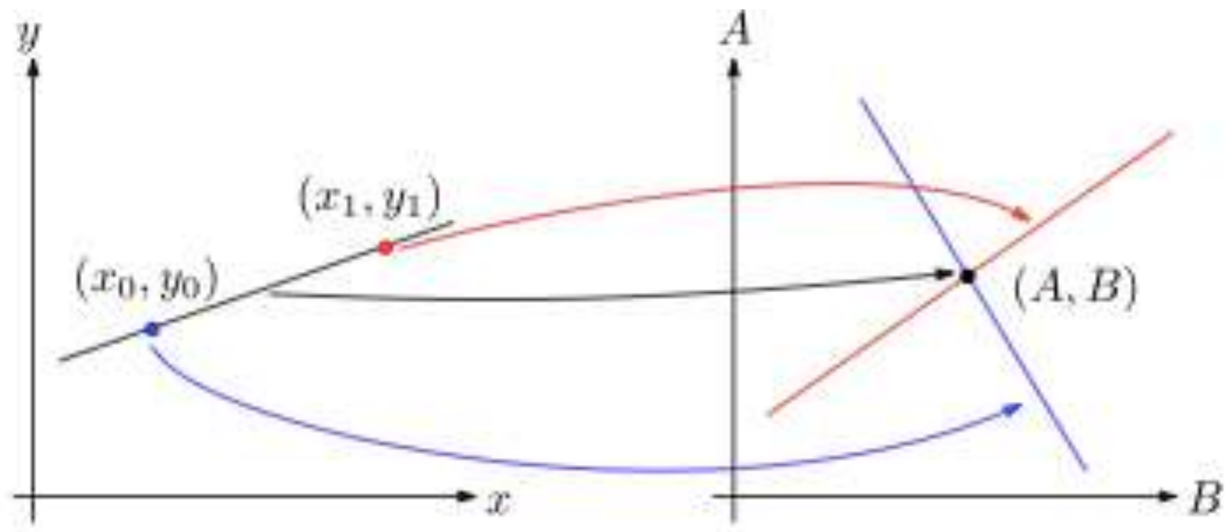

# Transformada de Hough - retas

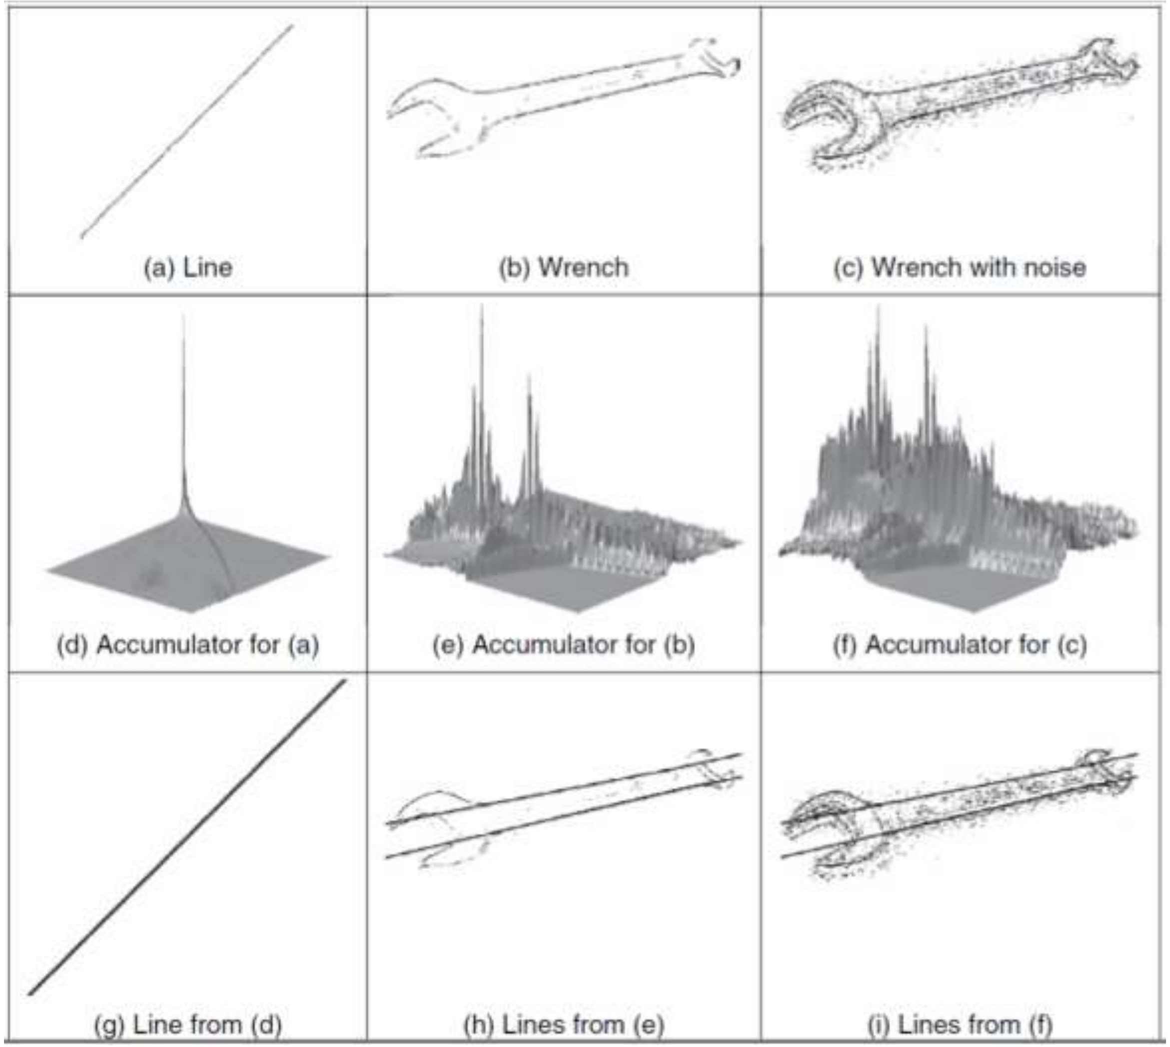

# Transformada de Hough - retas

## Transf. Hough polar para retas

- valores limitados para os parâmetros

$$r = x\cos(\theta) + y\sin(\theta)$$

- $\theta \in [0, \pi]$ e $r \in [0, \sqrt{2}N]$

- podemos passar de uma parametrização à outra:

$$m = \frac{-1}{\tan\theta}$$

$$c = \frac{r}{\sin\theta}$$

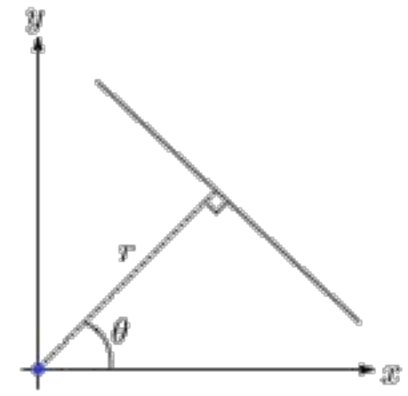


- exemplo: quando temos $m = -1$ e $c = 1$ temos $r = \frac{\sqrt{2}}{2}$ e $\theta = \frac{\pi}{4}$

- os pontos são mapeados em senoidais
- a interseção das curvas marca as prováveis retas

# Transformada de Hough - retas

## Transf. Hough polar para retas

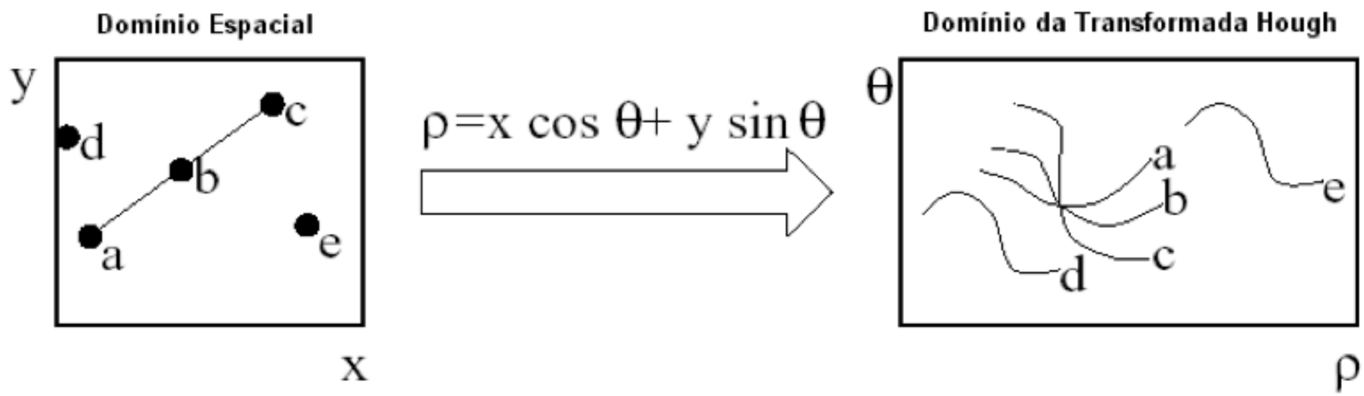


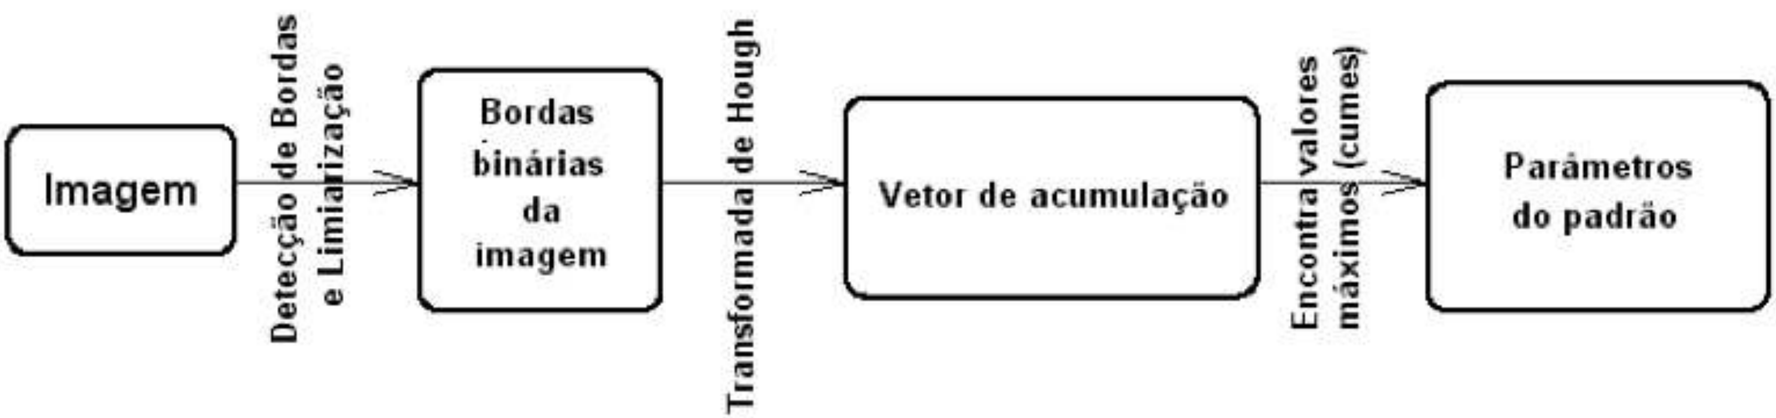

# Transformada de Hough - retas

## Transf. Hough polar para retas

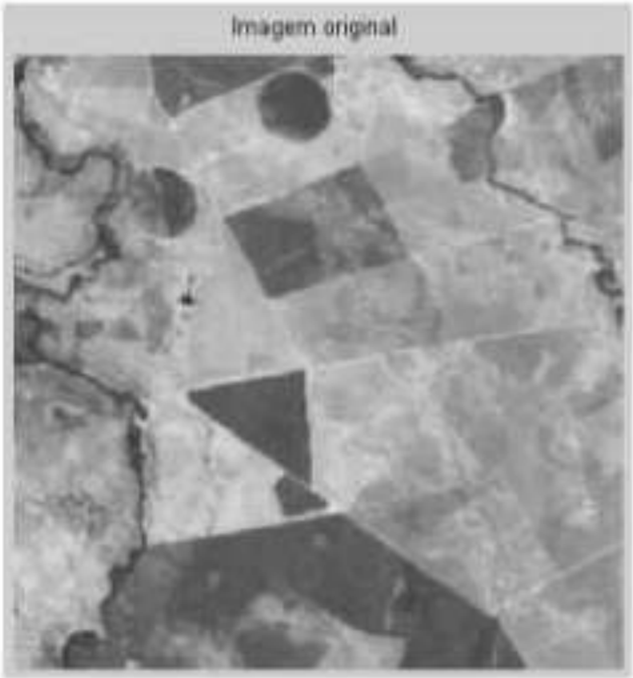


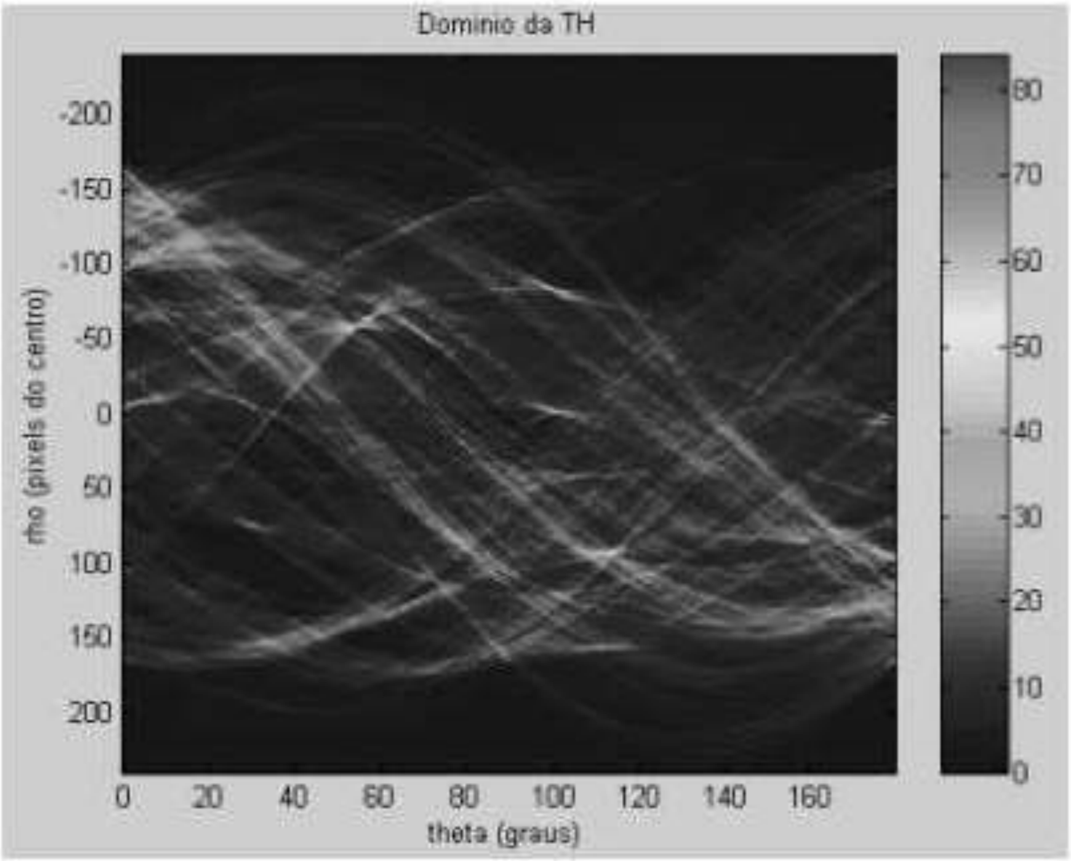

# Transformada de Hough - retas

**Transf. Hough polar para retas**

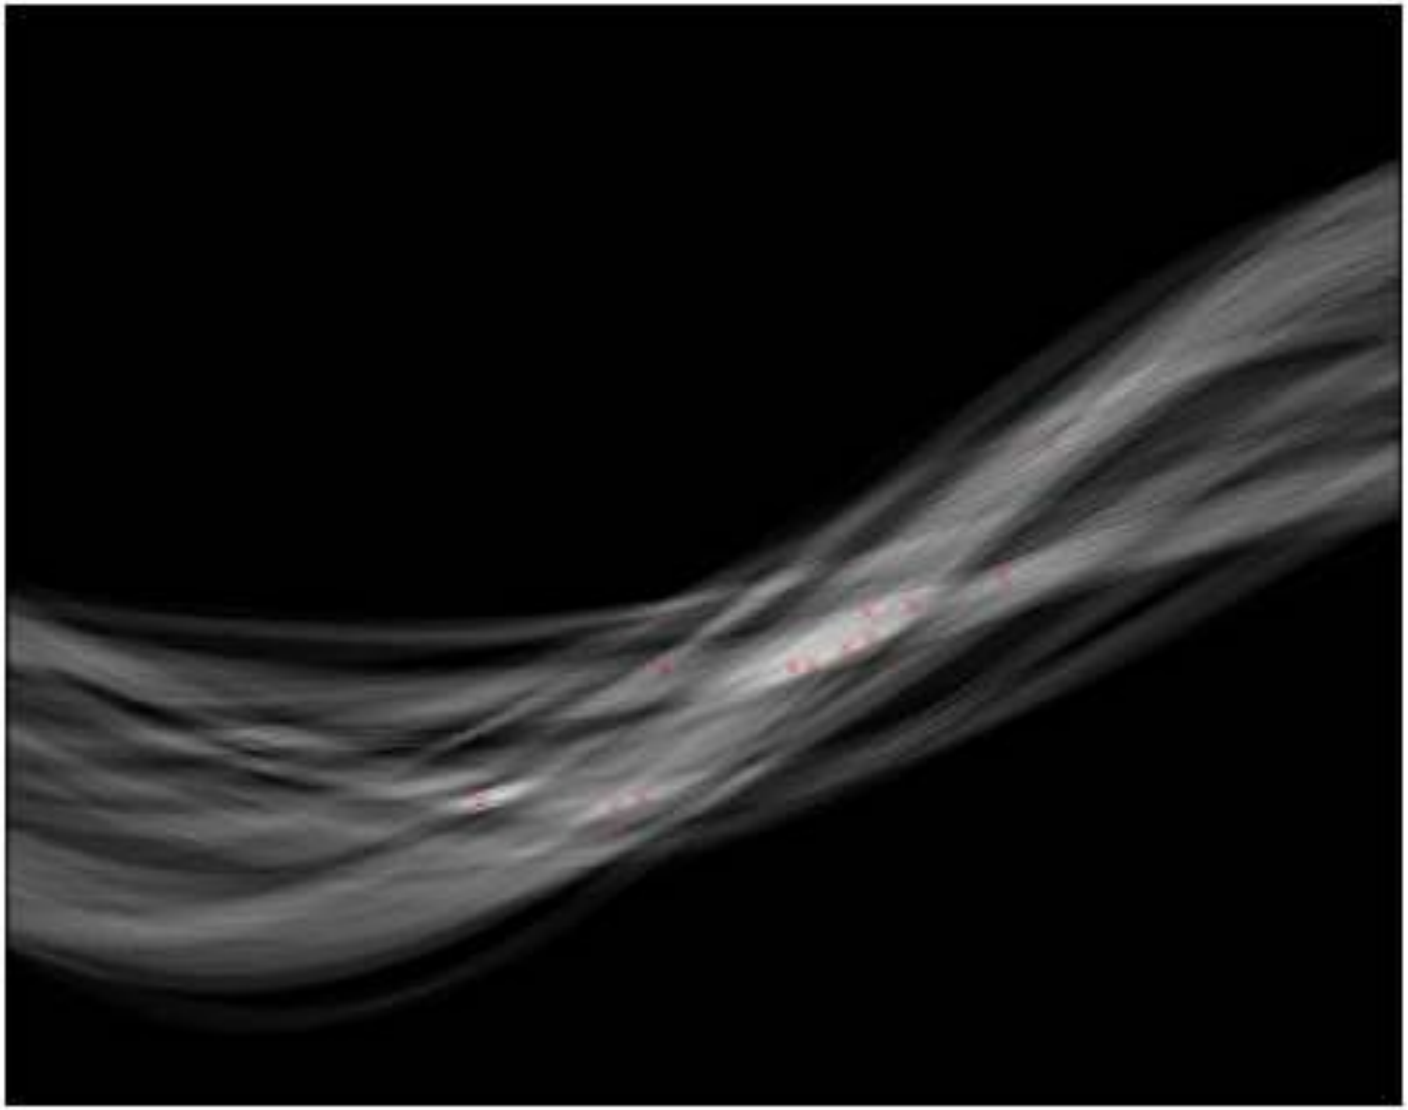

# Transformada de Hough - círculos

- forma paramétrica

$$(x-a)^2+(y-b)^2=r^2$$

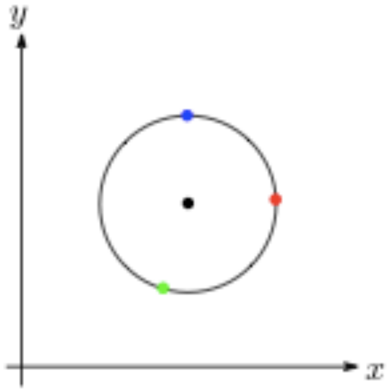


- três parâmetros $(a, b, r)$
- nosso espaço para votação agora está em 3D!
- cada ponto da imagem no espaço dual
  - gera um cone centrado no ponto
  - representa todos raios possíveis
- a votação em 3D encontra os círculos da imagem

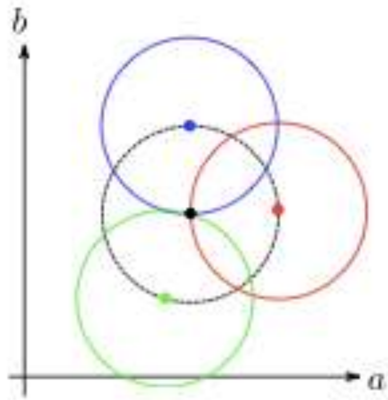


- todos círculos com raio $r$ no espaço dual intersectam no centro do círculo na imagem $(a, b)$

$$x=a+r\cos\theta, y=b+r\sin\theta$$

# Transformada de Hough círculos

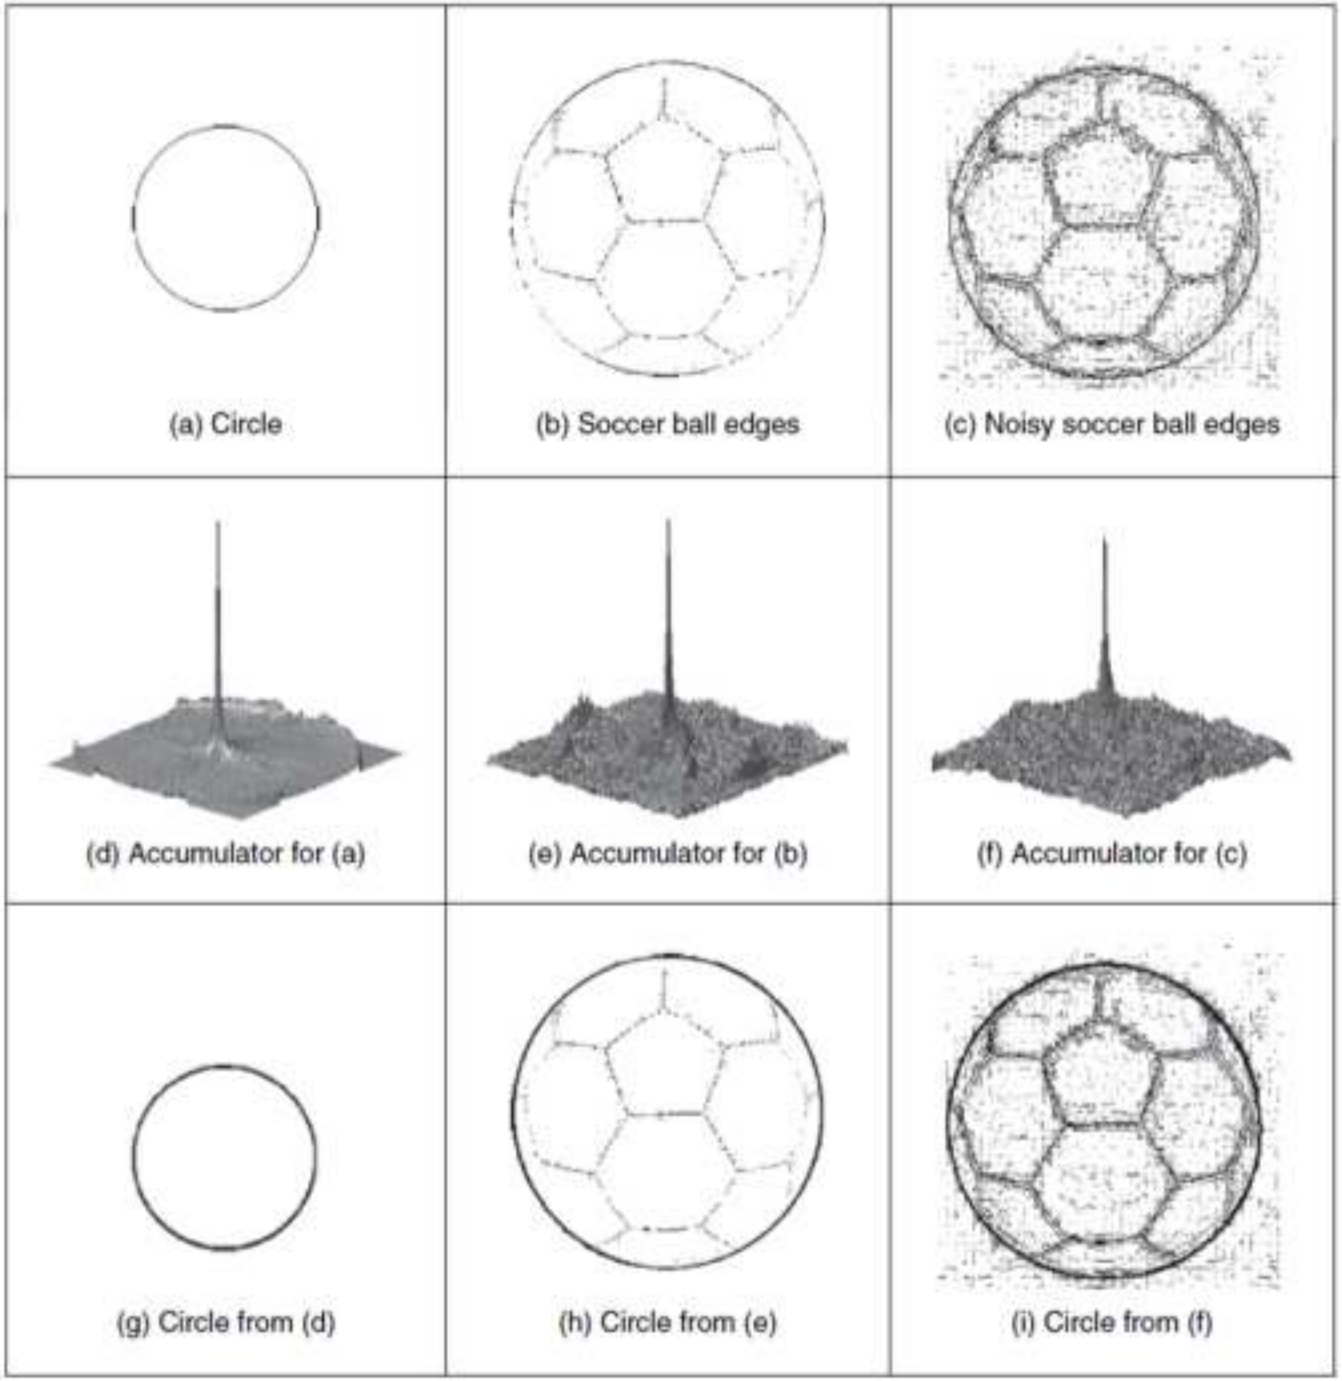

# Transformada de Hough

## **Material extra - exemplos**

### Matlab

https://www.dropbox.com/s/oiy0hrhzk9uutsq/Transformada_de_Hough_Matlab.pdf?dl=0

### OpenCv

https://www.dropbox.com/sh/c9eac0urmmtv9o9/AADXJFl-BRHr-MySIHIFdpxna?dl=0

# Watershed

## Segmentação por descontinuidade

# Watershed: O Divisor de Águas

1. Qualquer imagem Tom de Cinza pode ser considerado como uma superfície topográfica.
2. Se inundar esta superfície de seus mínimos e, se evitar a fusão das águas provenientes de diferentes fontes, nós dividimos a imagem em dois grupos diferentes:
   1. Bacias hidrográficas
   2. Linhas de bacias hidrográficas.
3. Se aplicarmos essa transformação ao gradiente de imagem, as bacias hidrográficas deve teoricamente correspondem às regiões de nível de cinza homogêneos desta imagem.

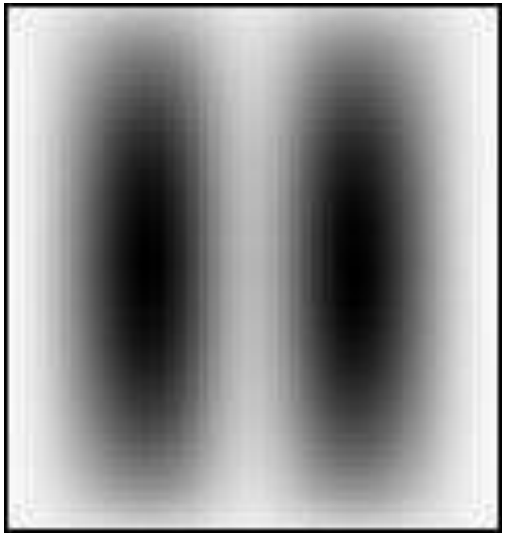

Imagem de gradientes

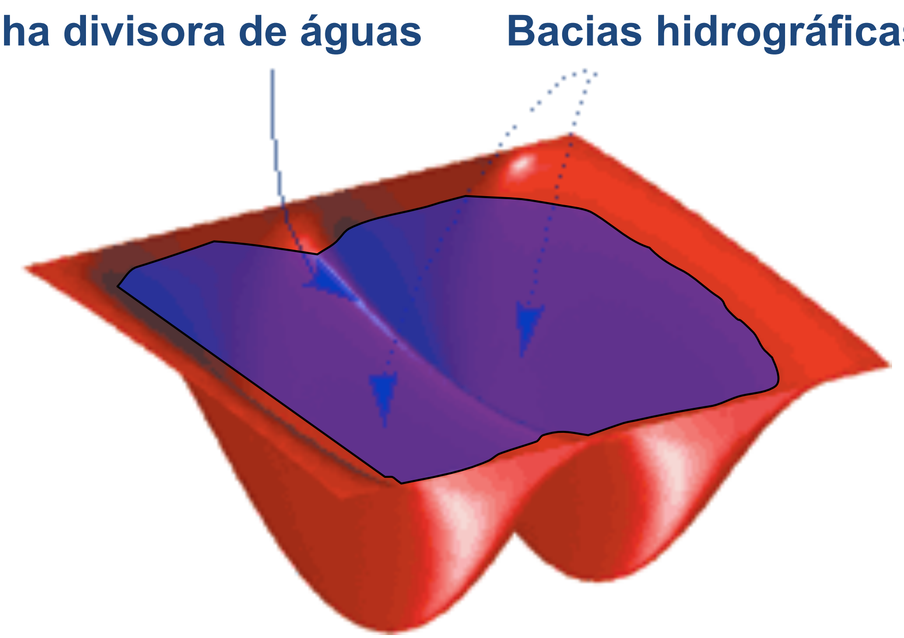

# Watershed: O Divisor de Águas

1. **Qualquer imagem Tom de Cinza pode ser considerado como uma superfície topográfica.**
2. **Se inundar esta superfície de seus mínimos e, se evitar a fusão das águas provenientes de diferentes fontes, nós dividimos a imagem em dois grupos diferentes:**
   1. **Bacias hidrográficas**
   2. **Linhas de bacias hidrográficas.**
3. **Se aplicarmos essa transformação ao gradiente de imagem, as bacias hidrográficas deve teoricamente correspondem às regiões de nível de cinza homogêneos desta imagem.**

# Watershed: Exemplo

- Passo 1: Temos uma imagem qualquer em tom de cinza de entrada

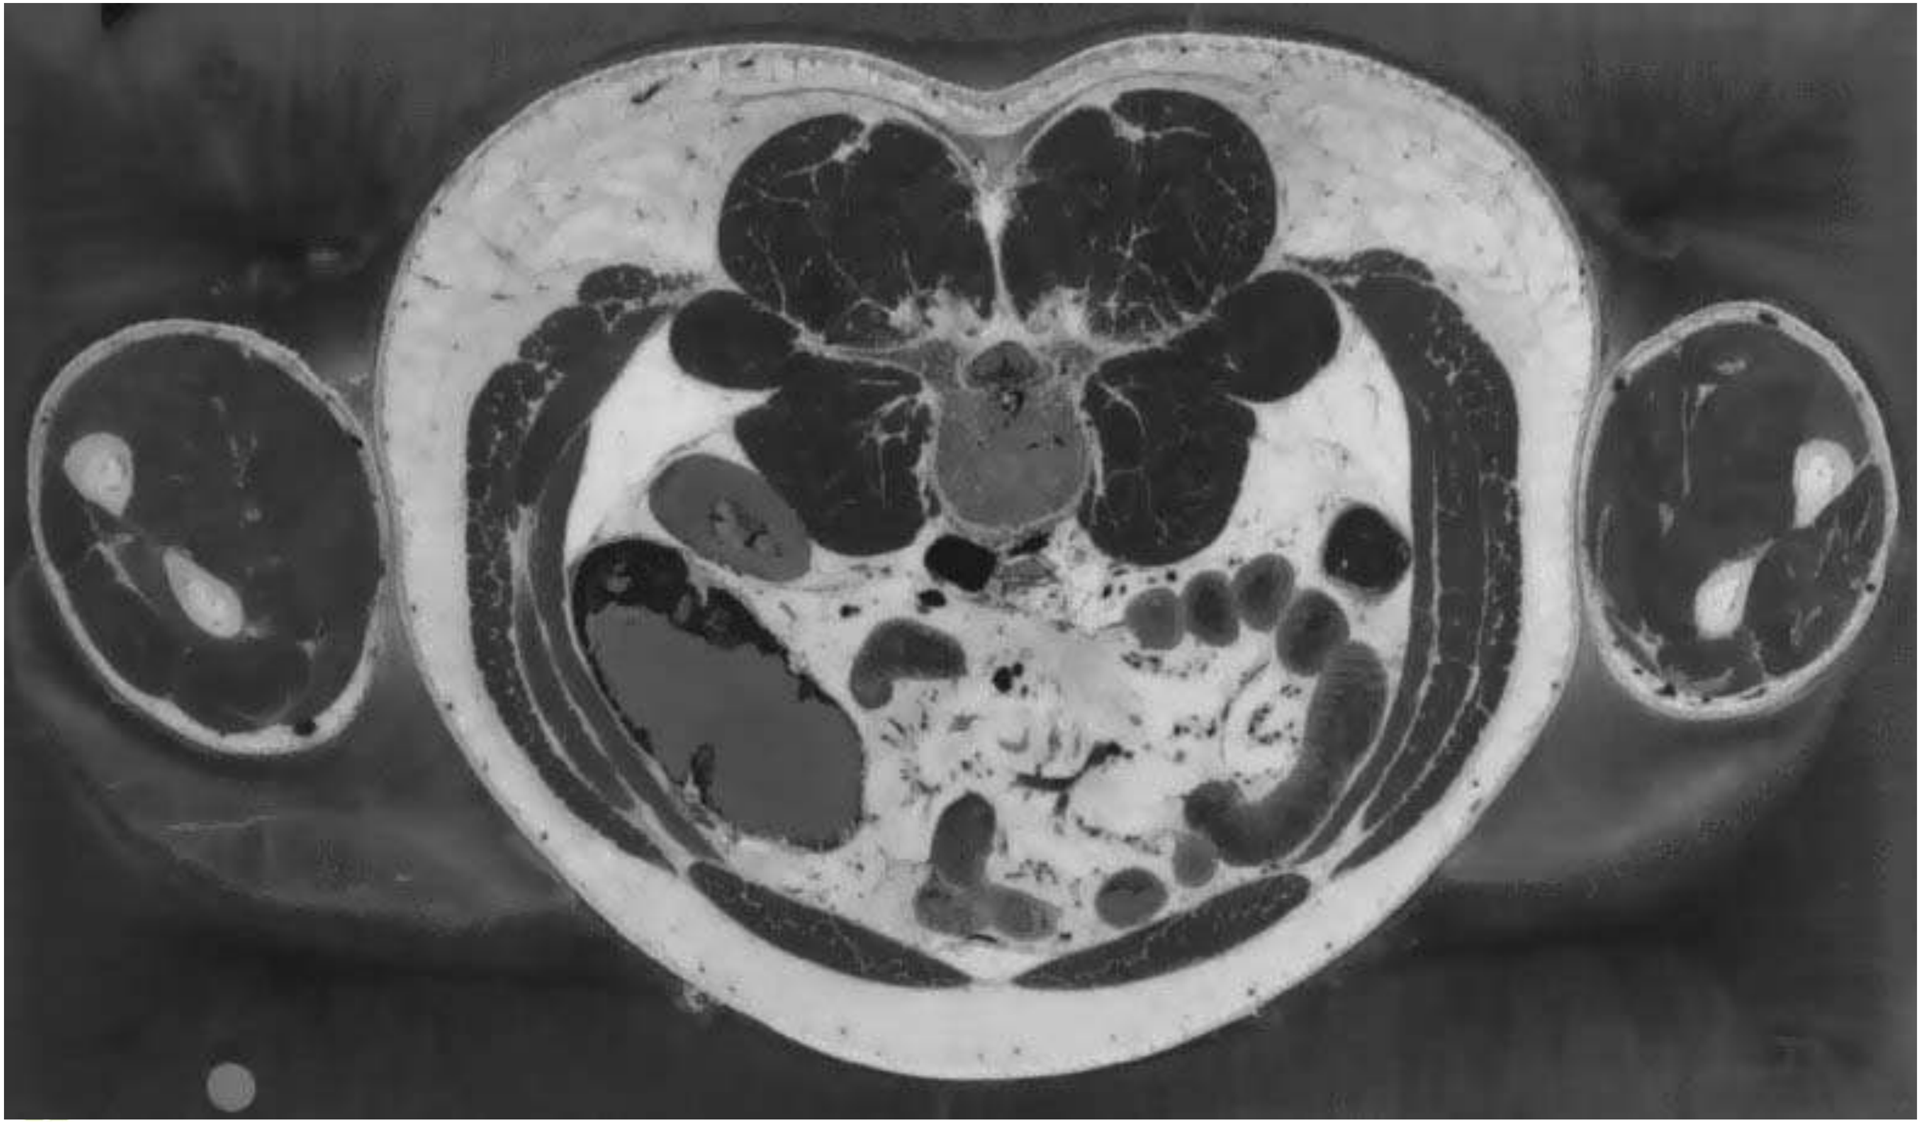

# E4.4. Watershed: Exemplo

- Passo 2: Calculamos seu gradiente usando Sobel, Canny ou outro....

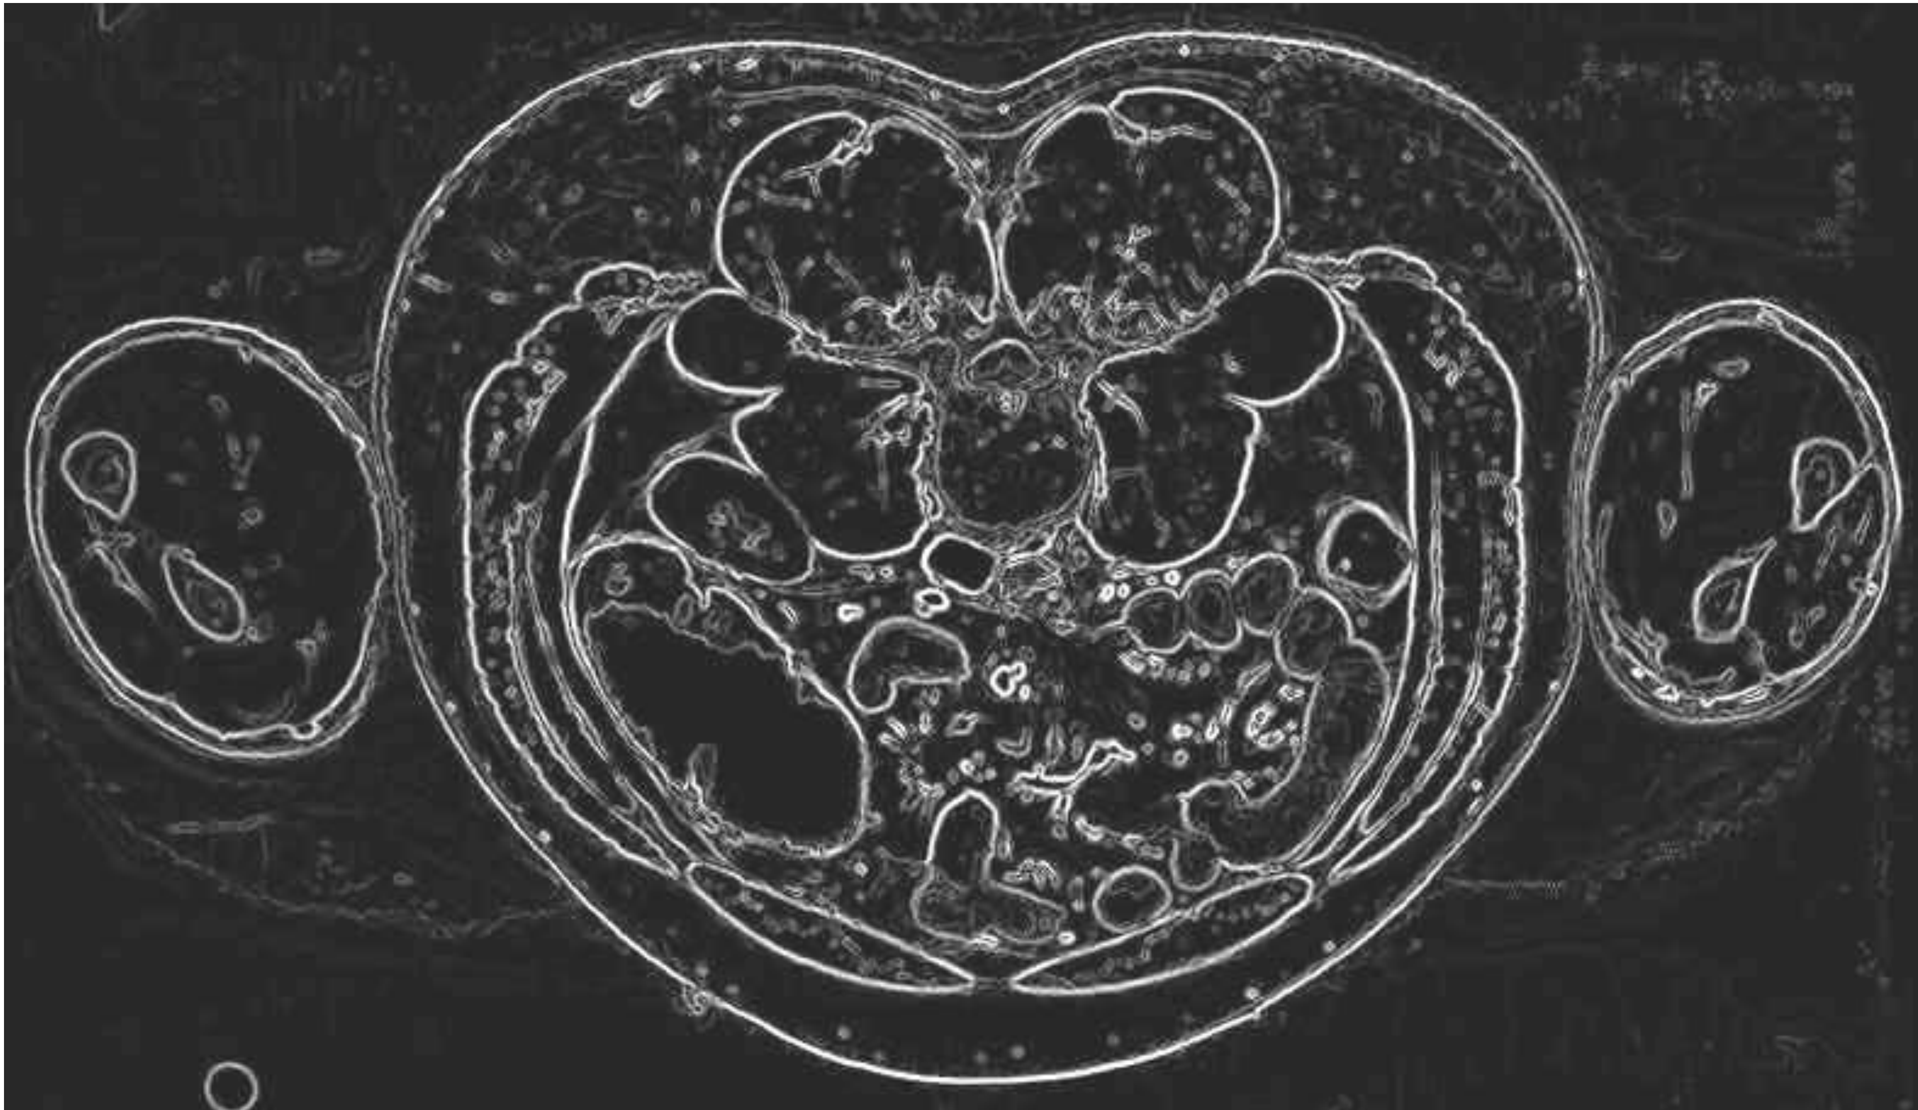

# E4.4. Watershed: Exemplo

- Passo 3: Agrupamos pixels vizinhos de gradiente (praticamente) nulo....

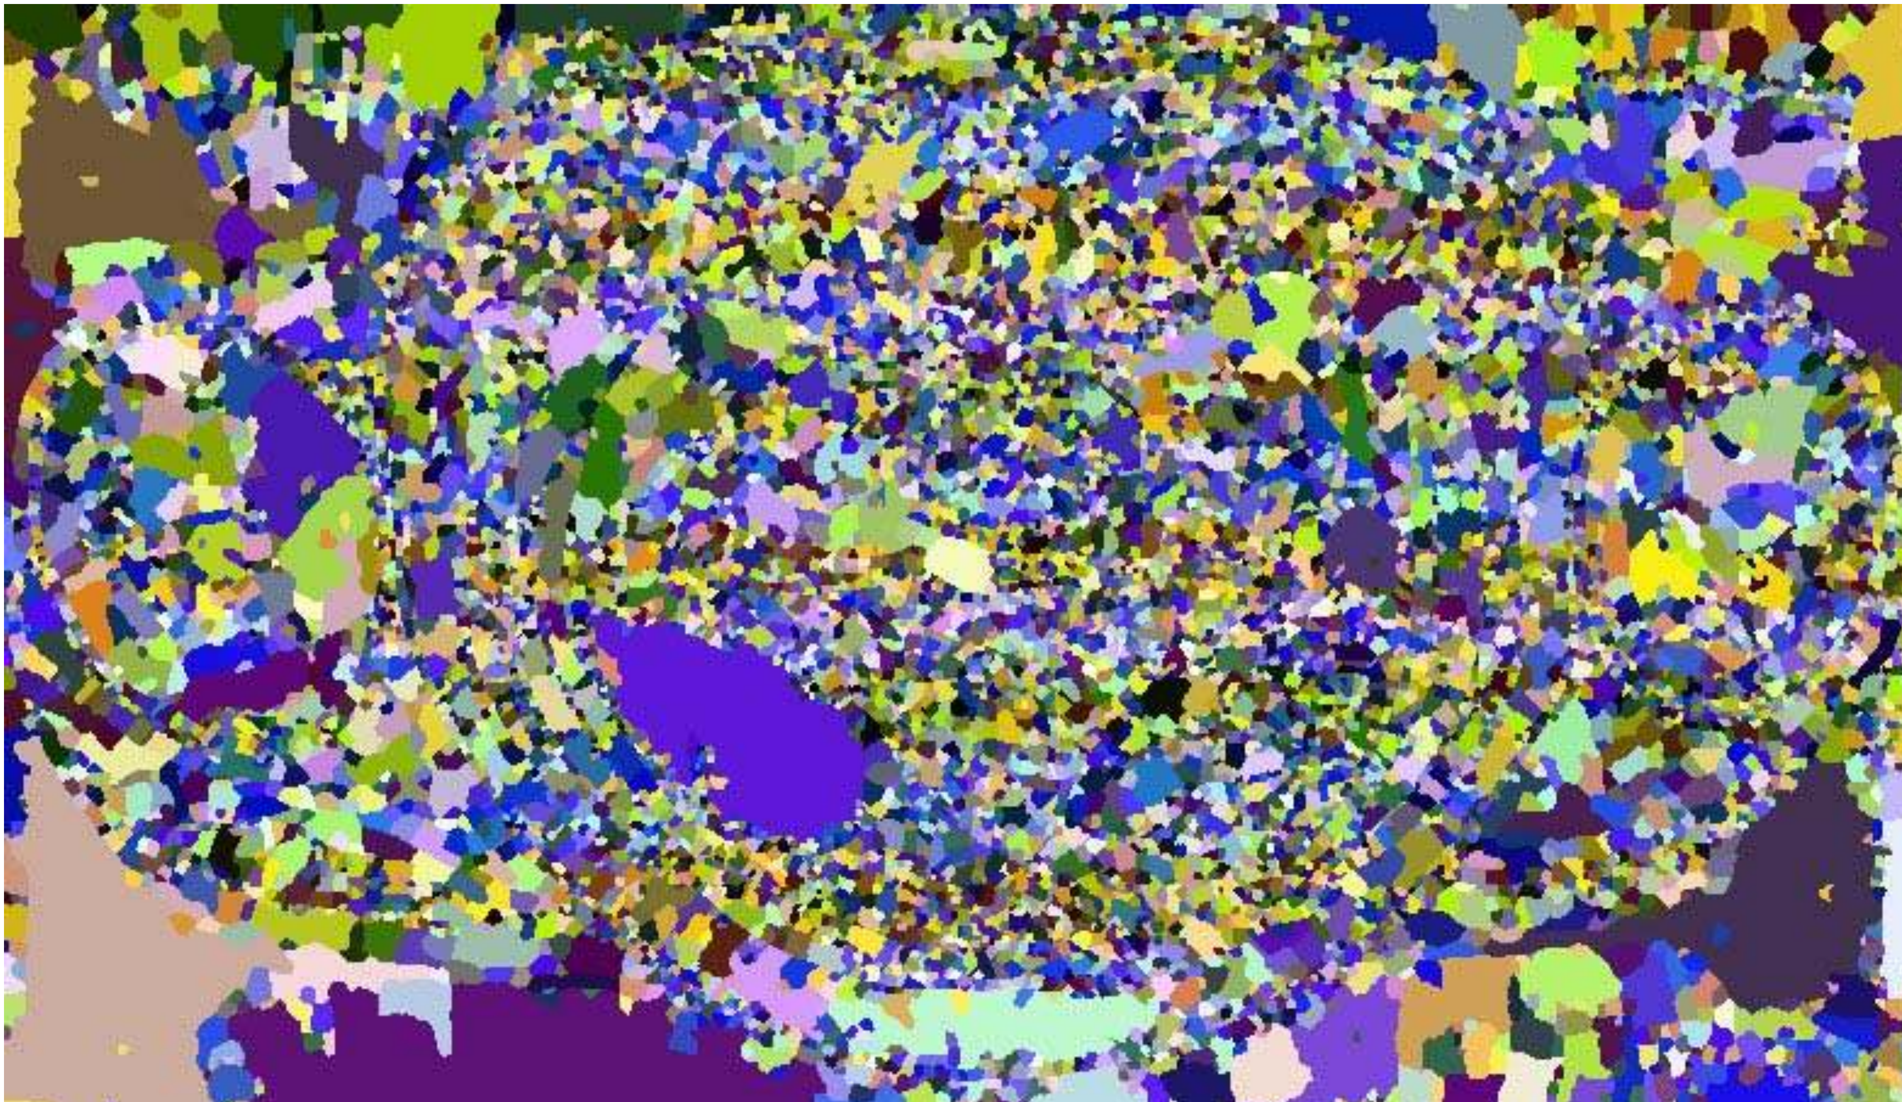

# E4.4. Watershed: Exemplo

- Passo 4: Agrupamos regiões elevando o nível da água (função *f*)....

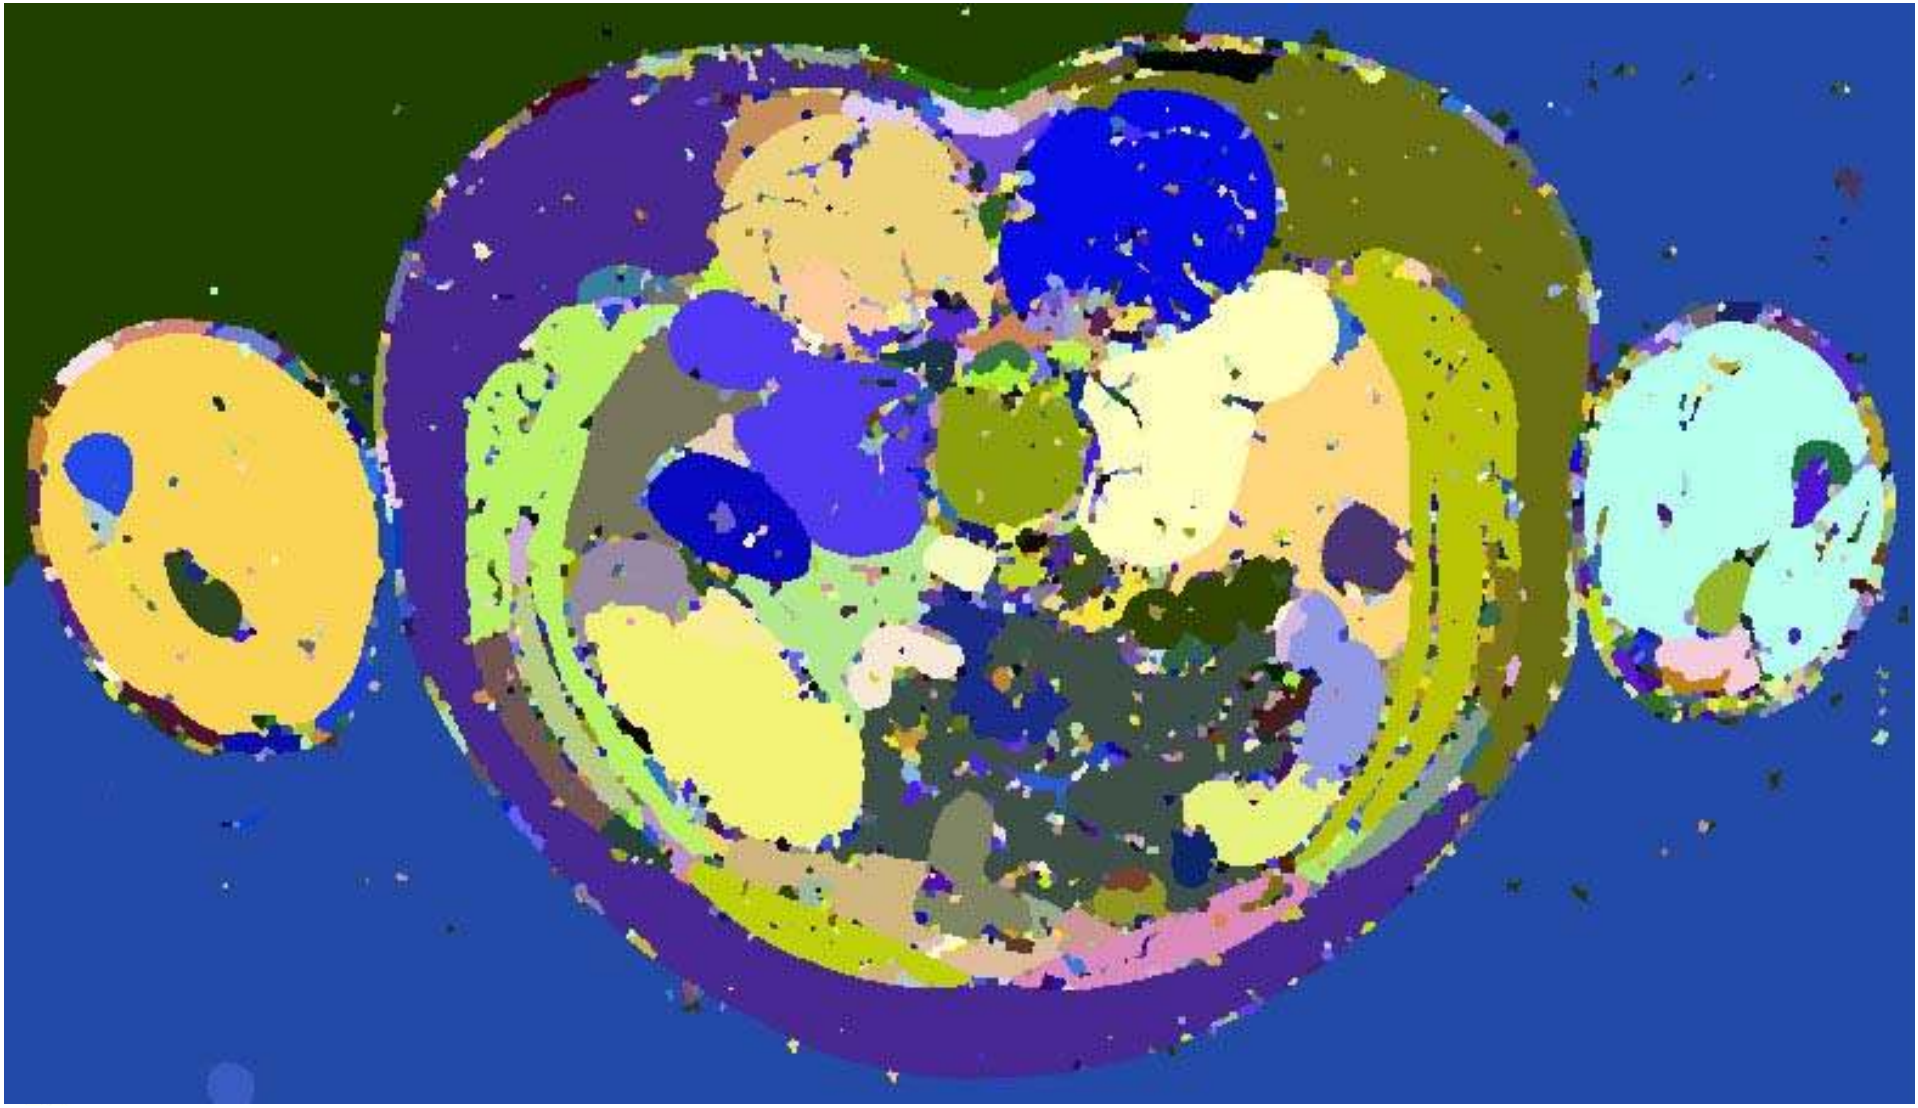

# E4.4. Watershed: Exemplo

- Passo 5: Agrupamos mais as regiões elevando mais o “nível da água” ...

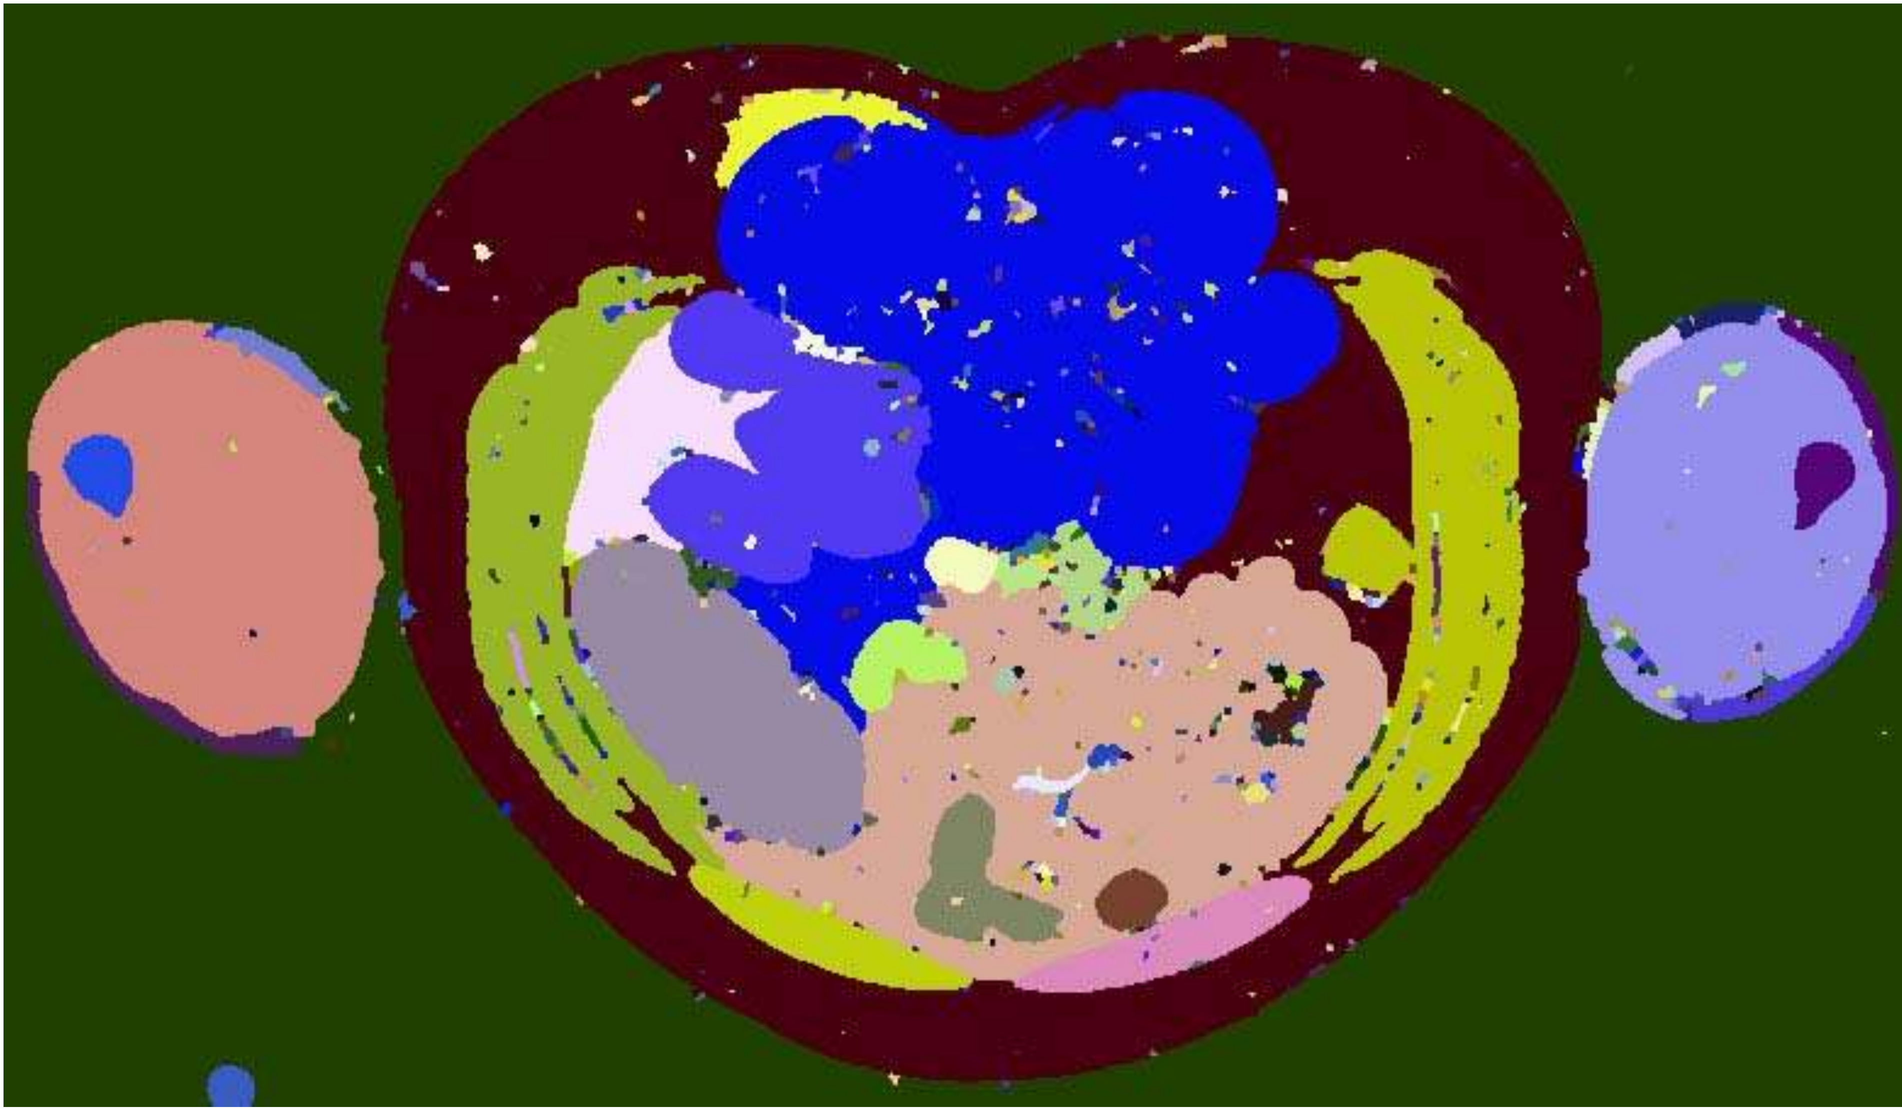

# Método de Contornos Ativos

Segmentação por descontinuidade

# Método de Contorno Ativo (MCA)

- Definição (KASS; WITKIN; TERZOPOULOS., 1987)
- Comporta-se como uma fita elástica (JÚNIOR, 2006)
- Vantagens (PICHUMANI, 1997):
  - facilidade de manipulação, pois, as forças externas se comportam de uma forma intuitiva;
  - autonomia e auto-adaptação na busca pelo estado de menor energia;
  - baixa sensibilidade ao ruído.
- MCAs:
  - Tradicional
  - Balão
  - GVF

# MCA Tradicional

- Função de Energia determinada por (KASS; WITKIN; TERZOPOULOS., 1987):

$$E = \int_o^1 E_{int}[c(s)] + E_{ext}[c(s)]ds$$

em que a parametrização geométrica da curva *c* é dada por:

$$\begin{cases} [0,1] & \rightarrow & \mathbb{R}^2 \\ s & \rightarrow & c(s) = [x(s), y(s)] \end{cases}$$

# MCA Tradicional

- Iterações sucessivas de minimização de energia através da análise da vizinhanca

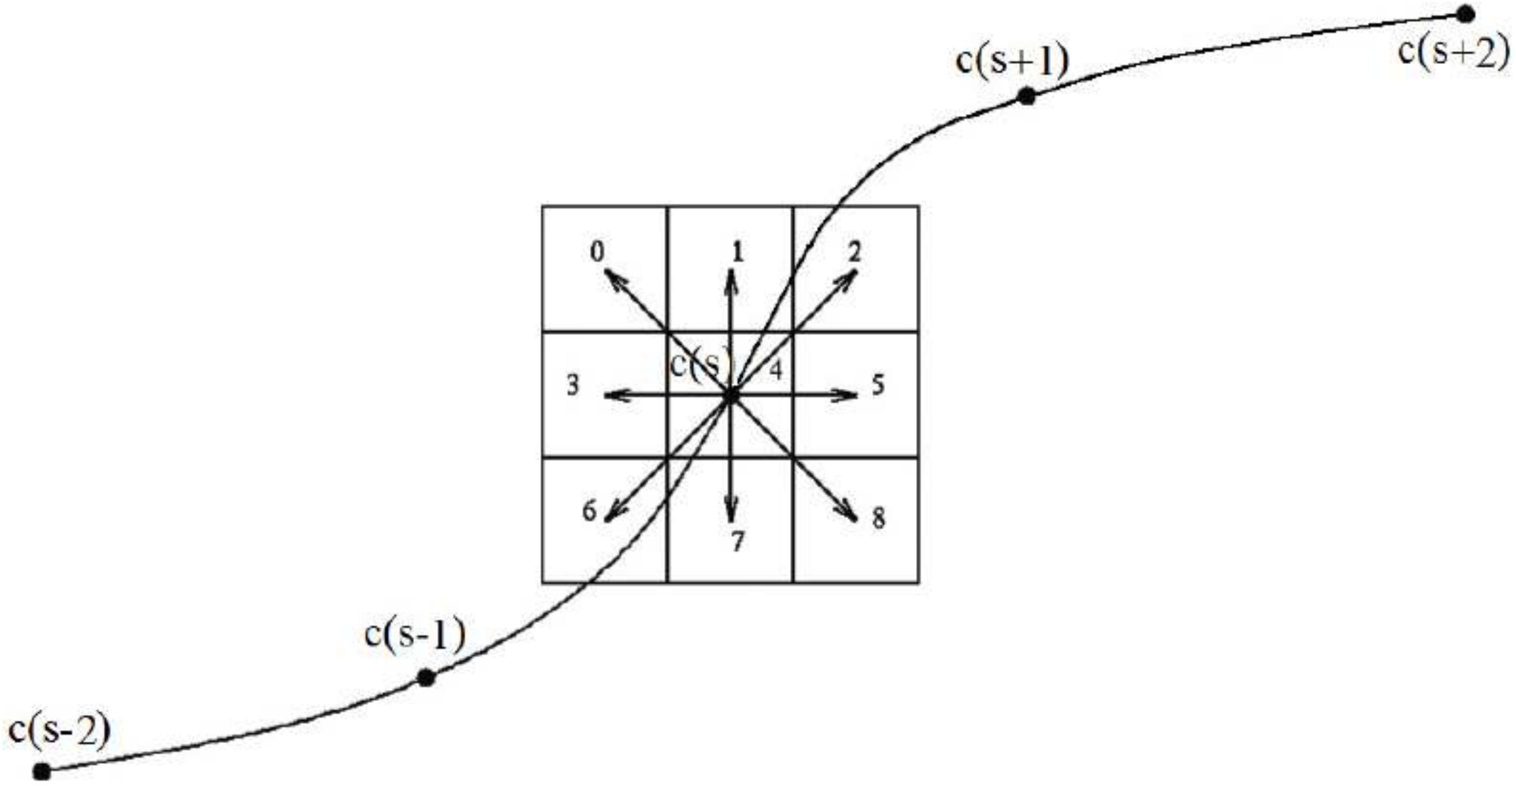


Figura 2.5: exemplo dos vizinhos considerados no cálculo da energia.

# MCA Tradicional

- Energia interna

$$E_{\text{int}}[c(s)] = \alpha(s)\left|\frac{d}{ds}c(s)\right|^2 + \beta(s)\left|\frac{d^2}{ds^2}c(s)\right|^2$$

$\left|\frac{d}{ds}c(s)\right|$ ➢ Força de continuidade $F_{cont}$

$\left|\frac{d^2}{ds^2}c(s)\right|$ ➢ Força de curvatura $F_{curv}$

- Energia externa

$$E_{\text{externa}}(V_i) = w_{line}E_{line}(V_i) + w_{grad}E_{grad}(V_i) + w_{term}E_{term}(V_i)$$

➢ Operador de gradiente Sobel

# MCA Tradicional

- MCA Greedy

$$E[c(s)] = \alpha(s)\left|\frac{dc(s)}{ds}\right|^2 + \beta(s)\left|\frac{d^2c(s)}{ds^2}\right|^2 + \gamma(s)E_{ext}[c(s)]$$

Aplicando a aproximação de Euler-Langrage (KASS; WITKIN; TERZOPOULOS., 1987)

$$\left|\frac{dc(s)}{ds}\right|^2 \approx |c(s) - c(s-1)|^2 = [x(s) - x(s-1)]^2 + [y(s) - y(s-1)]^2$$

Deste modo é dada por:

$$F_{cont} = \sqrt{[x(s) - x(s-1)]^2 + [y(s) - y(s-1)]^2}$$

# MCA Tradicional

- MCA Greedy

$$F_{cont} = \sqrt{[x(s) - x(s-1)]^2 + [y(s) - y(s-1)]^2}$$

  - Necessidade da distância média DM

$$DM = \frac{\sum_{i=0}^{N-1} \sqrt{(x_i - x_{i-1})^2 + (y_i - y_{i-1})^2}}{N}$$

  - Inserindo DM na equação de $F_{cont}$

$$F_{cont} = \left| DM - \sqrt{[x(s) - x(s-1)]^2 + [y(s) - y(s-1)]^2} \right|$$

# MCA Tradicional

- MCA Greedy

$$\left|\frac{d^2c(s)}{ds^2}\right|^2 \approx |c(s-1) - 2c(s) + c(s+1)|^2$$

Do mesmo modo, aplicando a aproximação de Euler-Langrage (KASS; WITKIN; TERZOPOULOS., 1987) na segunda derivada :

resultando em (NIXON; AGUADO, 2002)

$$F_{curv} = \sqrt{[x(s-1) - 2x(s) - x(s+1)]^2 + [y(s-1) - 2y(s) - y(s+1)]^2}$$

# MCA Tradicional

- Limitações
  - Parametrização (BOUHOURS, 2006)
  - Inicialização afastada das bordas (JÚNIOR, 2006)

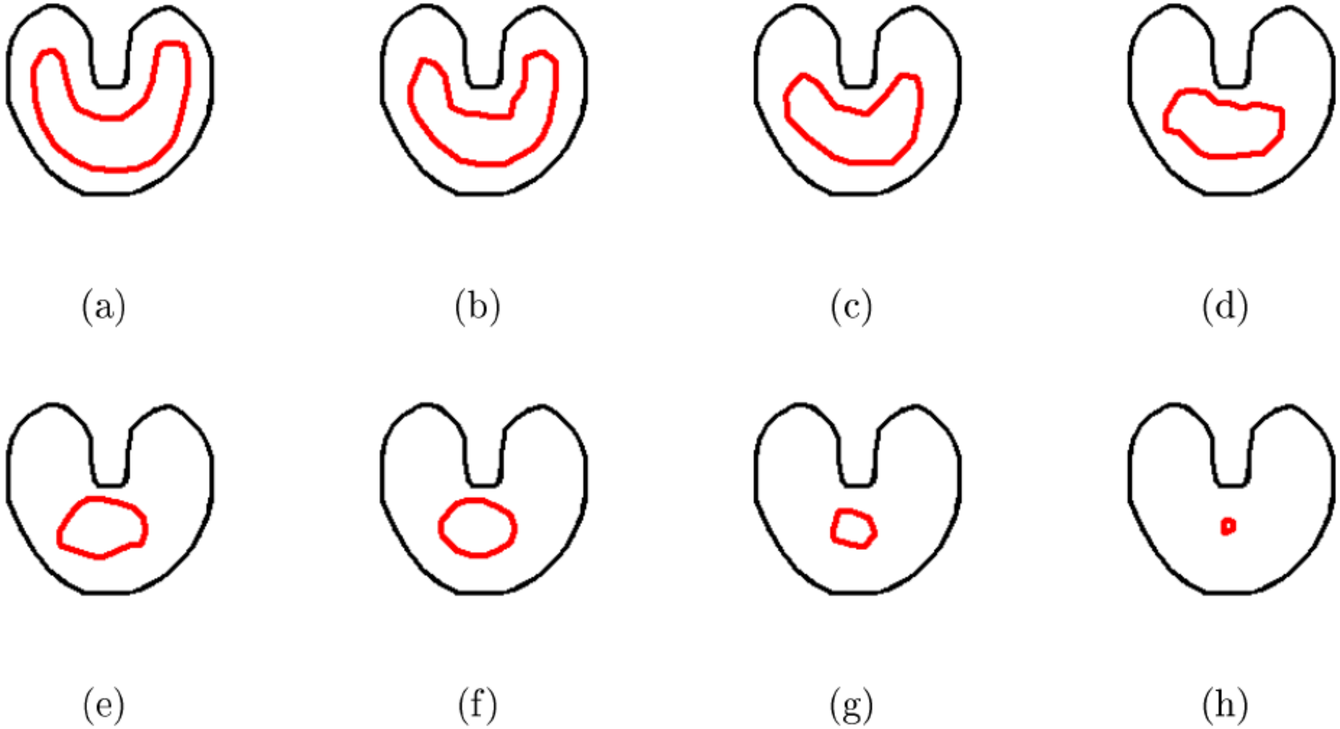


Figura 2.6: iteração do MCA Tradicional: a) inicialização, b) a g) iterações intermediárias e h) resultado final.

# MCA Tradicional

- Limitações
  - Segmentação de objetos côncavos

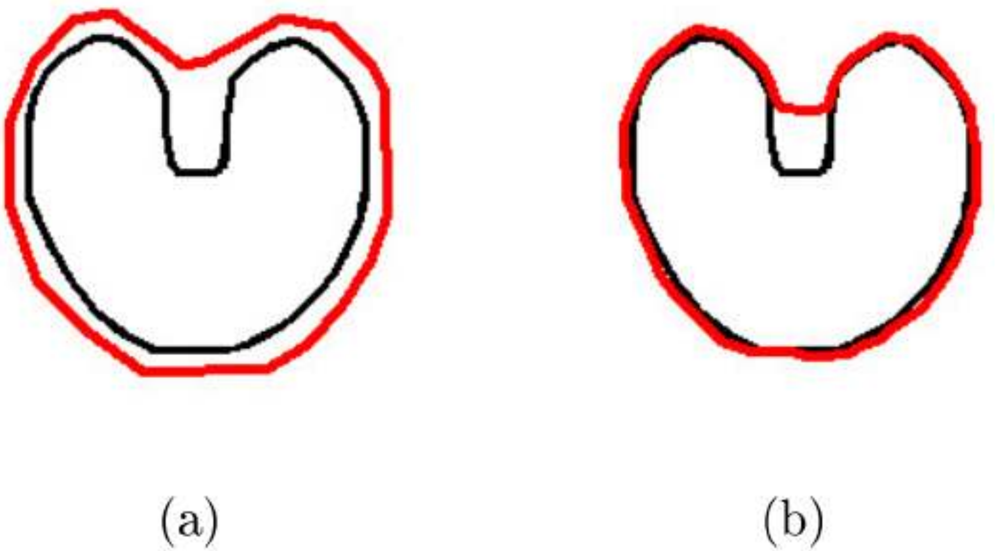

Figura 2.7: aplicação do MCA Tradicional na segmentação de objetos côncavos: a) inicialização e b) resultado final.

- MCA Balão e MCA GVF

# MCA Balão

- Desenvolvida por Cohen (COHEN, 1991)
- Mesma energia externa do MCA Tradicional
- Nova energia interna dada por

$$E_{int}[c(s)] = w_{cont}F_{cont}[c(s)] + w_{bal}F_{bal}[c(s)]$$

em que

$$F_{bal}[c(s)] = \sqrt{E_x^2 + E_y^2},$$

sendo

$$E_x = x(s) - \left|\frac{x_t - x(s)}{x_{max}}\right|$$

$$E_y = y(s) - \left|\frac{y_t - y(s)}{y_{max}}\right|$$

# MCA Balão

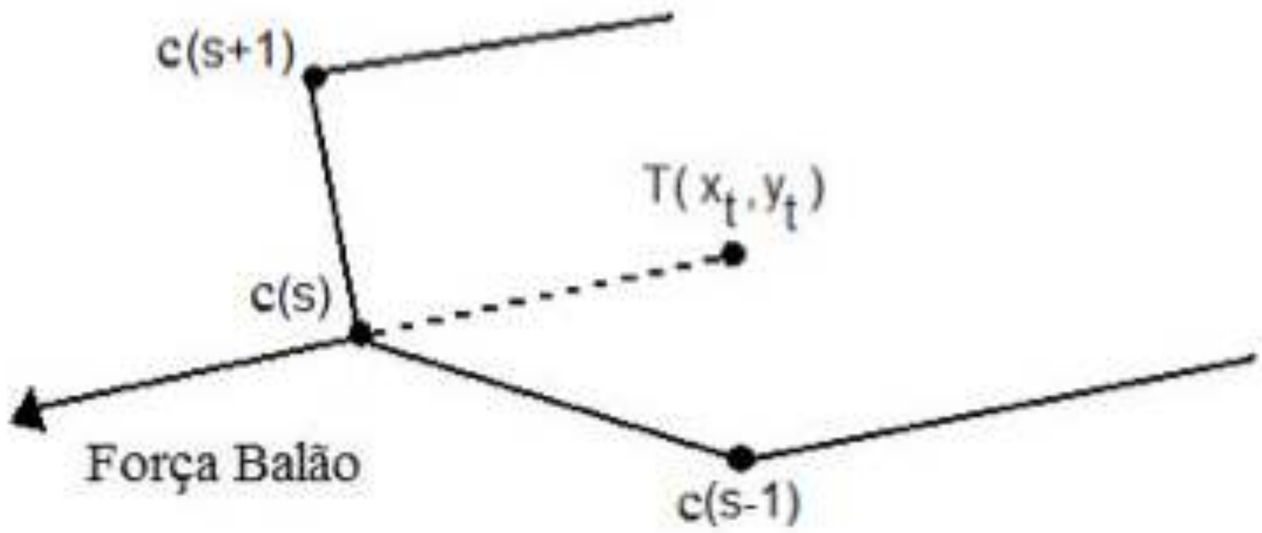


Figura 2.8: exemplo da atuação da força balão repulsando um ponto *c(s)* em direção contrária do baricentro *T(xt, yt).*

# MCA Balão

- Superando a limitação da inicialização interna e afastada das bordas

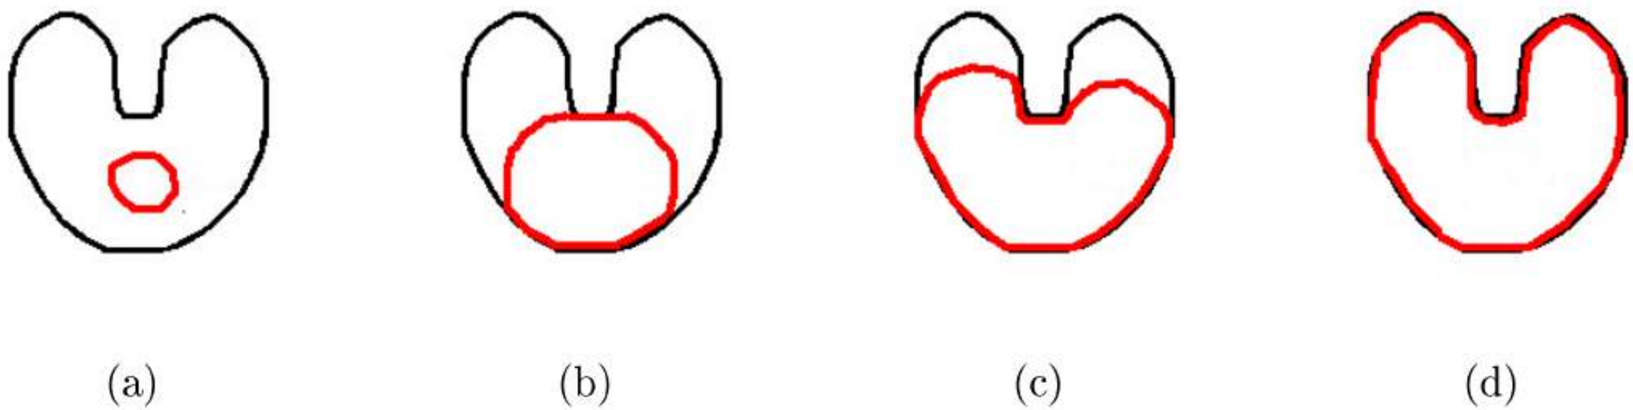


Figura 2.9: a) inicialização da curva, b) e c) são resultados das iterações intermediárias e d) resultado final da segmentação pelo MCA Balão.

# MCA Balão

- limitação da inicialização interna, afastada das bordas e descentralizada

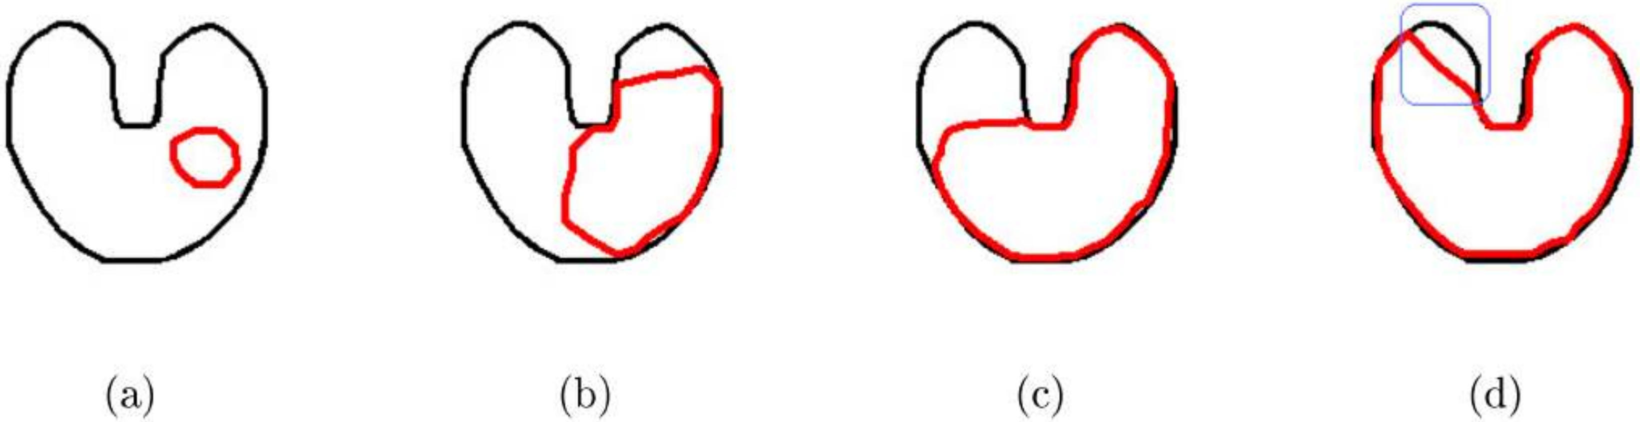


Figura 2.9: a) inicialização da curva, b) e c) são resultados das iterações intermediárias e d) resultado final da segmentação pelo MCA Balão.

# MCA Gradient Vector Flow

Os principais problemas no uso do gradiente da imagem como uma força externa no MCA são (XU; PRINCE, 1997):

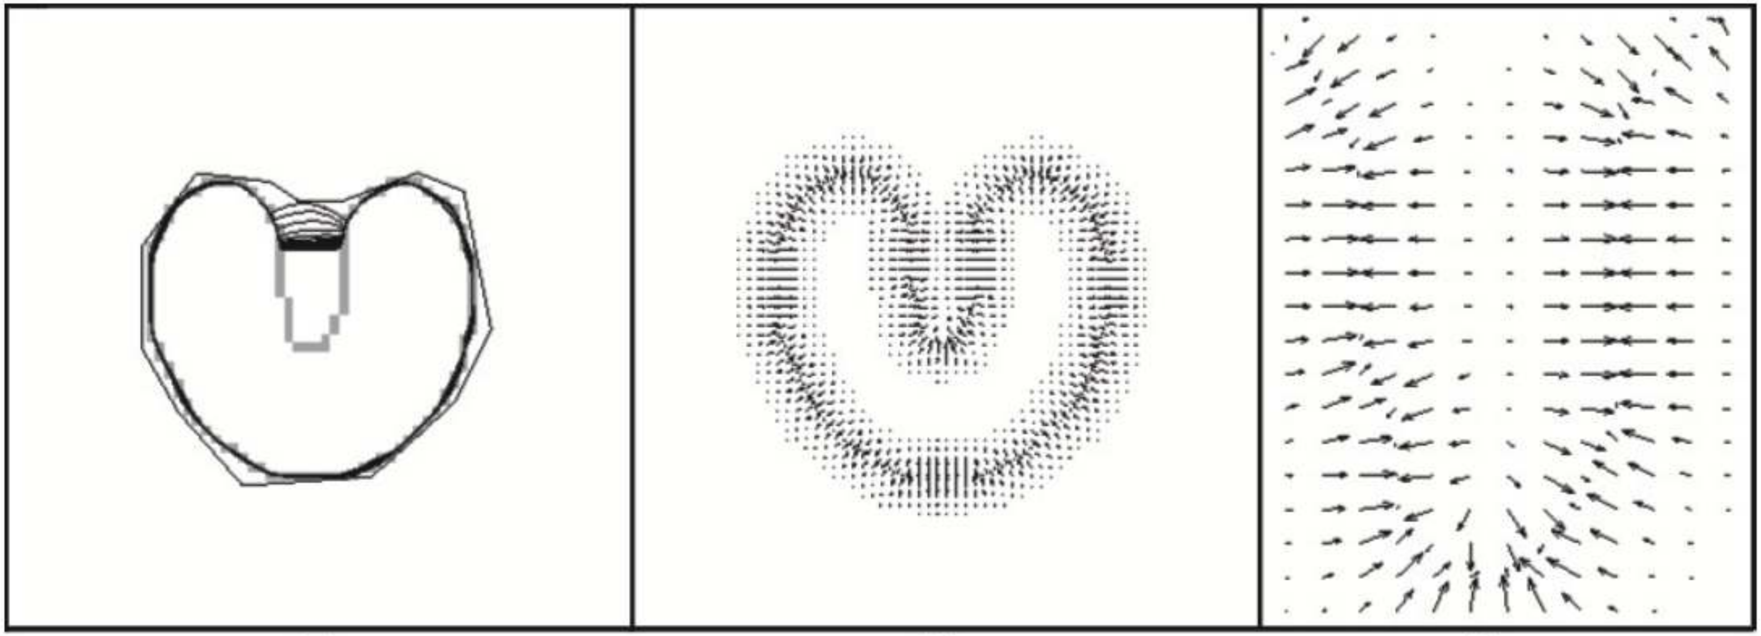

(a) (b) (c)

Figura 2.11: a) convergência do *snake*, b) campo de vetores gradiente, c) ampliação da concavidade do campo de gradiente (Xu and Price, 1997).

# MCA Gradient Vector Flow

A energia deste método é dada por

$$\alpha(s)\left|\frac{dc(s)}{ds}\right|^2 + \beta(s)\left|\frac{d^2c(s)}{ds^2}\right|^2 + E_{ext}[c(s)] = 0$$

em que

$$E_{ext} = w(x,y)$$

sendo o fluxo de vetores gradiente *w(x,y)* determinado por

$$w(x,y) = [u(x,y), v(x,y)]$$

# MCA Gradient Vector Flow

$$w(x,y) = [u(x,y), v(x,y)]$$

Esta energia externa é uma expansão do mapa das bordas, gerada por iterações sucessivas de minimização da função

$$\varepsilon = \int\int \{\mu(\frac{\partial u}{\partial x}^2 + \frac{\partial u}{\partial y}^2 + \frac{\partial v}{\partial x}^2 + \frac{\partial v}{\partial y}^2) + |\nabla f|^2 |w - \nabla f|^2\} dx dy$$

# MCA Gradient Vector Flow

Utilizando μ 0,1 para 100, 200 e 400 iterações, têm-se

(a) (b) (c)

Figura 2.12: fluxo Gradiente obtido com a) 100 iterações, b) 200 iterações, e c) 400 iterações.

# MCA Gradient Vector Flow

O MCA GVF é avaliado neste trabalho utilizando as limitações encontradas nos MCAs Tradicional e Balão

- A primeira limitação do MCA Tradicional, corrigida pelo MCA GVF, é a inicialização fora do objeto com concavidades

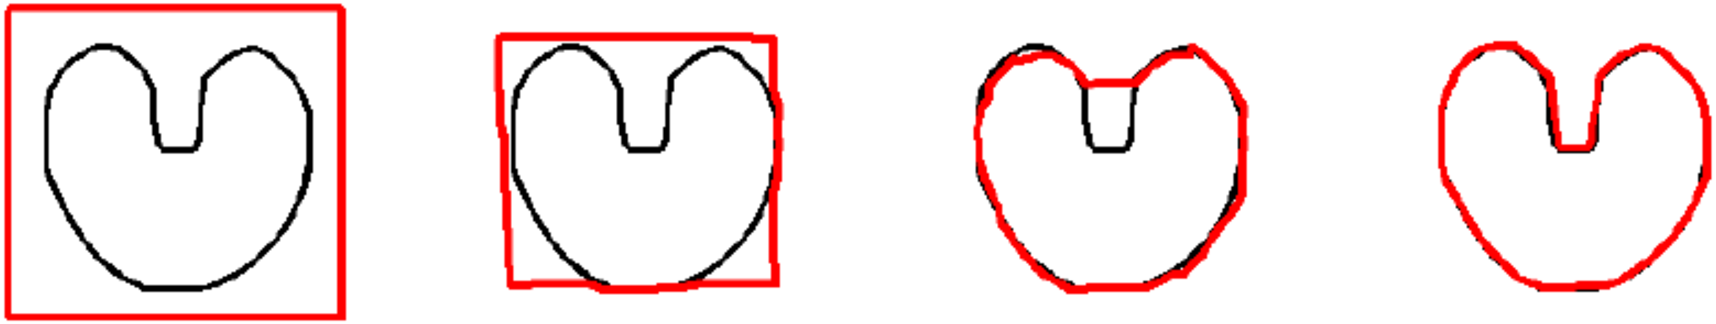

(a) (b) (c) (d)

Figura 2.13: primeira limitação do MCA Tradicional superada pelo MCA GVF: a) inicialização da curva, b) e c) iterações intermediárias d) resultado final da segmentação.

# MCA Gradient Vector Flow

O MCA GVF é avaliado neste trabalho utilizando as limitações encontradas nos MCAs Tradicional e Balão

- A segunda limitação do MCA Tradicional, corrigida pelo MCA GVF, inicialização da curva dentro do objeto e afastada das suas bordas

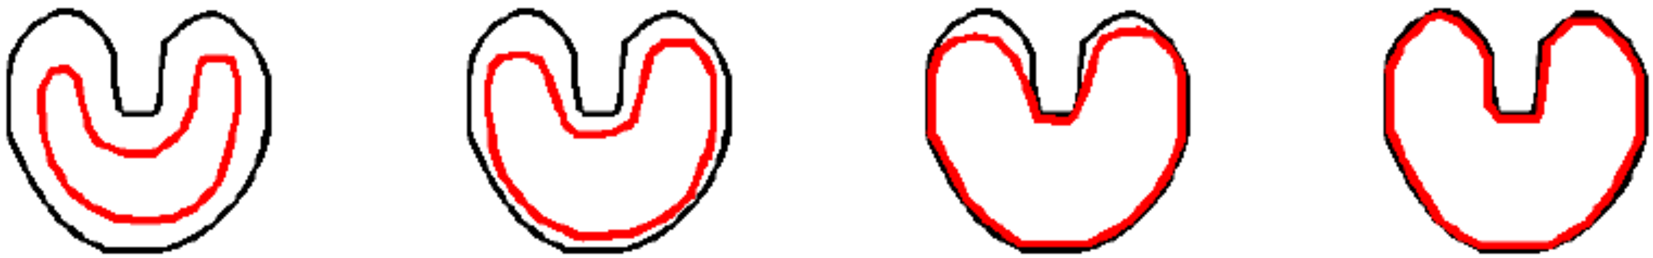

(a) (b) (c) (d)

Figura 2.14: segunda limitação do MCA Tradicional, corrigida pelo MCA GVF: a) inicialização da curva, b) e c) iterações intermediárias e d) resultado final da segmentação pelo MCA GVF.

# MCA Gradient Vector Flow

O MCA GVF é avaliado neste trabalho utilizando as limitações encontradas nos MCAs Tradicional e Balão

- A limitação do MCA Balão também ocorre no MCA GVF, inicialização da curva dentro do objeto, afastada das suas bordas e descentralizada

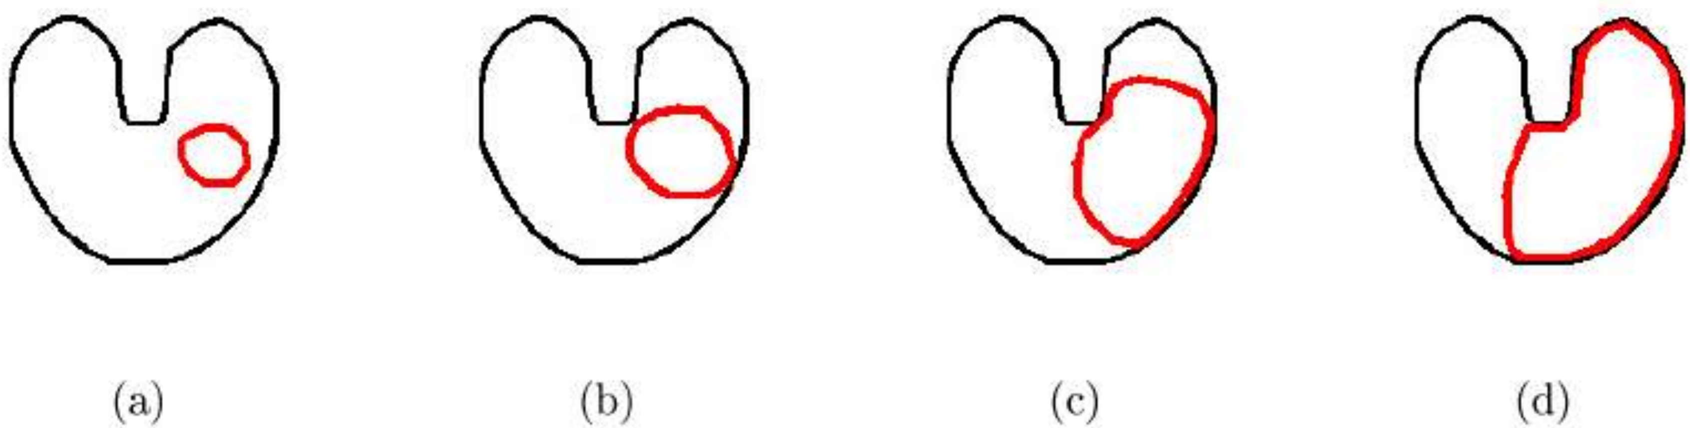


Figura 2.15: limitação dos MCAs Tradicional, Balão e GVF: a) inicialização da curva, b) e c) iterações intermediárias, e d) resultado final da segmentação pelo método GVF.

# Aplicações de Contornos Ativos

## Segmentação utilizando MCA na área médica

- segmentação do coração em imagens de ressonância magnética (PLUEMPITIWIRIYAWEJ; SOTTHIVIRAT, 2005)
- segmentação do cérebro em imagens de ressonância magnética (LIANG, 2008; SOUZA, 2003; HADZIAVDIC, 2000)
- segmentação do coração em imagens de ultrassom (TAUBER; BATATIA; AYACHE, 2005; LI; ACTON, 2007)
- segmentação de abdomens em imagens de TC (SHEN; KASSIM, 2007)
- segmentação dos pulmões em imagens de TC (ITAI; KIM; ISHIKAWA, 2007).
  - Depende da inicialização próxima das bordas
    - Doenças, ruído, falta de distinção das regiões com ar

# Método de Contornos Ativos

Doutorado do Prof. Pedro Pedrosa

# Método de Contornos Ativos

## Nova energia interna

Doutorado do Prof. Pedro Pedrosa

# Energia Interna Balão Adaptativo

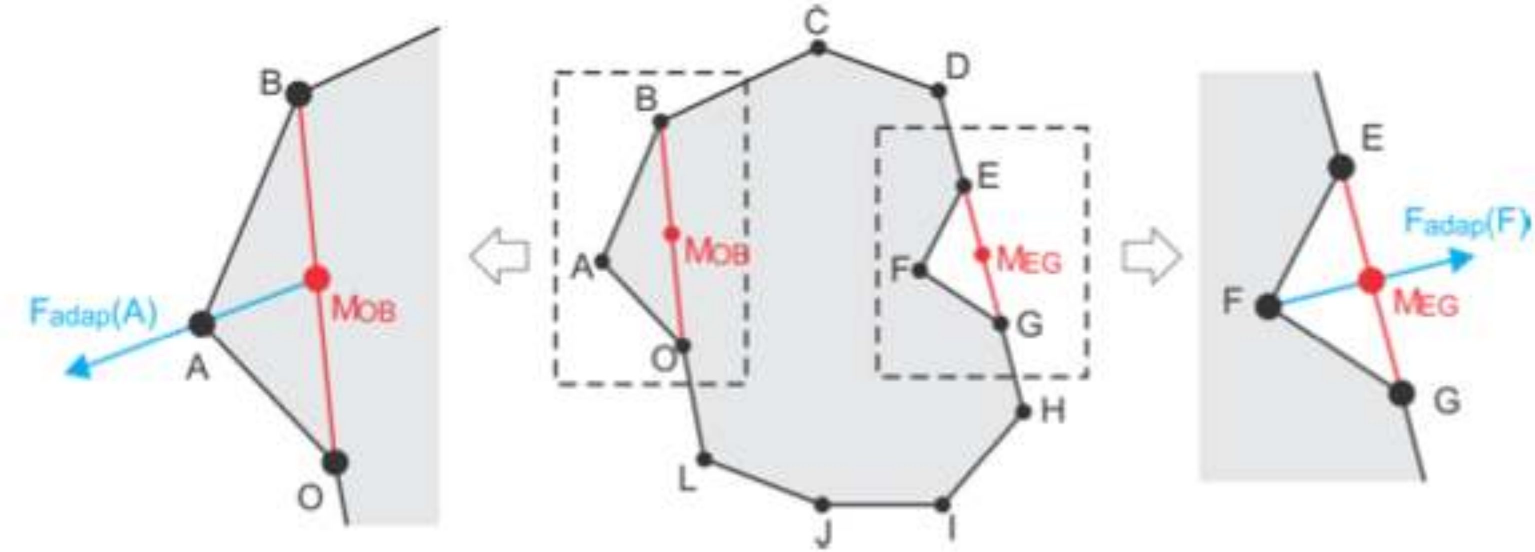


$$F_{adap}[c(s)] = \sqrt{E_x^2 + E_y^2},$$

$$E_x = |x(s) \pm x_m| \qquad E_y = |y(s) \pm y_m|$$

# Energia Interna Balão Adaptativo

# Método de Contornos Ativos

## Nova energia externa

Doutorado do Prof. Pedro Pedrosa

# Energia Externa Crisp Adaptativo

Análise das Densidades Pulmonares (ADP) – Mestrado do Prof. Pedro Pedrosa

- $u_0$ - hiperaeradas ($-1000$ a $-950$ UH) ;
- $u_1$ - normalmente aeradas ($-950$ a $-500$ UH);
- $u_2$ - pouco aeradas ($-500$ a $-100$ UH);
- $u_3$ - não aeradas ($-100$ a $100$ UH);
- $u_4$ - osso ($600$ a $2000$ UH);
- $u_5$ - áreas não classificadas (densidades que não se enquadram nas demais).

# Energia Externa Crisp Adaptativo

ADP

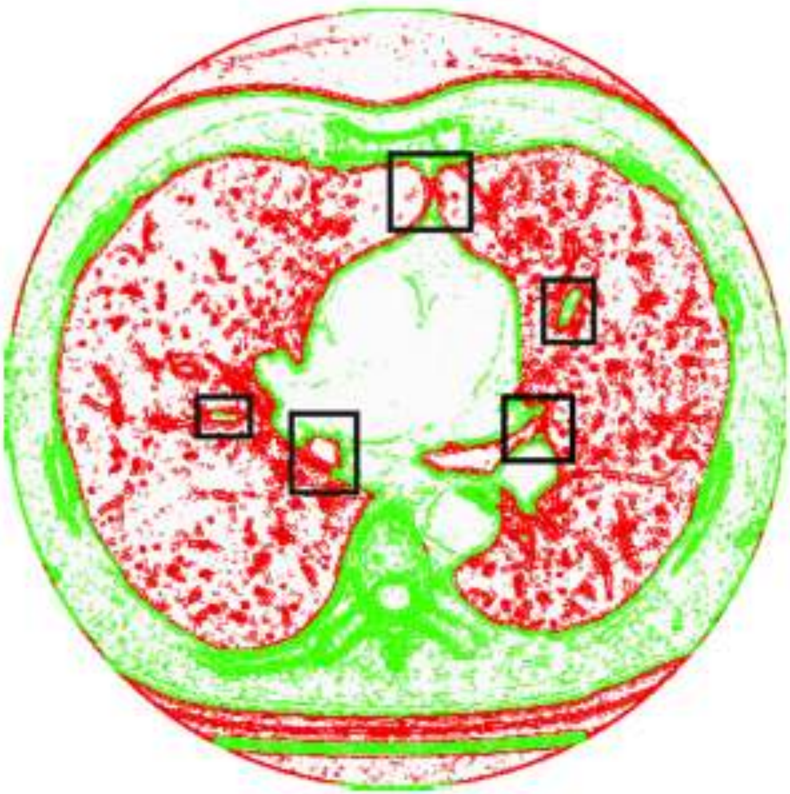

(a)

ADP – RNA MLP

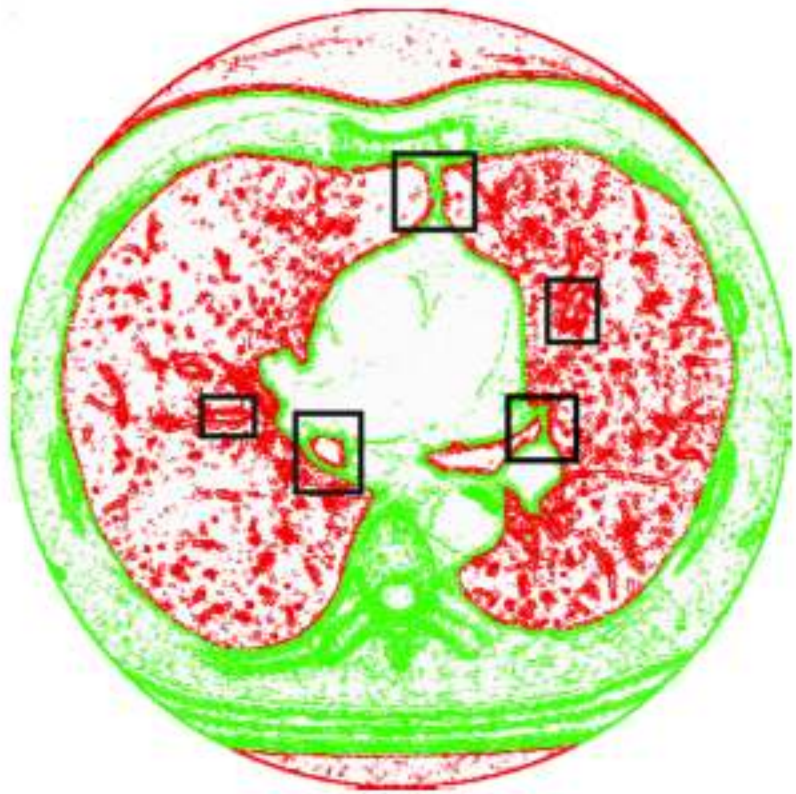

(b)

# Energia Externa Crisp Adaptativo

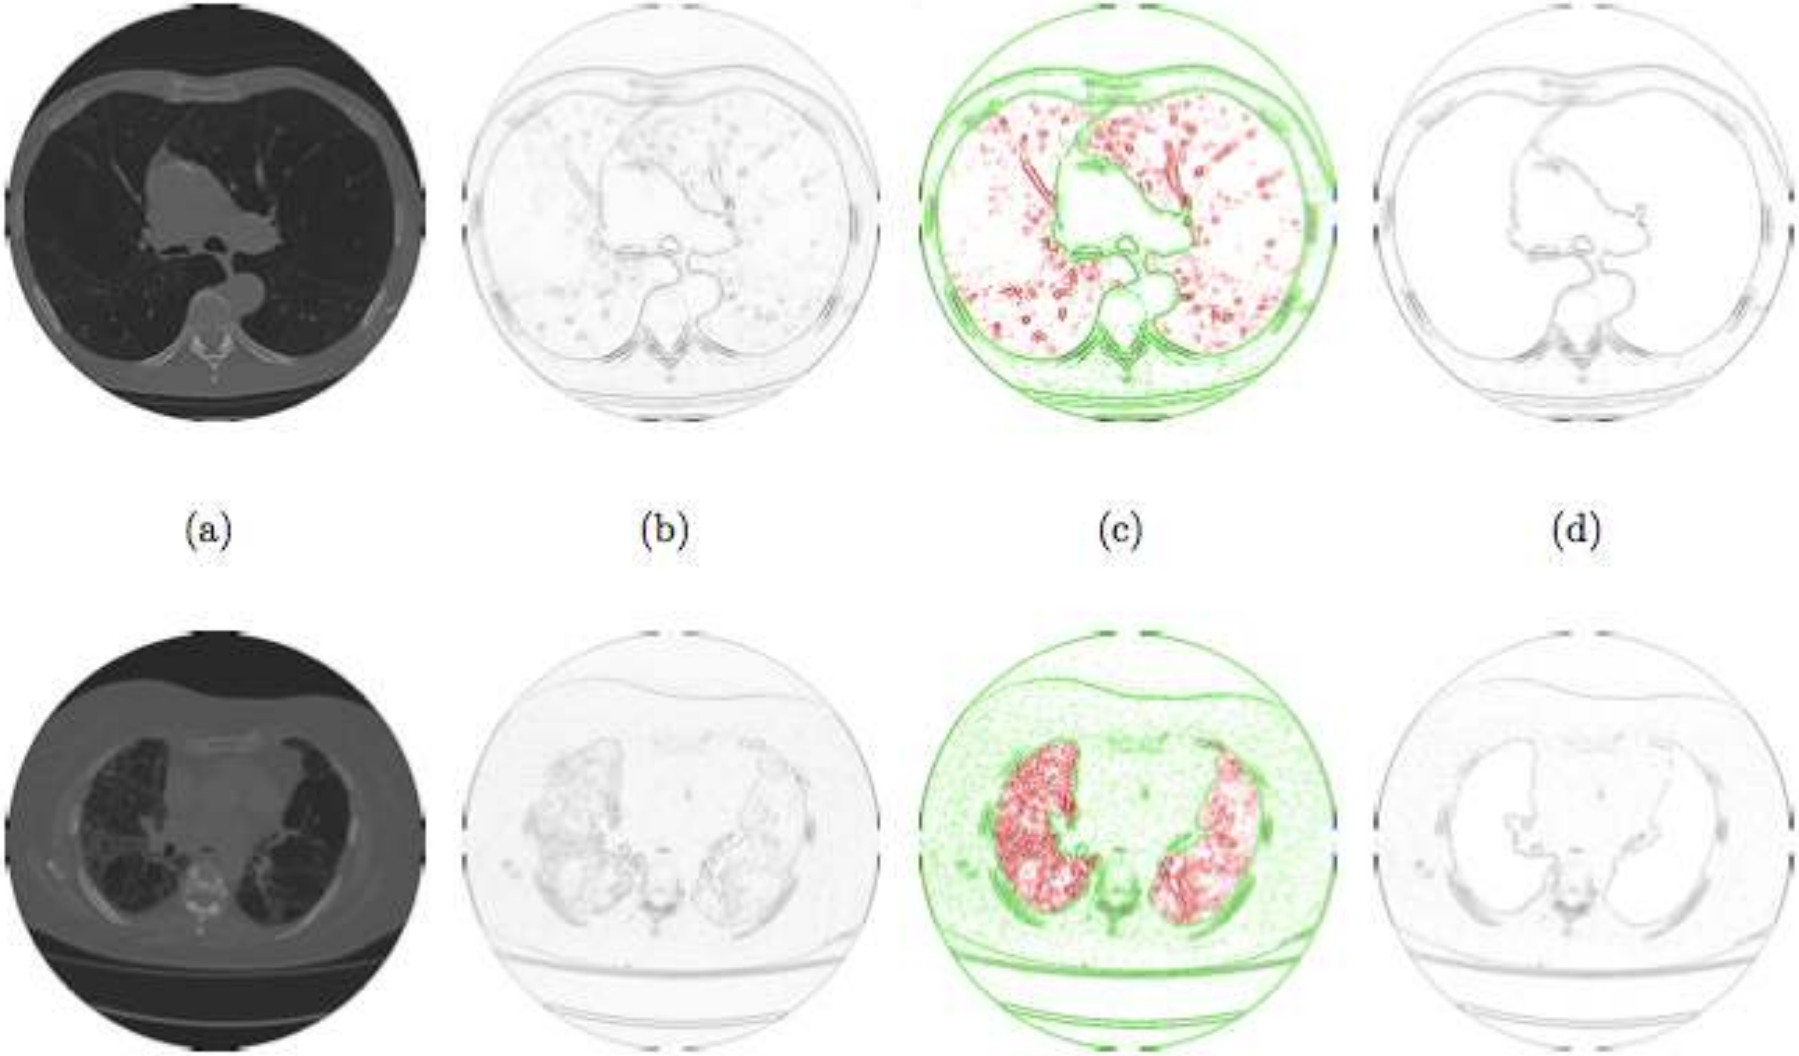

(a) (b) (c) (d) (e) (f) (g) (h)

# Método de Contornos Ativos

## MCA Crisp Adaptativo

Doutorado do Prof. Pedro Pedrosa

# MCA Crisp Adaptativo

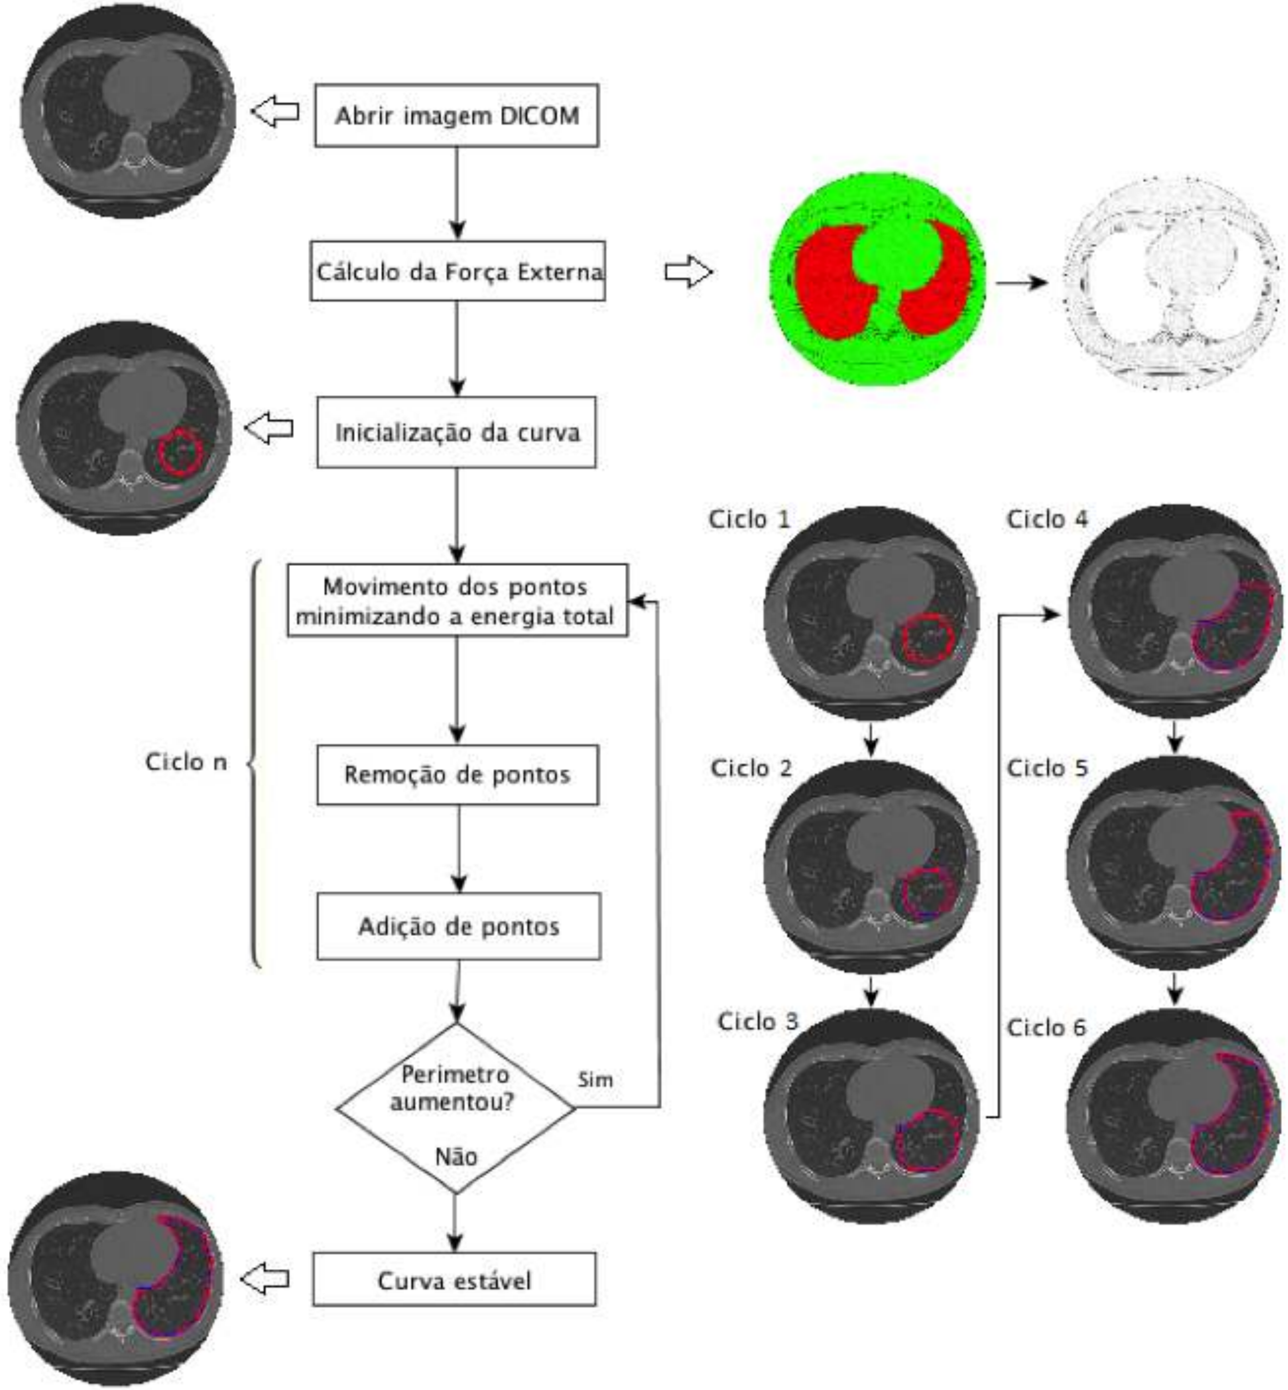

# MCA Crisp Adaptativo

(a) (b) (c)

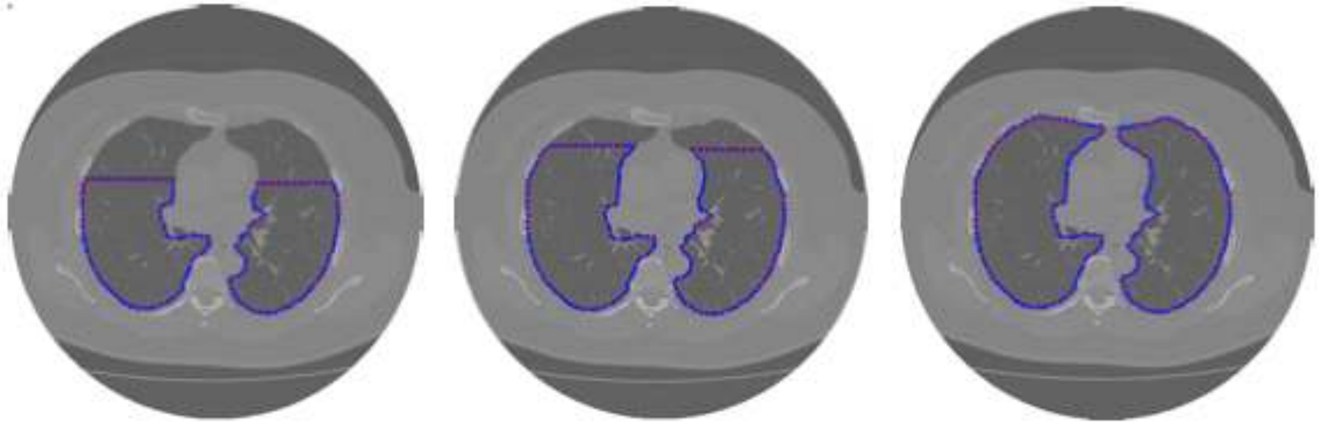

(d) (e) (f)

# Método de Contornos Ativos

## MCA Crisp Adaptativo

## Expansão para 3D

Doutorado do Prof. Pedro Pedrosa

# MCA Crisp Adaptativo 3D

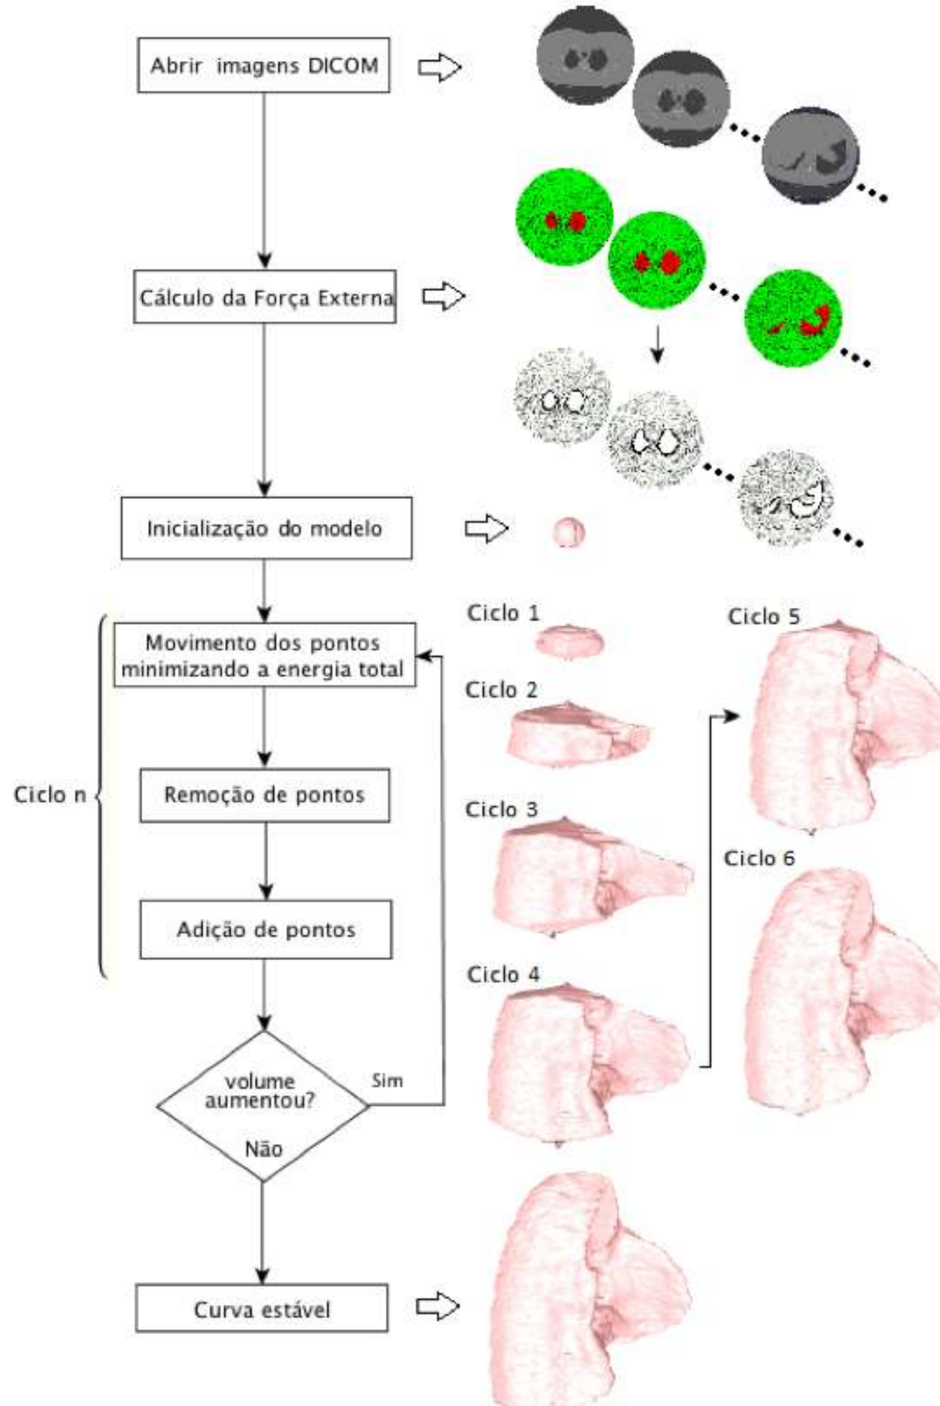

# Videos do doutorado do prof Pedro Pedrosa

1. MCA Balão Adaptativo – https://www.dropbox.com/s/ntnrqkc1b5iaiox/MCA_Bal%C3%A3o_Adaptativo_2D.m4v?dl=0

2. MCA Crisp Adaptativo – Pulmões
   Sadios: https://www.dropbox.com/s/isb06flbj7riwos/2D_Doutorado_Sadio.m4v?dl=0
   Fibrose: https://www.dropbox.com/s/xvam878g3ge0uti/2D_Doutorado_Fibrose.m4v?dl=0

3. MCA Balão Adaptativo 3D – Modelos Sintéticos 3D
https://www.dropbox.com/s/hn5y9d98k761npk/3D_Sintetico_Ampulheta.m4v?dl=0

4. MCA Crisp Adaptativo 3D – Pulmões
   Exemplo: https://www.dropbox.com/s/h8dujn8ex6hnyyt/Doutorado_01_Messejana_01.m4v?dl=0
   Aplicações: https://www.dropbox.com/s/bobx0b06sadcvis/Doutorado_00_Demonstra%C3%A7%C3%A3o.m4v?dl=0

# Encaminhamentos

- Dúvidas?
- Próximo assunto
  - Segmentação deobjetos por descontinuidade